

Ocena podobieństwa sygnałów akustycznych z wykorzystaniem wektorowej reprezentacji cech dźwięku

– od cech akustycznych do trudności percepcyjnej: jak porównać dwa dźwięki?

Bartosz Lewandowski (ORCID:0009-0004-1158-0693)^{1,*}, Maciej J. Wróbel (ORCID:0000-0003-1865-2122)², and Ewaryst Tkacz (ORCID:0000-0003-2580-7954)³

^{1,3}Department of Clinical Engineering, Academy of Silesia in Katowice

²Department of Otolaryngology and Oncological Laryngology Collegium Medicum NCU

*Corresponding author: Bartosz Lewandowski, Ph.D., bartosz.lewandowski@akademiaslaska.pl

Streszczenie

Praca przedstawia opracowanie i walidację obiektywnej, numerycznej miary podobieństwa bodźców akustycznych. Głównym celem badań było stworzenie metryki opartej na wektorowej reprezentacji cech dźwięku, która pozwoli na ilościową ocenę ryzyka błędnej identyfikacji, złożonych z pojedynczych dźwięków próbek wynikającej z ich bliskości akustycznej, a nie z deficytów poznawczych słuchaczy.

Materiał badawczy stanowiło 24 nagrań odgłosów zwierząt, które opisano za pomocą 16 wymiarowych wektorów cech, obejmujących centroid widmowy, częstotliwość podstawową, współczynnik Peak-to-Average Ratio oraz 13 współczynników cepstralnych w skali melowej. W celu ujednolicenia wpływu poszczególnych parametrów zastosowano normalizację metodą min-max, a relacje między próbkami poddano analizie z wykorzystaniem odległości euklidesowej oraz metody głównych składowych.

Zidentyfikowano kluczowe parametry różniące barwę dźwięku oraz wykazano brak silnej korelacji między centroidem widmowym a częstotliwością podstawową ($r = 0,26$), co potwierdza unikalność informacji niesionej przez poszczególne deskryptory. Porównanie z wynikami badań klinicznych wykazało wstępną zgodność opracowanej metryki z empiryczną trudnością percepcyjną: para bodźców o najniższym dystansie euklidesowym ($d = 0,736$) była identyfikowana poprawnie jedynie w 20,5% przypadków, podczas gdy pary bardziej odległe osiągały od 44,4% do 92,9% poprawnych odpowiedzi, przy czym zależność ta nie miała charakteru monotonicznego. Opracowana metodologia stanowi fundament do tworzenia powtarzalnych zestawów bodźców o kontrolowanym stopniu trudności w testach percepcji słuchowej.

Keywords: sound perception; sound analysis, vector analysis, acoustic tests, birds sounds, animal sounds, sound properties;

1 Wstęp

Konieczność prowadzenia analiz porównawczych sygnałów akustycznych, w tym złożonych próbek dźwiękowych, wynika z różnorodnych potrzeb natury poznawczej, diagnostycznej i aplikacyjnej. Jednym z istotnych obszarów zastosowań są badania audiologiczne, w których porównywanie bodźców dźwiękowych o kontrolowanych parametrach fizycznych umożliwia obiektywną ocenę funkcjonowania narządu słuchu oraz kondycji zdrowotnej pacjenta. Podobne w swojej naturze bodźce dźwiękowe, niosące różne informacje, wybrzmiewające osobno pozostają „czytelne” w odbiorze, podczas gdy oddziałujące równocześnie (wybrzmiewające jednocześnie), mogą być niezrozumiałe, ze względu na subtelne podobieństwa lub niewielkie różnice w fizycznej naturze tych bodźców.

Porównawcza analiza sygnałów akustycznych pozwala również na pogłębianie wiedzy dotyczącej mechanizmów percepcji słuchowej, w tym relacji pomiędzy fizycznymi właściwościami bodźca a jego subiektywnym odbiorem. W tym kontekście szczególnego znaczenia nabierają metody umożliwiające ilościowy

opis podobieństwa dźwięków, które stanowią podstawę do badań nad rozróżnialnością bodźców, adaptacją sensoryczną oraz przetwarzaniem informacji akustycznej w ośrodkowym układzie nerwowym. Rozwój narzędzi analitycznych pozwalających na obiektywną i powtarzalną ocenę podobieństwa sygnałów akustycznych stanowi zatem istotny element interdyscyplinarnych badań łączących akustykę, audiologię, neurofizjologię oraz nauki kognitywne.

Jednym z kluczowych wyzwań w badaniach opartych na analizie bodźców akustycznych jest duża liczba zmiennych wpływających na uzyskiwane wyniki, obejmujących zarówno parametry fizyczne sygnału, jak i czynniki związane z warunkami jego rejestracji oraz indywidualnymi cechami percepcyjnymi odbiorcy [10]. Zmienność tych parametrów może stanowić istotne ograniczenie metodologiczne, prowadząc do trudności w jednoznacznej interpretacji wyników oraz obniżenia ich powtarzalności i wiarygodności. W kontekście testów audiologicznych oraz badań nad percepcją słuchową szczególnie problematyczne jest rozdzielenie wpływu właściwości samego bodźca od efektów wynikających z jego prezentacji lub subiektywnej interpretacji.

Zastosowanie ustrukturyzowanych metod analizy porównawczej, opartych na mierzalnych i jednoznacznie definiowalnych parametrach akustycznych, umożliwia systematyczne uwzględnienie tej zmienności i ograniczenie jej wpływu na końcowe wnioski badawcze. Reprezentacja próbek dźwiękowych w postaci wielowymiarowych wektorów cech pozwala na równoczesną analizę wielu aspektów sygnału, takich jak struktura widmowa, dynamika amplitudowa czy cechy cepstralne, bez konieczności każdorazowego odwoływania się do złożonej i czasochłonnej oceny fizycznej poszczególnych parametrów. Takie podejście sprzyja standaryzacji procedur analitycznych, zwiększa obiektywność porównań oraz umożliwia szybką i powtarzalną ocenę podobieństwa sygnałów akustycznych. W rezultacie analiza wektorowa stanowi efektywne narzędzie wspomagające interpretację wyników badań, pozwalając na bardziej przejrzyste odniesienie obserwowanych różnic i podobieństw do mierzalnych właściwości bodźców dźwiękowych.

Istnieje szereg metod analizy próbek dźwiękowych, pozwalających na szczegółową charakterystykę fizyczną, opartych na komplementarnym zastosowaniu analiz w domenie czasu, częstotliwości oraz czasowo-częstotliwościowej [10, 14]. I tak, analiza czasowa może obejmować ocenę przebiegu sygnału w funkcji czasu poprzez wyznaczenie parametrów amplitudowych (wartość skuteczna RMS, dynamika), *Zero-Crossing Rate* (ZCR) do wstępnej klasyfikacji okresowości/szumów [4], oraz charakterystykę obwiedni (ADSR: attack, decay, sustain, release) określającą czasowe właściwości ataku i wybrzmienia [14]. Z kolei analiza częstotliwościowa wykorzystuje transformatę Fouriera do określenia widma amplitudowego i fazowego, identyfikacji składowych harmonicznych, *Spectral Centroid* (jasność barwy), *Spectral Flatness* (tonalność) oraz *Spectral Roll-off* (koncentracja energii widma) [14, 16]. Natomiast dla sygnałów niestacjonarnych stosuje się Krótkoczasową Transformatę Fouriera (STFT) i spektrogramy do śledzenia zmian widma w czasie, uzupełnione deskryptorami psychoakustycznymi jak MFCC i PLP, modelującymi nieliniowość ludzkiego słuchu poprzez banki filtrów melowych i krytycznych [8, 19]. Tak kompleksowe podejście analityczne umożliwia obiektywną ocenę fizycznych i percepcyjnych właściwości określonych próbek dźwiękowych, co może stanowić podstawę dalszych analiz podobieństwa ocenianych próbek [14].

Porównanie próbek dźwiękowych w oparciu o ich fizyczne składowe, tj. właściwości fizyczne bodźca dźwiękowego, oraz próby wskazania czy określone składowe różnych bodźców dźwiękowych odpowiadają za trudności w rozumieniu przekazywanej przez każdą z tych próbek informacji, ze względu na złożoność procesów analitycznych jest dużym wyzwaniem. Stąd istnieje potrzeba opracowania prostszych, parametrycznych, bardziej czytelnych algorytmów analizy poziomu podobieństw lub/i różnic między bodźcami dźwiękowymi poddanymi ocenie.

Niniejsza praca podejmuje temat selekcji cech fizycznych bodźców akustycznych, dalej przyporządkowania i obliczenia porównywalnych wielkości wektorowej dla poszczególnych cech fizycznych próbek dźwiękowych, w celu weryfikacji hipotezy badawczej zakładającej, że odległość euklidesowa między znormalizowanymi wektorami określonych cech akustycznych próbek dźwiękowych, stanowi obiektywną miarę podobieństwa (lub różnicy) porównywanych bodźców dźwiękowych [11], która koreluje z wynikami ich rozróżnienia w testach klinicznych. W szczególności, autorzy podjęli próbę weryfikacji założenia: że przyczyną błędnej identyfikacji podobieństwa pary bodźców dźwiękowych odtwarzanych podczas badania klinicznego może być „mały” dystans w przestrzeni euklidesowej wcześniej wybranych i zdefiniowanych cech [wybranych i zdefiniowanych dla potrzeb tej analizy] w przeciwieństwie do prawidłowej identyfikacji podobieństwa bodźców dźwiękowych dla pary o „dużym” dystansie w przestrzeni euklidesowej. Punktem odniesienia dla tej weryfikacji są wyniki badania MLT (*Memory Load Test*) przeprowadzonego przez Madhavan i wsp. [11], w którym zadaniem uczestników było rozpoznanie liczby jednocześnie prezentowanych dźwięków zwierząt.

2 Materiały i metodyka

Głównym założeniem analizy było wypracowanie konkretnej miary dla złożonych bodźców dźwiękowych, która pozwoli matematycznie ocenić, jak bardzo poszczególne sygnały - bodźce dźwiękowe są do siebie podobne. Innymi słowy, celem pracy było Część A. opracowanie metryki podobieństwa akustycznego, bazującego na odległościach między znormalizowanymi wektorami cech akustycznych próbek dźwiękowych, a następnie Część B. zweryfikowanie metryk dźwiękowych z wynikami doświadczeń klinicznych percepcji złożonych bodźców dźwiękowych.

Materiał badawczy stanowiły próbki dźwiękowe reprezentujące odgłosy popularnych zwierząt, przygotowane w formie plików MP3 (MPEG-1 Audio Layer III). Wszystkie 24 pliki mają częstotliwość próbkowania 44,1 kHz. Trzy z nich (*cat.mp3*, *gorilla.mp3*, *hawk.mp3*) przepróbkowano do 44,1 kHz z oryginałów o częstotliwości 11,025 kHz (*cat.mp3*, *gorilla.mp3*) i 22,05 kHz (*hawk.mp3*), w związku z czym ich efektywne pasmo jest ograniczone do ok. 5 kHz i ok. 11 kHz. Trzy nagrania ze zbioru MLT (*elephant.mp3*, *frog.mp3*, *horse.mp3*) były pierwotnie zapisane w formacie AAC i zostały przekonwertowane do formatu MP3. 21 nagrań zapisano w trybie stereofonicznym, a 3 (*cat.mp3*, *gorilla.mp3*, *hawk.mp3*) – w trybie monofonicznym. Cechy wyznaczano przy natywnej częstotliwości próbkowania każdego pliku, po zmiksowaniu kanałów do sygnału monofonicznego. Analizowany zbiór cechował się zróżnicowaną długością trwania – od 3,2 s (*hawk.mp3*) do 162,3 s (*duck.mp3*), przy średniej 32,9 s i medianie 9,1 s; łączny rozmiar zbioru wyniósł około 13,7 MB.

Łącznie przygotowano 24 pliki dźwiękowe reprezentujące różne gatunki zwierząt. Pierwszą część stanowiło 10 nagrań wykorzystanych jako materiał bodźcowy w badaniu MLT przeprowadzonym przez zespół Madhavan i wsp. [11]: *chicken.mp3*, *cow.mp3*, *dog.mp3*, *donkey.mp3*, *elephant.mp3*, *frog.mp3*, *horse.mp3*, *lion.mp3*, *monkey.mp3*, *sheep.mp3*. Nagrania te, jako pierwotny zbiór bodźców tego badania, określane są w dalszej części pracy jako *zbiór MLT*. Uzupełniono je o 14 nagrań odgłosów zwierząt wybranych losowo z biblioteki BBC Sound Effects [1]: *blackbird.mp3*, *chaffinch.mp3*, *great_tit.mp3*, *tundra_swan.mp3*, *wolf1.mp3*, *cat.mp3*, *duck.mp3*, *frog2.mp3*, *gorilla.mp3*, *hawk.mp3*, *owl.mp3*, *tawny_owl.mp3*, *wild_boar.mp3*, *wolf2.mp3*. Łącznie 24 nagrania tworzą *zbiór rozszerzony*.

Zestaw cech dobrano zgodnie z zasadą możliwie oszczędnego, lecz komplementarnego opisu sygnału, tak aby pokryć trzy względnie niezależne domeny percepcyjno-akustyczne przy zachowaniu interpretowalności każdego wymiaru: barwę opisano centroidem widmowym (najlepiej ugruntowanym korelatem percepcyjnej „jasności” brzmienia [5, 9, 16]) oraz zestawem 13 współczynników MFCC stanowiących standardowy, zwarty opis kształtu obwiedni widmowej [2, 15, 18], przyjętych w liczbie zgodnej z powszechną konwencją i domyślną konfiguracją biblioteki *librosa* [12]; wysokość dźwięku reprezentowano częstotliwością podstawową (F_0), której niezależność od barwy potwierdza słaba korelacja z centroidem ($r = 0,26$); dynamikę czasową ujęto parametrem PAR, pozwalającym odróżnić sygnały o zbliżonej wysokości i barwie, lecz odmiennym charakterze impulsowym. Za takim doбором przemawiały ponadto względy praktyczne: jednoznaczna interpretacja każdej cechy (istotna przy zastosowaniu metryki do audytu materiału bodźcowego), niewielki wymiar wektora adekwatny do liczebności zbioru (24 nagrania), dostępność wszystkich deskryptorów w standardowych, otwartych narzędziach ekstrakcji oraz zgodność z reprezentacją stosowaną w pracy Madhavan i wsp. [11], którą niniejsze badanie rozszerza. Przyjęto zatem celowo prostą i interpretowalną reprezentację bazową, stanowiącą punkt odniesienia dla bardziej rozbudowanych zestawów cech.

Każdy dźwięk opisano za pomocą zestawu 16 cech akustycznych obejmujących: A. centroid widmowy opisujący „jasność” dźwięku, B. częstotliwość podstawową (F_0), C. Peak to Average Ratio (PAR); D. Mel Frequency Cepstral Coefficients ($MFCC$) -13 cech opisujących dynamikę oraz barwę, wyekstrahowanych przy użyciu biblioteki *librosa* [12] (Tab. 1).

Parametr	Opis techniczny	Interpretacja akustyczna
Centroid widmowy	Parametr opisujący środek ciężkości widma sygnału dźwiękowego, określający częstotliwość, wokół której skupiona jest energia sygnału.	Wyższe wartości oznaczają dominację wysokich częstotliwości (dźwięk jasny, ostry, klarowny). Niższe wartości wskazują na przewagę niskich częstotliwości (dźwięk stłumiony, ciemny).
Częstotliwość podstawowa (F0; Hz)	Najniższa składowa częstotliwościowa złożonej próbki dźwiękowej, odpowiadająca wysokości dźwięku.	Niższe F0 oznacza dźwięk bardziej basowy, wyższe F0 – wyższy, bardziej „piszczący”.
Peak-to-Average Ratio (PAR; dB)	Stosunek wartości szczytowej sygnału do jego wartości średniokwadratowej (RMS), wyrażony w decybelach.	Niskie wartości wskazują na stabilną dynamikę (np. mruczenie, przedłużone dźwięki tonalne). Wysokie wartości świadczą o obecności krótkotrwałych impulsów i transjentów. Umożliwia rozróżnianie sygnałów o podobnym F0, lecz odmienną dynamikę.
MFCC 1 (Energia)	Pierwszy współczynnik cepstralny opisujący całkowitą energię sygnału.	Wysokie wartości odpowiadają głošnym dźwiękom, niskie – cichym sygnałom, szeptowi lub ciszy.
MFCC 2 (Jasność/Ciemność)	Współczynnik opisujący rozkład energii między niskimi i wysokimi częstotliwościami.	Określa, czy dźwięk jest bardziej jasny (wysokotonowy) czy ciemny (niskotonowy).
MFCC 3–4 (Kształt widma)	Współczynniki opisujące strukturę środkowej części widma oraz obecność charakterystycznych rezonansów.	Pozwalają odróżniać dźwięki o tej samej wysokości, ale różnej barwie, np. samogłoski o podobnym F0.
MFCC 5–8 (Struktura formantowa i rezonanse)	Parametry związane z formantami i charakterystycznymi rezonansami źródła dźwięku.	Odpowiadają za indywidualny charakter brzmienia, umożliwiają identyfikację instrumentu lub cech aparatu głosowego. Są kluczowe w systemach rozpoznawania mowy.
MFCC 9–13 (Mikrostruktura sygnału)	Współczynniki opisujące wysokoczęstotliwościowe szczegóły i drobne fluktuacje widma.	Określają stopień gładkości, szorstkości lub chropowatości dźwięku. Pomagają odróżniać bardzo podobne próbki dźwiękowe i zwiększają realizm cyfrowego odwzorowania.

Tabela 1: Zestaw cech akustycznych wybranych do charakterystyki złożonego bodźca dźwiękowego.

Ze względu na znaczące różnice w jednostkach i skalach mierzonych parametrów (np. częstotliwość w Hz osiągająca wartości rzędu kilku tysięcy, wobec współczynników MFCC o znacznie mniejszej amplitudzie), w celu eliminacji dominacji parametrów o wysokich wartościach bezwzględnych (np. jak Centroid) nad pozostałymi cechami podczas obliczeń statystycznych, wszystkie wyekstrahowane cechy zostały poddane transformacji do wspólnego przedziału przy użyciu klasy *MinMaxScaler* z biblioteki *scikit-learn* w wersji 1.7.2 [13]. Obliczony dla każdej próbki dźwiękowej wektor cech akustycznych powstał w wyniku połączenia składowych, uśrednionych wartości dla każdej z obliczanej cechy, w sumie 16 cech.

W celu redukcji wymiarowości wielowymiarowego zbioru cech akustycznych oraz umożliwienia ich czytelnej wizualizacji zastosowano analizę głównych składowych (*Principal Component Analysis, PCA*) [17, 20]. Punkt wyjścia stanowiła macierz danych, w której każda próbka dźwiękowa była opisana wektorem cech obejmującym parametry widmowe i cepstralne, w tym współczynniki MFCC oraz wybrane miary energetyczne. Przed właściwą analizą dane poddano centrowaniu oraz standaryzacji w celu wyeliminowania wpływu różnic skali pomiędzy poszczególnymi cechami. Następnie obliczono macierz kowariancji, która posłużyła do wyznaczenia wartości i wektorów własnych definiujących nowe, ortogonalne osie zmienności danych. Wektory własne uporządkowano malejąco według odpowiadających im wartości własnych, a do dalszej analizy wybrano dwie pierwsze główne składowe (PC1 i PC2), wyjaśniające największą część całkowitej wariancji zbioru. Ostatecznie próbki dźwiękowe zostały rzutowane na płaszczyznę wyznaczoną przez PC1 i PC2, co umożliwiło ich rozmieszczenie na dwuwymiarowym wykresie oraz dalszą analizę podobieństw i dystansów pomiędzy sygnałami w zredukowanej przestrzeni cech.

Finalnie, nałożenie na siebie obu tych wymiarów pozwala sprowadzić skomplikowany, 16-wymiarowy model audio do czytelnego punktu na płaszczyźnie, dając wgląd w obiektywne podobieństwa kliniczne badanych próbek.

Wektory cech plików audio porównano za pomocą miary odległości euklidesowej (najkrótszy, mierzony w linii prostej dystans między dwoma punktami w przestrzeni cech) która w analizie dźwięku pozwala matematycznie określić stopień podobieństwa między sygnałami.

3 Wyniki

3.1 Część A: Analiza statystyczna wektorów cech akustycznych

Na podstawie przeprowadzonej analizy, opisanej w Sekcji 2, uzyskano wyniki, które wskazały występowanie istotnych różnic w analizowanych parametrach. Wyniki przed normalizacją i po normalizacji metodą min-max dla wszystkich 24 próbek włączonych do analizy:


parameter	min	max	avg	median	std dev	avg (norm)	median (norm)	std dev (norm)
Centroid	1282.841	5257.504	3007.300	2971.778	1152.948	0.434	0.425	0.290
F0	437.437	2419.417	1077.390	973.540	530.156	0.323	0.270	0.267
PAR	10.051	27.325	18.180	18.047	3.748	0.471	0.463	0.217
MFCC_1	-483.287	-189.880	-316.674	-302.734	85.493	0.568	0.615	0.291
MFCC_2	33.468	251.931	109.258	116.611	48.762	0.347	0.381	0.223
MFCC_3	-128.067	41.666	-38.894	-39.764	38.279	0.525	0.520	0.226
MFCC_4	-40.317	44.812	2.950	3.965	22.025	0.508	0.520	0.259
MFCC_5	-57.688	32.865	-6.901	-6.799	20.654	0.561	0.562	0.228
MFCC_6	-23.855	29.992	0.849	0.843	13.936	0.459	0.459	0.259
MFCC_7	-30.839	8.275	-9.328	-7.750	9.691	0.550	0.590	0.248
MFCC_8	-23.265	20.130	3.572	6.866	12.688	0.618	0.694	0.292
MFCC_9	-22.330	18.031	-2.636	-3.059	11.225	0.488	0.477	0.278
MFCC_10	-11.814	15.074	2.409	2.062	7.517	0.529	0.516	0.280
MFCC_11	-8.958	29.734	3.479	0.792	9.332	0.321	0.252	0.241
MFCC_12	-10.249	17.582	0.639	1.012	6.381	0.391	0.405	0.229
MFCC_13	-14.581	12.754	0.037	0.247	6.284	0.535	0.542	0.230

Tabela 2: Ogólna charakterystyka zbioru dźwięków dla wszystkich 24 próbek włączonych do analizy

Wyniki znormalizowane metodą min-max wskazują, że średnie wartości mieszczą się w przedziale 0,32–0,62, a dla 11 z 16 cech – między 0,4 a 0,6; oznacza to, że dane są zbalansowane; nie ma sytuacji, w której większość próbek ma skrajnie niskie (blisko 0) lub skrajnie wysokie (blisko 1) wartości.

3.1.1 Centroid widmowy (Spectral Centroid)

Zakres analizy parametru *Spectral Centroid* kształtował się od wartości 5257,504 Hz (dla pliku *tawny_owl.mp3*) do 1282,841 Hz (dla pliku *cat.mp3*). Wartości średnie i mediana dla analizowanej grupy wyniosły odpowiednio 3007,300 Hz oraz 2971,778 Hz, przy odchyleniu standardowym na poziomie 1152,948 Hz. Większość próbek koncentruje się w niższych rejestrach jasności, co potwierdza znormalizowana wartość mediany ($med = 0,425$). Próbką *tawny_owl.mp3* ($c = 5257,504$ Hz) podnosi średnią wartość centroidu i wyraźnie oddziela się od reszty zbioru. Kolejna najwyższa wartość w zbiorze (*blackbird.mp3*, $c = 4619,491$ Hz) jest niższa o 638,013 Hz. Jest to największy odstęp między kolejnymi wartościami centroidu w całym zbiorze (pozostałe odstęp między sąsiednimi wartościami nie przekraczają 365 Hz), co wyodrębnia to nagranie jako przypadek o szczególnie wysokiej jasności spektralnej. Rozkład wartości centroidu dla wszystkich analizowanych próbek przedstawiono na Rys. 1.




Rysunek 1: Centroid widomowy dla poszczególnych plików dźwiękowych, słupki zielone z deseniem oznaczają dźwięki ze zbioru MLT [11].

3.1.2 Częstotliwość podstawowa (F0)

Najwyższe wartości: 2419.417 Hz i 2240.552 Hz odnotowano w plikach *hawk.mp3* oraz *blackbird.mp3*, natomiast najniższe wartości 437.437 Hz, 456.731 Hz w plikach *lion.mp3* oraz *tawny_owl.mp3*; średnia i mediana dla całej grupy wynosiła odpowiednio ($mean=1077.390Hz$) oraz ($median=973.540Hz$).


Analizując dane znormalizowane, F0 ma średnią ($mean=0.323$), co oznacza, że większość próbek oscyluje w dolnym zakresie wysokości dźwięku w porównaniu do najwyższej znalezionej tam wartości. Jednocześnie niskie odchylenie standardowe ($std = 0.267$) wskazuje, że próbki są do siebie dość zbliżone pod względem wysokości. Średnia ($mean=0.323$) jest wyższa od mediany ($median=0.270$) co oznacza, że w zbiorze jest kilka wysokich dźwięków, które podnoszą średnią, podczas gdy dla większości próbek obliczona wartość F0 jest niska. Zakres ($0.0 - 1.0$) wskazuje, że w zbiorze jest pełna rozpiętość danych. Wartości częstotliwości podstawowej dla poszczególnych próbek przedstawiono na Rys. 2.



Rysunek 2: Częstotliwość podstawowa dla poszczególnych plików dźwiękowych, słupki zielone z deseniem oznaczają dźwięki ze zbioru MLT [11].

3.1.3 PAR (Peak-to-Average Ratio)

Zakres analizy parametru PAR kształtował się od wartości 27.325 dB (dla pliku o najwyższej dynamice, czyli *duck.mp3*) do wartości 10.051 dB (*dog.mp3*), wartości średnie i mediana dla analizowanej grupy wyniosły odpowiednio: (mean=18.180 dB), (median=18.047dB) oraz odchylenie standardowe ($std = 3.748$). Analizując dane znormalizowane, parametr PAR, którego średnia ($avg = 0.471$) plasuje się niemal w połowie skali, wykazuje największą stabilność spośród badanych cech fizycznych. Świadczy o tym stosunkowo niskie odchylenie standardowe ($std = 0.217$). Wartość mediany (mediana = 0.463) jest bardzo zbliżona do średniej, co sugeruje równomierny rozkład współczynnika szczytu w całym zbiorze 24 próbek, bez ekstremalnych anomalii. Choć wybrane pliki dominują w górnym rejestrze skali, to większość danych skupiona jest wokół punktu środkowego, co oznacza, że nagrania mają zbliżoną strukturę dynamiki i nasycenia sygnału. Rozkład wartości PAR dla analizowanych plików przedstawiono na Rys. 3.




Rysunek 3: PAR dla poszczególnych plików dźwiękowych, słupki zielone z deseniem oznaczają dźwięki ze zbioru MLT [11].

3.1.4 Współczynniki MFCC

Zakres analizy pierwszego współczynnika (MFCC_1), odpowiedzialnego za ogólną energię widmową, kształtował się od -189.880 (*sheep.mp3*) do -483.287 (*frog.mp3*), przy średniej wynoszącej -316.674 . Tak duże odchylenie standardowe (85.493) wskazuje, że próbki różnią się między sobą głównie głośnością i całkowitą mocą sygnału.

W obszarze charakterystyki spektralnej dominują współczynniki MFCC_2 ($avg = 109.258$) oraz MFCC_3 ($avg = -38.894$), które niosą najwięcej informacji o "cieple" lub "ostrości" dźwięku. Przewaga MFCC_2 sugeruje silnie zdefiniowane niższe pasma częstotliwości. Z kolei wartości pozostałych współczynników (MFCC_4 - 13) oscylują bliżej zera (od $avg = -9.328$ do $avg = 3.572$), co wskazuje na wygładzenie wyższych składowych barwy, typowe dla naturalnych odgłosów zwierząt.

Normalizacja umożliwiła bezpośrednie porównanie wszystkich 13 cech, wykazując wysoki poziom zbalansowania zbioru. Ponad połowa współczynników (7 z 13) plasuje się w przedziale średnich 0.45-0.55, a żaden nie przekracza 0.62, co oznacza, że zbiór jest statystycznie jednorodny, pozbawiony dominującego parametru, który mógłby maskować pozostałe cechy. Najwyższą średnią znormalizowaną wykazuje MFCC_8 ($avg = 0.618$), który jednocześnie charakteryzuje się największym odchyleniem standardowym spośród współczynników MFCC ($std = 0.292$), co wskazuje, że to w tym paśmie próbki różnią się najsilniej. Największą stabilność wykazuje natomiast MFCC_2, którego najniższe wśród współczynników MFCC odchylenie standardowe ($std = 0.223$) czyni go wspólnym mianownikiem dla wszystkich 24 nagrań. Parametr MFCC_9 również charakteryzuje się relatywnie wysoką wartością odchylenia standardowego ($std = 0.278$), co wskazuje, że informacja przenoszona przez te wartości ma wpływ na próbki dźwiękowe. Odchylenia standardowe poszczególnych współczynników MFCC przedstawiono na Rys. 4.



Rysunek 4: Odchylenie standardowe dla parametrów MFCC

Analiza porównawcza średniej i mediany wykazała ich wysoką zbieżność we wszystkich 13 współczynnikach, różnice te są minimalne i zazwyczaj nie przekraczają wartości 0.05 (np. dla MFCC_10 $\text{avg} = 0.529$ vs $\text{mediana} = 0.516$). Świadczy to o symetrycznym rozkładzie barwy w całym zbiorze danych. Można na tej podstawie wnioskować, że nagrania zostały wykonane w zbliżonych warunkach akustycznych lub przy użyciu urządzeń o pokrewnej charakterystyce częstotliwościowej, co eliminuje występowanie ekstremalnych anomalii statystycznych w obszarze psychoakustyki.


Analiza korelacji została użyta jako test redundancji cech, jeśli dwie zmienne są silnie skorelowane, to w metryce opartej o odległość euklidesową mogą w praktyce, w próbie dźwiękowej, dublować informację i wzmacniać jeden wymiar różnic, kosztem drugiego. Niska korelacja oznacza, że cechy opisują odmienne aspekty sygnału i ich łączne użycie zwiększa rozróżnialność podobieństwa akustycznego (np. niezależność centroidu od F0 oznacza, że barwa/jasność nie wynika bezpośrednio z wysokości tonu).

3.1.5 Analiza korelacji parametrów audio

Macierz korelacji jest tabelarycznym zestawieniem współczynników korelacji obliczonych dla każdej pary analizowanych parametrów, opisujących siłę i kierunek liniowej zależności między nimi. Współczynnik przyjmuje wartości z przedziału od -1 do $+1$: wartości bliskie $+1$ oznaczają silną zależność dodatnią (wzrost jednej cechy współwystępuje ze wzrostem drugiej), wartości bliskie -1 – silną zależność ujemną (wzrost jednej cechy współwystępuje ze spadkiem drugiej), natomiast wartości zbliżone do zera wskazują na brak liniowego związku, czyli wzajemną niezależność cech. W kontekście niniejszego badania analiza macierzy korelacji pełni funkcję testu redundancji: cechy silnie skorelowane niosą w znacznym stopniu tę samą informację i w metryce opartej na odległości euklidesowej mogą sztucznie wzmacniać jeden wymiar różnic kosztem pozostałych, podczas gdy cechy słabo skorelowane opisują odmienne aspekty sygnału i ich łączne uwzględnienie zwiększa zdolność różnicowania podobieństwa akustycznego. Identyfikacja tych zależności pozwala zatem ocenić, czy przyjęty zestaw deskryptorów jest wzajemnie komplementarny.

Do analizy korelacji wybrano trzy nie-MFCC deskryptory: Centroid, F0 oraz PAR, uzupełnione o trzy reprezentatywne współczynniki MFCC. Włączenie Centroidu, F0 i PAR było kluczowe, ponieważ parametry te reprezentują trzy odrębne domeny wektora cech (odpowiednio: jasność widmową, wysokość dźwięku oraz dynamikę czasową); zestawienie ich w jednej macierzy pozwala zweryfikować, czy rzeczywiście niosą wzajemnie niezależną informację, co stanowi bezpośredni test redundancji cech w metryce opartej na odległości euklidesowej. Spośród współczynników MFCC wybrano MFCC_1 (energia sygnału) oraz MFCC_2 (globalna składowa barwy i nachylenie widma), osiągające najwyższe wartości bezwzględne w przestrzeni MFCC (odpowiednio $-316,674$ i $109,258$), a także MFCC_9 jako przykład współczyn-

nika wyższego rzędu o wysokiej zmienności w badanym zbiorze (odchylenie standardowe po normalizacji $\text{std} = 0,278$). Prezentację ograniczono do tego podzbioru w celu zachowania czytelności macierzy oraz uwypuklenia zależności między głównymi, interpretowalnymi parametrami akustycznymi. Ograniczenie to dotyczy jednak wyłącznie warstwy ilustracyjnej: w analizie PCA składowe główne (PC1 i PC2) wyznaczane są na podstawie pełnego wektora cech (Centroid, F0, PAR oraz MFCC_1–MFCC_13), dzięki czemu porównywanie próbek dźwiękowych uwzględnia łączną informację niesioną przez wszystkie deskrytory, a nie jedynie wybrane współczynniki. Otrzymaną macierz korelacji przedstawiono na Rys. 5.



Rysunek 5: Macierz korelacji

i. **Spectral Centroid, a parametr F0**

w badanym zbiorze danych zależność między parametrem *Spectral Centroid* a częstotliwością podstawową F0 jest słaba (współczynnik korelacji wynosi 0,26). Wynik ten wskazuje, że jasność dźwięku (percepcyjna barwa) nie jest bezpośrednio determinowana przez fizyczną wysokość tonu podstawowego. Analiza próbek wykazała obecność sygnałów o unikalnej charakterystyce, takich jak *tawny_owl.mp3* oraz *duck.mp3*, które mimo niskiej wysokości dźwięku (niskie wartości F0) charakteryzują się bardzo wysokim centroidem. Potwierdza to, że w przypadku tych dźwięków energia spektralna jest przesunięta ku wyższym częstotliwościom ze względu na ich specyficzną, bogatą w harmoniczne lub szumy strukturę, co czyni te parametry niezależnymi i wartościowymi diagnostycznie źródłami informacji. Z punktu widzenia percepcji dźwięku, można mieć dźwięki niskie (niskie F0), które są jednocześnie "jasne" (wysoki centroid) przez dużą ilość składowych wysokoczęstotliwościowych. Stąd, tworząc metrykę podobieństwa, oba parametry są potrzebne.

ii. **Relacja Centroid, a MFCC_1 i MFCC_2**

Najsilniejsze zależności zaobserwowano między jasnością dźwięku (centroid) a składowymi barwy. Odnotowano istotną ujemną korelację z MFCC_1 (-0.46) oraz MFCC_2 (-0.80). Sugeruje to, że wraz ze wzrostem jasności widmowej (centroidu), wartości MFCC_1 i MFCC_2 maleją. w praktyce oznacza to, że jaśniejsze dźwięki w zbiorze mają specyficzny, powtarzalny profil energetyczny i barwowy.

iii. **Unikalność parametru MFCC_9**


Zaobserwowano silną ujemną korelację między MFCC_9 a energią całkowitą sygnału (MFCC_1),

wynoszącą $-0,65$. Oznacza to, że parametr ten ściśle reaguje na zmiany głośności i natężenia dźwięku. Jednocześnie MFCC_9 wykazuje niemal całkowitą niezależność od dynamiki wewnętrznej sygnału (parametr PAR, korelacja $0,11$). Brak związku z impulsowym charakterem dźwięku sugeruje, że współczynnik ten opisuje cechy barwowo-teksturalne, a nie chwilowe skoki amplitudy. Występuje umiarkowana korelacja MFCC_9 z częstotliwością podstawową (F_0) na poziomie $0,33$. Wynik ten potwierdza, że informacja niesiona przez parametr MFCC_9 jest w dużym stopniu niezależna od tego, czy dźwięk jest wysoki, czy niski. Dzięki temu MFCC_9 staje się narzędziem pozwalającym na obiektywną ocenę charakteru źródła dźwięku, bez wpływu jego wysokości.

iv. Stabilność dynamiki (PAR)

Parametr PAR wykazuje najniższe korelacje z większością pozostałych cech, szczególnie z MFCC_9 ($0,11$) oraz MFCC_1 i MFCC_2 (po $-0,14$). Potwierdza to, że dynamika wewnętrzna próbek (stosunek szczytu do średniej) jest cechą niemal całkowicie niezależną od barwy dźwięku. Pozwala to na skuteczne rozróżnienie próbek pod względem ich "charakteru uderzeniowego" lub nasycenia, niezależnie od tego, czy dźwięk jest wysoki, czy niski. w praktyce uzasadnia to wykorzystanie PAR w wektorze cech jako osobnego wymiaru: pozwala rozróżniać próbki o podobnej wysokości i barwie, ale odmiennej "impulsowości" lub rozkładzie energii w czasie.

Rzutowanie próbek na płaszczyznę wyznaczoną przez dwie pierwsze główne składowe (PC1 i PC2) przedstawiono na Rys. 6.



Rysunek 6: Cechy PC1 oraz PC2, elementy zielone z czarną ramką oznaczają dźwięki ze zbioru MLT [11].

3.2 Część B: Weryfikacja metryki z wynikami oceny klinicznej

W celu empirycznej walidacji opracowanej metryki podobieństwa obliczone odległości euklidesowe zestawiono z wynikami badania percepcji słuchowej.

Dla czterech par dźwiękowych wyznaczono odległości euklidesowe w 16-wymiarowej znormalizowanej przestrzeni cech i zestawiono je z odsetkiem poprawnych identyfikacji liczby dźwięków w badaniu Madhavan et al. [11] (Tab. 3).

Para bodźców	Odległość euklidesowa	Rozróżnialność % prawidłowych odpowiedzi
cow.mp3 - horse.mp3	0,736	20,5%
cow.mp3 - lion.mp3	0,929	92,9%
donkey.mp3 - horse.mp3	1,102	55,6%
sheep.mp3 - frog.mp3	1,710	44,4%

Tabela 3: Zestawienie odległości euklidesowych między parami bodźców dźwiękowych z odsetkiem poprawnych odpowiedzi w próbach dwuelementowych badania MLT [11].

Para *cow.mp3-horse.mp3*, charakteryzująca się najniższą odległością euklidesową ($d = 0,736$), okazała się najtrudniejsza do rozróżnienia dla słuchaczy (20,5% poprawnych odpowiedzi). Wszystkie trzy pary o większych odległościach ($d = 0,929-1,710$) były identyfikowane poprawnie wyraźnie częściej (44,4–92,9%), co jest zgodne z przewidywaniem modelu, że mniejszemu dystansowi w przestrzeni cech towarzyszy niższa dokładność identyfikacji liczby jednocześnie prezentowanych dźwięków.

Wśród tych trzech par poprawność nie rosła jednak wraz z odległością: para *cow.mp3-lion.mp3* ($d = 0,929$) była identyfikowana poprawnie w 92,9% przypadków, para *donkey.mp3-horse.mp3* ($d = 1,102$) – w 55,6%, a para *sheep.mp3-frog.mp3*, mimo największego dystansu akustycznego ($d = 1,710$) – jedynie w 44,4%. W analizowanym zestawie zależność między odległością euklidesową a poprawnością odpowiedzi nie jest zatem monotoniczna.

4 Dyskusja

Pytanie, jak porównać dwa dźwięki, jest pozornie proste. W praktyce podobieństwo akustyczne i podobieństwo percepcyjne są konstruktami wielowymiarowymi i nie mogą być wiarygodnie opisane przez pojedynczy parametr sygnału. Już klasyczne badania nad barwą dźwięku wykazały, że ocena podobieństwa opiera się równocześnie na kilku częściowo niezależnych cechach spektralnych i czasowych. Grey wykorzystywał wielowymiarowe skalowanie ocen podobieństwa brzmień instrumentów, natomiast Lakatos wykazał, że do głównych wymiarów percepcyjnych należą m.in. centroid widmowy i czas narastania sygnału [5, 9]. Późniejsze badania potwierdziły, że percepcyjna przestrzeń barwy może być opisana kombinacją kilku cech akustycznych, a nie pojedynczą zmienną [3].

W odniesieniu do dźwięków środowiskowych szczególnie istotny jest wynik pracy Gygi i wsp., w której analizowano 50 naturalnych dźwięków. Autorzy wykazali, że oceny podobieństwa tworzą wielowymiarową strukturę, a położenie bodźców w tej przestrzeni można częściowo przewidywać na podstawie kombinacji takich cech, jak harmoniczność, udział ciszy czy głębokość modulacji [6]. Wynik ten ma bezpośrednie znaczenie dla niniejszej pracy, ponieważ analizowany materiał dźwiękowy również obejmuje złożone, semantycznie rozpoznawalne odgłosy, a nie laboratoryjne tony czyste. Oznacza to, że podobieństwo pomiędzy takimi bodźcami powinno być traktowane jako wynik współdziałania wielu właściwości sygnału, a nie jako funkcja samej wysokości tonu czy pojedynczej miary widmowej.

Współczesne metody analizy dźwięku umożliwiają odwrócenie klasycznego paradygmatu badań psychofizycznych: zamiast najpierw pytać słuchacza, które dźwięki są podobne, można najpierw zbudować numeryczną reprezentację każdego bodźca, a następnie obliczyć odległość pomiędzy reprezentacjami. Rozwój zestawów deskryptorów, takich jak *Timbre Toolbox* (zestaw narzędzi do automatycznego opisu barwy i innych właściwości dźwięku za pomocą wielu parametrów akustycznych), pozwolił ujmować strukturę sygnału za pomocą wielu parametrów spektralnych, energetycznych i czasowych [15]. Współczynniki MFCC stały się natomiast standardowym sposobem zwartego opisu kształtu obwiedni widmowej, szeroko stosowanym w analizie mowy, muzyki, identyfikacji źródeł oraz klasyfikacji dźwięków. Należy podkreślić, że ani zastosowanie MFCC, ani wykorzystanie odległości euklidesowej nie stanowią same w sobie nowości metodologicznej. Już Helén i Virtanen wykorzystywali miary odległości pomiędzy reprezentacjami cech w systemie *audio query-by-example*, porównując m.in. odległość euklidesową z miarami opartymi na rozkładach prawdopodobieństwa [7]. De Camargo i wsp. zastosowali MFCC oraz miary odległości w automatycznej identyfikacji odgłosów zwierząt [2], z kolei Siedenburg i Müllensiefen modelowali jawne oceny podobieństwa krótkich fragmentów muzycznych za pomocą zestawów deskryptorów barwy i MFCC, wykorzystując odległości pomiędzy cechami jako predyktory ocen słuchaczy [18]. Badania te potwierdzają,

że wektorowa reprezentacja sygnału jest uzasadnionym sposobem ilościowego ujmowania podobieństwa, ale jednocześnie wyznaczają granicę, poza którą należy poszukiwać właściwej innowacyjności obecnego podejścia.

Odrębność niniejszej pracy nie polega zatem na zaproponowaniu nowej klasy deskryptorów ani nowej matematycznej definicji dystansu. Polega na przypisaniu tej odległości innej roli eksperymentalnej. W typowych systemach rozpoznawania lub wyszukiwania dźwięków dystans pomiędzy wektorami służy jako kryterium klasyfikacji: odpowiedź ma wskazać, jaki to dźwięk albo który element bazy jest najbardziej podobny do dźwięku, o który pytamy. W badaniach psychofizycznych odległość w przestrzeni cech bywa z kolei odnoszona do jawnej oceny podobieństwa, wydawanej przez słuchacza. W obecnym badaniu odległość akustyczna jest natomiast traktowana jako niezależna cecha konstrukcji bodźców i potencjalny czynnik wpływający na wykonanie zadania percepcyjno-poznawczego. Jest to istotne, ponieważ uczestnicy pierwotnego badania, opisanego przez Madhavan i wsp. [11], nie odpowiadali na pytanie, czy dwa dźwięki są do siebie podobne. Ich zadaniem było rozpoznanie liczby jednocześnie prezentowanych obiektów słuchowych. Podobieństwo akustyczne nie było więc bezpośrednim przedmiotem odpowiedzi, lecz mogło działać jako ukryty czynnik utrudniający segregację sceny słuchowej. W tym ujęciu pytanie „jak porównać dwa dźwięki?” ma znaczenie metodologiczne: chodzi nie tylko o opis ich podobieństwa, ale o ocenę, czy para bodźców jest na tyle bliska akustycznie, że może zmieniać trudność testu niezależnie od procesów poznawczych, które test ma mierzyć.

Takie zastosowanie metryki ma praktyczne znaczenie dla projektowania materiału w badaniach audiologicznych i kognitywnych. Dwa bodźce mogą należeć do odmiennych kategorii semantycznych, a mimo to pozostawać bliskie w wielowymiarowej przestrzeni cech. Jeżeli są prezentowane jednocześnie, ich rozdzielenie może być utrudnione przez podobieństwo struktury widmowej, wysokości, dynamiki lub innych właściwości sygnału. W konsekwencji wynik testu może odzwierciedlać zarówno badaną zdolność poznawczą, jak i właściwości samego materiału dźwiękowego. Obiektywna analiza odległości między bodźcami może więc pełnić funkcję kontroli jakości zestawu testowego i pomagać w identyfikacji par nadmiernie podobnych jeszcze przed rozpoczęciem badania klinicznego.

Uzyskane wyniki dostarczają jedynie częściowego i wstępnego wsparcia dla takiej interpretacji. Spośród czterech par, dla których dostępne były dane z badania Madhavan i wsp. [11], para *cow.mp3-horse.mp3*, charakteryzująca się najmniejszym dystansem ($d = 0,736$), była jednocześnie parą o zdecydowanie najniższym odsetku prawidłowych odpowiedzi (20,5%), a każda z trzech par bardziej oddalonych w przestrzeni cech była rozpoznawana poprawnie znacznie częściej. Jest to zgodne z hipotezą, że akustyczna bliskość bodźców może zwiększać obciążenie procesów segregacji słuchowej. Powyżej tej odległości wartość dystansu nie porządkowała jednak trudności zadania: para *cow.mp3-lion.mp3* ($d = 0,929$) uzyskała 92,9% poprawnych odpowiedzi, *donkey.mp3-horse.mp3* ($d = 1,102$) – 55,6%, a *sheep.mp3-frog.mp3*, mimo największej odległości euklidesowej ($d = 1,710$) – jedynie 44,4%. Taki układ może wskazywać raczej na efekt progowy, w którym bardzo mała odległość akustyczna wyraźnie utrudnia zadanie, niż na liniowy gradient trudności; przy czterech parach nie sposób jednak rozstrzygnąć, która z tych interpretacji jest właściwa, dlatego wnioski muszą pozostać ostrożne. Wyniki te pokazują ponadto, że pojedyncza globalna miara odległości nie może być traktowana jako kompletny predyktor trudności percepcyjnej. Na wykonanie zadania mogą wpływać również właściwości czasowe sygnału, synchronia początku bodźców, modulacja amplitudy i częstotliwości, różnice w czasie trwania, cechy semantyczne i rozpoznawalność źródła, a także mechanizmy uwagi i organizacji sceny słuchowej. Z tego względu obecne dane należy traktować jako pilotażową walidację koncepcji, a nie jako ustalenie uniwersalnego progu podobieństwa.

Warto również skorygować interpretację rozszerzonego zestawu 24 bodźców. Minimalna odległość w zbiorze MLT wynosiła 0,736 dla pary *cow.mp3-horse.mp3*, natomiast w zbiorze rozszerzonym znaleziono jeszcze bliższą parę *owl.mp3-tawny_owl.mp3* ($d = 0,500$). Oznacza to, że rozszerzenie zbioru rzeczywiście wprowadziło parę o większym podobieństwie akustycznym, a nie – jak można byłoby błędnie wnioskować – wyłącznie poszerzyło pokrycie przestrzeni cech bez zwiększenia redundancji. Z punktu widzenia celu pracy, taki wynik pokazuje, że zaproponowana procedura może wykrywać potencjalnie problematyczne pary bodźców, zanim zostaną one zastosowane w badaniu percepcyjnym.

4.1 Znaczenie doboru cech i ograniczenia interpretacyjne

Dobór centroidu widmowego, F0, PAR oraz MFCC tworzy relatywnie prosty i interpretowalny wektor obejmujący różne aspekty sygnału. Zaletą takiego rozwiązania jest możliwość sprowadzenia złożonego opisu akustycznego do jednej miary odległości przy zachowaniu informacji o wielu cechach jednocześnie. Wyniki analizy korelacji wskazują, że część parametrów wnosi względnie odrębną informację – przykładowo zależność pomiędzy F0 i centroidem widmowym była słaba. Jest to argument za łączeniem

deskryptorów, zamiast redukowania podobieństwa do pojedynczego wymiaru. Należy jednak unikać nadmiernie literalnej interpretacji poszczególnych współczynników MFCC. Współczynniki te opisują kolejne składowe obwiedni widmowej w skali melowej, przy czym wraz ze wzrostem numeru współczynnika reprezentowane są coraz drobniejsze szczegóły kształtu widma [18]. Nie istnieje uniwersalne przyporządkowanie typu „MFCC_5 = określony rezonans” czy „MFCC_9 = mikrostruktura” niezależne od materiału i parametrów ekstrakcji. Z tego samego powodu wysoka średnia wartość znormalizowanego MFCC nie jest równoznaczna z wysoką zdolnością dyskryminacyjną tej cechy. Ocena rzeczywistego znaczenia poszczególnych wymiarów wymagałaby np. analizy ważności cech, walidacji krzyżowej modeli z usuwaniem kolejnych parametrów albo zastosowania metod redukcji wymiarowości i regresji na większym zbiorze danych.

Drugim ograniczeniem jest sposób agregowania informacji w czasie. W obecnej procedurze dla całego nagrania uzyskuje się uśrednione wartości cech. Takie podejście jest proste i stabilne, lecz traci informacje o dynamice sygnału: początku dźwięku, obwiedni, modulacji, zmianach widma oraz kolejności zdarzeń. Lakatos wykazał znaczenie czasu narastania dla percepcji barwy [9], a praca Siedenburga i Müllensiefena pokazuje, że cechy spektroczasowe i pochodne MFCC mogą wносить istotną informację przy modelowaniu podobieństwa [18]. W przyszłości zasadne byłoby więc porównanie obecnego modelu z reprezentacją uwzględniającą delta-MFCC, parametry obwiedni czasowej lub metody dopasowania sekwencji, np. *dynamic time warping*.

Odległość euklidesowa ma w tym projekcie ważną zaletę: jest prosta, jednoznaczna i łatwa do interpretacji. Po normalizacji cech każdy parametr uczestniczy w obliczeniu dystansu w porównywalnej skali, co pozwala uzyskać przejrzystą miarę globalną. Jednocześnie wybór ten implikuje założenie o równym znaczeniu wszystkich wymiarów i o geometrycznie izotropowej przestrzeni cech. Założenie to nie musi być zgodne z rzeczywistą wagą percepcyjną poszczególnych parametrów.

Literatura dotycząca wyszukiwania i modelowania podobieństwa audio wskazuje, że skuteczność konkretnej metryki zależy od rodzaju materiału i celu analizy [7, 18]. Kolejnym etapem badań powinno więc być porównanie dystansu euklidesowego z innymi miarami, np. odległością kosinusową, odległością Mahalanobisa lub metrykami uczonymi na danych behawioralnych. Szczególnie interesujące byłoby wyznaczenie wag cech na podstawie większego zbioru odpowiedzi przez ankietowanych w badaniu MLT. Obecny model należy zatem traktować jako celowo prostą i interpretowalną metrykę bazową, stanowiącą punkt odniesienia dla bardziej złożonych rozwiązań.

Najbardziej praktycznym zastosowaniem przedstawionej procedury jest możliwość wstępnej standaryzacji materiału dźwiękowego. W testach, których celem jest ocena procesów poznawczych, pamięciowych lub integracji percepcyjnej, bodźce powinny być dobrane w taki sposób, aby niezamierzona bliskość akustyczna nie stała się dominującym źródłem trudności. Zastosowanie macierzy odległości dla całego zestawu pozwala wskazać pary szczególnie bliskie, kontrolować rozkład trudności oraz budować zestawy alternatywne o podobnym profilu akustycznym. Jest to potencjalnie użyteczne nie tylko dla oceny efektu subitacji, ale także dla innych procedur audiologicznych i eksperymentów nad percepcją słuchową. Jednocześnie obecne badanie ma charakter eksploracyjny. Liczba bodźców jest niewielka, a walidacja behawioralna obejmuje jedynie cztery pary. Na tej podstawie nie można wyznaczyć wiarygodnych progów klasyfikujących dźwięki jako „podobne”, „pośrednie” lub „różne”. W kolejnych badaniach konieczna będzie walidacja większej liczby par, analiza prób obejmujących więcej niż dwa jednoczesne bodźce oraz bezpośrednie porównanie miary akustycznej zarówno z jawnymi ocenami podobieństwa, jak i wynikami zadań z badań ankietowych MLT. Takie rozwiązanie pozwoliłoby rozdzielić trzy poziomy: podobieństwo fizyczne sygnału, świadomie raportowane podobieństwo percepcyjne oraz rzeczywisty wpływ podobieństwa na wykonanie zadania. W tym kontekście proponowana metoda nie powinna być przedstawiana jako uniwersalny sposób rozstrzygania, czy dwa dźwięki są „takie same” lub „różne”. Jej wartość polega raczej na dostarczeniu obiektywnego, powtarzalnego i łatwego do audytu wskaźnika bliskości akustycznej, który można wykorzystać jako dodatkową zmienną przy projektowaniu i interpretacji testów słuchowych. Takie ujęcie łączy analizę sygnału z psychofizyką i zastosowaniem klinicznym: od pytania, jakie cechy zawiera dźwięk, przechodzi do pytania, w jakim stopniu właściwości bodźca mogą współkształtować zachowanie słuchacza.

Podsumowując, wcześniejsze badania jednoznacznie pokazują, że ilościowe porównywanie dźwięków za pomocą wielowymiarowych reprezentacji i miar odległości ma ugruntowane podstawy metodologiczne. Nowość proponowanego podejścia należy więc lokować nie w samych narzędziach analizy sygnału, lecz w ich zastosowaniu do kontroli materiału bodźcowego i interpretacji wykonania zadania percepcyjnego. Fakt, że para o najmniejszej odległości akustycznej była rozpoznawana poprawnie najrzadziej, sugeruje, że wielocechowa metryka może pomagać identyfikować bodźce niosące dodatkowe ryzyko interferencji. Jednocześnie brak monotonicznej zależności w pozostałych parach oraz mała liczba dostępnych porównań

wskazują, że zależność ta wymaga dalszej, prospektywnej walidacji. W takim ujęciu przedstawiona procedura stanowi nie końcowy model percepcji dźwięku, lecz praktyczne i przejrzyste narzędzie do zadania fundamentalnego pytania: jak porównać dwa dźwięki w sposób istotny dla zachowania słuchacza?

Declaration of generative AI and AI-assisted technologies in the writing process

During the preparation of this manuscript, the authors used Claude Opus 5.5 (Anthropic) to translate an original Polish-language draft into English and to improve language readability. Claude Sonnet 5.0 (Anthropic) was used to support the organization and editorial structuring of the manuscript, including the presentation of the authors' own results. The authors reviewed and edited all AI-assisted output and take full responsibility for the content of the published article.

Literatura

- [1] BBC. BBC sound effects. <https://sound-effects.bbcrewind.co.uk/>, 2026. Access: [01.02.2026].
- [2] Ulisses M. de Camargo, Panu Somervuo, and Otso Ovaskainen. PROTAX-Sound: A probabilistic framework for automated animal sound identification. *PLoS ONE*, 12(9):e0184048, 2017. doi: 10.1371/journal.pone.0184048. PMID: 28863178.
- [3] Taffeta M. Elliott, Liberty S. Hamilton, and Frederic E. Theunissen. Acoustic structure of the five perceptual dimensions of timbre in orchestral instrument tones. *Journal of the Acoustical Society of America*, 133(1):389–404, 2013. doi: 10.1121/1.4770244. PMID: 23297911.
- [4] Fabien Gouyon and François Pachet. On the use of zero-crossing rate for an application of classification of percussive sounds. In *Proceedings of DAFx-00*, 2000. URL <https://www.francoispachet.fr/wp-content/uploads/2021/01/gouyon-00-dafx00.pdf>.
- [5] John M. Grey. Multidimensional perceptual scaling of musical timbres. *Journal of the Acoustical Society of America*, 61(5):1270–1277, 1977. doi: 10.1121/1.381428. PMID: 560400.
- [6] Brian Gygi, Gary R. Kidd, and Charles S. Watson. Similarity and categorization of environmental sounds. *Perception & Psychophysics*, 69(6):839–855, 2007. doi: 10.3758/BF03193921. PMID: 18018965.
- [7] Marko Helén and Tuomas Virtanen. Audio query by example using similarity measures between probability density functions of features. *EURASIP Journal on Audio, Speech, and Music Processing*, 2010:179303, 2010. doi: 10.1155/2010/179303.
- [8] Hynek Hermansky. Perceptual linear predictive (plp) analysis of speech. *Journal of the Acoustical Society of America*, 87(4):1738–1752, 1990. doi: 10.1121/1.399423. URL <https://doi.org/10.1121/1.399423>.
- [9] Stephen Lakatos. A common perceptual space for harmonic and percussive timbres. *Perception & Psychophysics*, 62(7):1426–1439, 2000. doi: 10.3758/BF03212144. PMID: 11143454.
- [10] Tomasz Letowski. Sound quality assessment: concepts and criteria, 01 1989.
- [11] Maya Madhavan et al. A concept for cognitive reserve evaluation with auditory perception. *Otolaryngologia Polska*, 2024. doi: 10.5604/01.3001.0054.5661. URL <https://bibliotekanauki.pl/articles/58971739.pdf>. Open access PDF available via Biblioteka Nauki / Otolaryngologia Polska.
- [12] Brian McFee, Colin Raffel, Dawen Liang, Daniel P. W. Ellis, Matt McVicar, Eric Battenberg, and Oriol Nieto. librosa: Audio and music signal analysis in Python. In *Proceedings of the 14th Python in Science Conference*, pages 18–25, 2015. doi: 10.25080/Majora-7b98e3ed-003.
- [13] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Edouard Duchesneau. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011. URL <https://jmlr.org/papers/v12/pedregosa11a.html>.
- [14] Geoffroy Peeters. A large set of audio features for sound description (similarity and classification) in the cuidado project. Technical report, IRCAM, 4 2004. URL http://recherche.ircam.fr/anasy/peeters/ARTICLES/Peeters_2003_cuidadoaudiofeatures.pdf. Project report, version 1.0.
- [15] Geoffroy Peeters, Bruno L. Giordano, Patrick Susini, Nicolas Misdariis, and Stephen McAdams. The timbre toolbox: extracting audio descriptors from musical signals. *Journal of the Acoustical Society of America*, 130(5):2902–2916, 2011. doi: 10.1121/1.3642604. PMID: 22087919.
- [16] Charalampos Saitis and Kai Siedenburg. Brightness perception for musical instrument sounds: Relation to timbre dissimilarity and source-cause categories. *The Journal of the Acoustical Society of America*, 148(4):2256–2266, 10 2020. doi: 10.1121/10.0002275. URL <https://doi.org/10.1121/10.0002275>.

- [17] Amir Salimi, Abram Hindle, and Osmar R. Zaiane. Evaluating sound similarity metrics for differentiable, iterative sound-matching. *arXiv preprint arXiv:2506.22628*, 2025. doi: 10.48550/arXiv.2506.22628. URL <https://arxiv.org/abs/2506.22628>.
- [18] Kai Siedenburg and Daniel Müllensiefen. Modeling timbre similarity of short music clips. *Frontiers in Psychology*, 8:639, 2017. doi: 10.3389/fpsyg.2017.00639. PMID: 28491045.
- [19] Brian Tracey, Dmitri Volfson, James Glass, R’mani Haulcy, Melissa Kostrzebski, Jamie Adams, Tairmae Kangarloo, Amy Brodtmann, E. Ray Dorsey, and Adam Vogel. Towards interpretable speech biomarkers: exploring MFCCs. *Scientific Reports*, 13:22787, 2023. doi: 10.1038/s41598-023-49352-2. URL <https://www.nature.com/articles/s41598-023-49352-2>.
- [20] Linlin Xiong, Zhenyu Liao, Yong Liang, and Xiang Gong. Research on voiceprint recognition based on mfcc-pca-lstm, 2023.

A Wektory cech akustycznych

Wektor cech akustycznych przed normalizacją min-max, wykorzystanych w artykule.

Name	F0	PAR	Centroid										
MFCC													
chicken	930.343	17.700	2926.691										
-327.237	82.999	-38.592	-33.489	-32.739	-16.701	-22.290	-11.800	4.410	12.632	5.750	2.132	0.797	
hawk	2419.417	15.509	2488.237										
-251.789	103.930	-128.067	12.339	-16.788	0.802	-9.057	-23.265	18.031	1.548	13.810	-0.863	8.423	
sheep	1279.340	19.892	3325.403										
-189.880	109.772	-88.828	6.104	-25.419	15.384	-30.839	-3.600	-21.130	9.763	-1.861	0.301	12.754	
wolf1	510.134	15.807	2421.858										
-231.524	144.509	-9.122	21.388	-25.433	-2.456	-14.032	-4.206	-9.847	-1.886	-8.958	2.777	-3.800	
donkey	1254.720	16.949	3438.254										
-210.732	119.803	-76.757	1.164	-57.688	24.694	-14.443	14.486	-12.009	0.844	12.634	-10.031	1.196	
wolf2	551.040	16.948	2131.952										
-334.230	131.805	41.666	-0.186	-5.520	5.895	1.657	5.204	-0.917	2.270	-2.057	7.741	11.357	
tundra_swan	784.416	18.319	2701.883										
-230.075	125.439	-51.170	5.210	-21.519	-6.252	-26.662	-14.046	-10.482	5.757	13.905	9.226	7.296	
chaffinch	1397.990	21.744	4473.348										
-379.172	84.621	-16.691	34.242	-16.974	-18.007	-17.783	18.617	-12.605	-0.168	-3.704	-1.220	-2.195	
duck	809.362	27.325	4146.062										
-214.189	113.623	-54.584	34.472	-32.769	29.992	-17.735	16.085	-13.393	13.294	-6.171	8.963	-3.980	
great_tit	1421.528	18.490	3894.647										
-401.115	71.831	-31.917	44.812	5.723	-18.835	8.275	9.700	-3.537	-6.278	5.170	4.607	-4.099	
gorilla	765.910	17.776	1303.749										
-268.323	251.931	-52.944	-40.317	28.067	-17.206	-14.699	15.738	-10.583	-11.814	9.174	-10.249	-14.581	
dog	501.156	10.051	2209.468										
-210.405	140.009	-0.183	11.668	-14.332	0.444	-15.602	-17.633	-22.330	-8.135	-1.243	-5.612	1.156	
owl	622.496	13.560	4539.256										
-429.998	47.405	10.065	-2.331	-8.078	-7.900	-2.792	10.686	15.895	15.074	8.192	2.367	-1.195	
monkey	1710.385	22.929	3530.151										
-394.827	53.336	-97.621	-15.711	-11.431	7.840	-5.534	18.661	11.501	3.127	-7.646	-2.045	-11.244	
elephant	921.593	13.944	1513.661										
-260.251	162.428	-58.647	-32.457	16.998	-23.855	-13.288	14.543	-10.527	-11.295	6.729	-6.081	-4.957	
wild_boar	1085.865	22.563	3304.438										
-268.061	126.635	-52.249	20.793	3.746	11.124	-4.933	-14.149	7.141	-1.544	-3.149	2.109	-6.019	
frog2	1016.737	23.145	3016.866										
-392.174	131.438	-36.168	2.720	9.223	13.644	0.556	7.303	7.392	10.260	17.142	1.723	1.871	
cat	1131.030	18.468	1282.841										
-308.504	147.258	-40.937	-11.268	32.865	-11.005	-6.443	20.130	-2.581	0.584	29.734	17.582	3.068	
cow	875.505	18.591	1654.120										
-394.512	137.184	-21.177	-26.304	-1.867	9.404	0.484	-2.328	2.940	1.853	-4.083	-4.867	0.937	
horse	1076.735	17.383	1995.819										
-296.963	119.598	-52.974	-3.744	-8.938	7.708	-5.830	-3.010	-13.740	-5.828	-6.452	-3.833	-1.159	
lion	437.437	12.647	1858.200										
-294.076	104.998	-4.434	26.838	-4.114	10.453	-3.604	8.942	-4.704	4.246	0.125	-1.112	-0.304	
tawny_owl	456.731	17.654	5257.504										
-447.315	38.390	15.328	5.323	1.278	-0.280	0.894	6.429	9.165	9.383	6.560	4.190	1.832	
blackbird	2240.552	20.041	4619.491										
-381.544	39.774	-62.417	10.515	18.136	4.618	-10.540	11.598	1.926	7.897	1.459	2.245	4.149	
frog	1656.927	18.897	4141.290										
-483.287	33.468	-25.039	-0.985	1.946	0.883	0.374	1.642	6.730	6.226	-1.564	-4.723	-0.417	