

Ocena organoleptyczna miodu jako kryterium dopuszczenia do obrotu - analiza w warunkach badania ślepego

Bartosz Lewandowski, (ORCID:0009-0004-1158-0693)^{1,*}, Przemysław Rujna (ORCID:0000-0001-9178-1540)², and Katarzyna Banach (ORCID:0000-0003-2580-7954)³

¹Department of Clinical Engineering, Academy of Silesia in Katowice

²Wydział Nauk o Zarządzaniu, Uniwersytet Morski w Gdyni

³Instytut Nauk o Zarządzaniu i Jakości, Uniwersytet Warmińsko-Mazurski w Olsztynie

*Corresponding author: Bartosz Lewandowski, Ph.D., bartosz.lewandowski@akademiaslaska.pl

Streszczenie

Celem badania była weryfikacja, czy konsumencka ocena organoleptyczna miodu, przeprowadzona w warunkach badania ślepego, stanowi obiektywne i powtarzalne kryterium dopuszczenia produktu do obrotu. W ślepym teście panelowym respondenci dokonali oceny sensorycznej siedmiu próbek miodu o znanym statusie dopuszczenia, oceniając ogólną akceptację smaku, słodycz, kwasowość, intensywność aromatu oraz typowość smaku. Zależność między statusem dopuszczenia a akceptacją konsumencką analizowano z wykorzystaniem miar asocjacji, modeli z efektami mieszanymi, testu równoważności, podejścia bayesowskiego, analizy mocy oraz oceny zdolności dyskryminacyjnej.

Wszystkie badane próbki spełniały wymagania ilościowe (analiza pyłkowa, profil cukrów, NMR, przewodność, parametry fizykochemiczne); cztery zostały niedopuszczone do obrotu wyłącznie na podstawie jakościowej oceny smaku lub zapachu, sformułowanej bez deklaracji niepewności pomiaru. Stwierdzona różnica typowości smaku między miodami dopuszczonymi a niedopuszczonymi była niewielka i kilkukrotnie mniejsza niż naturalny rozrzut ocen wewnątrz samej grupy miodów dopuszczonych. Zdolność oceny sensorycznej do odtworzenia werdyktu laboratoryjnego była zbliżona do losowej, a hipotetyczna reguła decyzyjna oparta na typowości smaku prowadziłyby do błędnego wykluczenia znacznej części miodów legalnie dopuszczonych do obrotu i jednoczesnego przepuszczenia większości próbek niedopuszczonych.

Wyniki wskazują, że subiektywna ocena organoleptyczna smaku nie spełnia trzech warunków stawianych kryterium prawno-administracyjnemu: obiektywności (wynik zależy od oceniającego i nie jest mierzalny bez odniesienia do wzorca), powtarzalności (ta sama próbka uzyskuje różne oceny w zależności od liczby i doboru degustatorów) oraz proporcjonalności (narzędzie o zdolności dyskryminacyjnej zbliżonej do losowej nie powinno samodzielnie dyskwalifikować produktu spełniającego wszystkie ilościowo oznaczane normy). Ocena sensoryczna pozostaje wartościowym narzędziem badawczym i marketingowym; wyniki niniejszego badania wskazują jednak, że nie powinna stanowić samodzielnej podstawy decyzji o dopuszczeniu lub wykluczeniu produktu z obrotu.

Słowa kluczowe: miód, ocena organoleptyczna, badanie ślepe, analiza sensoryczna, dopuszczenie do obrotu.

1 Wstęp

Miód jest cenionym produktem żywnościowym o wysokiej wartości odżywczej i zdrowotnej, odgrywającym istotną rolę w tradycji kulinarnej w Polsce. Jako produkt naturalny o znacznej wartości rynkowej podlega on jednocześnie licznym wymaganiom jakościowym oraz regulacjom prawnym, których celem jest ochrona konsumenta przed produktami zafałszowanymi lub niespełniającymi norm. W praktyce kontroli jakości miodu współistnieją dwa rodzaje kryteriów: parametry fizykochemiczne, oznaczane laboratoryjnie i mające charakter obiektywny i powtarzalny, oraz cechy organoleptyczne, oceniane przez człowieka i z natury obciążone większą zmiennością.

Ocena organoleptyczna, obejmująca smak, zapach, barwę oraz konsystencję, pozostaje powszechnie stosowanym narzędziem opisu jakości miodu i badania preferencji konsumentów. Jej zaletą jest bezpośrednie odwzorowanie doświadczenia konsumenta, wadą natomiast subiektywny charakter percepcji i podatność na błędy systematyczne wynikające ze znajomości marki, ceny, odmiany czy pochodzenia próbki. W celu ograniczenia tej stronniczości stosuje się metodę badań ślepych (*blind tests*), w której próbki podawane są w formie zakodowanej i w losowej kolejności, bez ujawniania panelistom informacji mogących wpłynąć na ocenę.

Pomimo szerokiego zastosowania oceny sensorycznej otwarte pozostaje pytanie o jej rolę w procesie dopuszczania produktu do obrotu. Narzędzie wykorzystywane z powodzeniem do celów badawczych i marketingowych nie musi bowiem spełniać wymogów stawianych kryterium o charakterze prawno-administracyjnym, od którego oczekuje się obiektywności, powtarzalności oraz niskiego odsetka błędnych klasyfikacji. Jeżeli ocena typowości smaku miodu nie różnicuje w sposób wiarygodny próbek dopuszczonych i niedopuszczonych do obrotu, oparcie na niej decyzji administracyjnych prowadziłoby do rozstrzygnięć arbitralnych i obciążonych wysokim ryzykiem błędu.

Należy przy tym odróżnić mierzalność danego parametru od jego przydatności jako kryterium dopuszczenia produktu do obrotu: nie każda cecha, którą można ilościowo oznaczyć, niesie informację wystarczającą do podjęcia decyzji administracyjnej spełniającej wymóg proporcjonalności. Problem ten wykazano już w odniesieniu do mikrobiologicznych parametrów miodu, gdzie sama liczba drożdży osmofilnych (CFU/g), przy braku aktywnej fermentacji, nie stanowi wystarczającej podstawy do uznania produktu za niezgodny z wymaganiami [7].

Niniejsza praca podejmuje to zagadnienie empirycznie. W badaniu zastosowano ślepą ocenę panelową siedmiu próbek miodu o znanym statusie dopuszczenia do obrotu oraz zestaw metod analizy statystycznej, od miar asocjacji i modeli z efektami mieszanymi, przez test równoważności i analizę bayesowską, po ocenę zdolności dyskryminacyjnej i analizę mocy, pozwalających ocenić nie tylko istnienie, lecz przede wszystkim wielkość, wiarygodność i praktyczną przydatność zależności między oceną sensoryczną a statusem administracyjnym próbki.

2 Przegląd literatury

W literaturze opisano liczne standardy jakości miodu, w tym wymagania prawne i kryteria handlowe, koncentrujące się zarówno na parametrach fizykochemicznych, jak i cechach organoleptycznych.

W literaturze podejmowano już krytyczną analizę proporcjonalności kryteriów jakościowych miodu, wskazując, że pojedynczy parametr o ograniczonej zdolności różnicowania nie powinien stanowić samodzielnej przesłanki dyskwalifikacji produktu [7].

Sensoryczna ocena miodu obejmująca postrzeganie smaku słodkiego, kwaśnego i (w śladowych, lecz diagnostycznych ilościach) słonego, obok goryczy i cech zapachowych stanowi element kontroli jakości oraz weryfikacji pochodzenia botanicznego produktu. W praktyce laboratoryjnej oceny te wykonują wyszkoleni asesorzy lub eksperci, a wynik traktowany bywa jako miara zobiektywizowana. Niniejszy rozdział poddaje to założenie krytycznej analizie, wychodząc od psychofizjologii percepcji smaku i psychometrii skal ocen. Argumentacja prowadzi do wniosku, że subiektywność oceny sensorycznej jest zjawiskiem realnym, wynikającym zarówno ze zmienności percepcyjnej, jak i z nieporównywalności skal między osobami, i że jej ograniczenie wymaga jawnej kalibracji, której w rutynowej ocenie miodu zwykle nie da się zweryfikować.

Przemek - czy mozesz przygotowac całą sekcje przeglądową? Na 100procent masz to w doktoracie. Pytania: czy warto dodac metodologie badań prowadzonych przez IJHARS, Erufins, etc? Czy dodac ogólnie metodologie badań laboratoryjnych?

3 Międzyosobnicza zmienność percepcji smaków podstawowych

Punktem wyjścia jest fakt, że percepcja smaków słodkiego, kwaśnego i słonego różni się między ludźmi, a część tej zmienności ma podłoże dziedziczne. W badaniu bliźniąt wykazano, że próg rozpoznania kwaśności (kwas cytrynowy) jest dziedziczny w około 53%, podczas gdy dla słoności (chlorek sodu) większą rolę odgrywa środowisko wspólne niż addytywny komponent genetyczny [16]. Dla smaku słodkiego zmienność ma również komponent molekularny: polimorfizmy genu *GNAT3*, kodującego gustducynę, wyjaśniają około 13% wariacji w postrzeganiu słodczy sacharozy [6]. Znaczy to, że ten sam bodziec (np. identyczna próbka miodu) wywołuje u różnych oceniających wrażenia o realnie różnej intensywności. Jak zauważa [2], doświadczeń zmysłowych nie da się współdzielić, przez co bezpośrednie zestawienie wrażeń dwóch osób jest z zasady problematyczne. W kontekście miodu oznacza to, że rozbieżność ocen tej samej próbki nie musi świadczyć o błędzie, może odzwierciedlać autentyczną różnicę w świecie percepcyjnym asesorów.

4 Nieporównywalność ocen wyrażanych na skalach opisowych

Drugim, silniej udokumentowanym źródłem subiektywności jest psychometryczna nieporównywalność skal ocen. [3] wykazują, że etykiety słowne skal (np. „bardzo silny”) oznaczają różne *bezwzględne* intensywności dla różnych osób i różnych domen zmysłowych zachowują się jak napisy na „elastycznej linijce”, która kurczy się i rozciąga zależnie od odniesienia. Czyni to skale kategoryjne, skale Likerta oraz wizualno-analogowe (VAS)

nieprawomocnymi narzędziami porównań międzygrupowych. Przełożone na ocenę miodu: deklaracja „kwasowość 6 na 10” wystawiona przez jednego panelistę nie jest równoważna takiej samej liczbie podanej przez innego, ponieważ obaj zakotwiczą skalę we własnym, prywatnym zakresie doznań. Sama zgodność liczbowa nie dowodzi więc zgodności percepcyjnej.

5 Empiryczna (nie)spójność ocen ekspertów

Że problem ten nie jest wyłącznie teoretyczny, pokazują badania rzetelności ekspertów na produktach naturalnych zbliżonych metodycznie do miodu. Analizując oceny sędziów na dużym konkursie win, [9] stwierdził, że jedynie około 10% z nich potrafiło powtórzyć własną ocenę identycznej (potrójnie zaślepionej) próbki w obrębie tej samej grupy nagród, a kolejne około 10% oceniało to samo wino w rozpiętości od najniższej do najwyższej kategorii. W analizie obejmującej wiele konkursów [10] wykazał brak zgodności między ośrodkami: zdobycie najwyższej nagrody na jednym konkursie okazało się statystycznie niezależne od wyniku na innym, co wskazuje na znaczący udział przypadku. Wyniki te dokumentują, że nieustrukturyzowana ocena ekspercka bywa mało powtarzalna (wewnątrz asesora) i mało odtwarzalna (między asesorami oraz między ośrodkami), ostrzeżenie wprost przenoszalne na panele oceniające miód.

6 Kalibracja jako warunek porównywalności, granice zaufania do „eksperta”

Powyższe nie oznacza, że ocena sensoryczna jest z natury bezwartościowa. Subiektywność da się kontrolować metodycznie. [14] przedstawiają zestaw mierzalnych wskaźników jakości panelu (zgodność, dyskryminacja, powtarzalność, odtwarzalność, poprawność użycia skali) oraz procedury kalibracji (w szczególności kotwiczenie skali za pomocą wzorców i materiałów odniesienia) dzięki którym wyselekcjonowani i wytrenowani asesory dają oceny spójne i powtarzalne. Na poziomie psychofizyki rozwiązaniem problemu „elastycznej linijki” jest uogólniona skala intensywności (gLMS) zakotwiczona w „najsilniejszym wyobrażalnym wrażeniu dowolnego rodzaju” oraz technika dopasowania wielkości (*magnitude matching*), które w odróżnieniu od klasycznych skal etykietowanych umożliwiają prawomocne porównania między osobami i grupami [4].

Kluczowe zastrzeżenie dotyczy jednak warunku, od którego owa porównywalność zależy: wspólnego, jawnego układu odniesienia. W rutynowej ocenie miodu warunek ten pozostaje najczęściej niespełniony lub niemożliwy do zweryfikowania. Samo określenie „ekspert”, czy nawet formalna przynależność do rejestru asesorów, nie stanowi dowodu aktualnego poziomu wykształcenia osoby badającej daną próbkę: brakuje zwykle opublikowanych wskaźników jej wydajności (powtarzalności wewnątrzasesorskiej, zgodności z panelem, poprawności użycia skali), które według [14] są niezbędne do orzeczenia o wiarygodności oceny. Nie wiemy zatem, na ile konkretny oceniający jest w istocie skalibrowany.

Problem zaostrza się przy porównaniach międzylaboratoryjnych. Jeżeli nie dysponujemy wspólną skalą kalibracyjną ani wspólnymi materiałami odniesienia, zestawienie oceny eksperta z laboratorium A z oceną eksperta z laboratorium B jest metodologicznie nieuprawnione: każdy ośrodek zakotwicza własną „elastyczną linijkę” inaczej [3], a jak pokazuje analiza międzyośrodkowa [10], zgodność ocen tego samego obiektu między niezależnymi ośrodkami bywa bliska losowej. W konsekwencji identyczna wartość liczbowa (np.

„intensywność smaku słodkiego 7”) uzyskana w dwóch laboratoriach nie musi opisywać tego samego wrażenia, a rozbieżność między nimi nie musi oznaczać różnicy w próbkę. Wiarygodne porównanie wymaga zatem uprzedniej harmonizacji: wspólnych wzorców odniesienia, skal o zewnętrznym zakotwiczeniu (gLMS / magnitude matching) oraz badań pierścieniowych (*ring tests*) dokumentujących odtwarzalność między ośrodkami.

Zagadnienie to nie pozostaje wyłącznie teoretyczne: w części empirycznej niniejszej pracy (rozdz. 12.6) przedstawiono bezpośredni, ilościowy przykład takiej rozbieżności międzylaboratoryjnej dla tych samych partii miodu.

7 Podsumowanie

Zebrane przesłanki uzasadniają wniosek w wersji ostrożnej, a nie skrajnej. Subiektywność sensorycznej oceny smaku miodu jest realna i ma dwa niezależne źródła: międzyosobniczą, częściowo dziedziczną zmienność percepcji [16, 6] oraz psychometryczną nieporównywalność skal między osobami [3, 2]. Jej skutkiem bywa niska powtarzalność i odtwarzalność ocen ekspertów obserwowana w badaniach empirycznych [9, 10]. Nie oznacza to jednak, że pomiar sensoryczny jest niekalibrowalny: właściwie wyselekcjonowany, wytrenowany i monitorowany panel, posługujący się wzorcami odniesienia i skalami o zewnętrznym zakotwiczeniu, osiąga akceptowalną wiarygodność [14, 4]. Źródłem niespójności nie jest więc sama natura zmysłu smaku, lecz brak jawnej kalibracji. Dopóki dla danej próbki miodu nie potrafimy wykazać, jak dobrze wyszkolony jest oceniający ją ekspert, ani nie dysponujemy wspólną skalą odniesienia, dopóty porównywanie ocen pochodzących z niezależnych laboratoriów należy traktować z ostrożnością.

8 Cel i zakres badań

Celem głównym badań przedstawionych w poniższej publikacji, jest weryfikacja, czy konsumencka ocena organoleptyczna smaku miodu, przeprowadzona w warunkach ślepego testu panelowego, dostarcza wystarczającej podstawy empirycznej, by traktować ocenę smaku i zapachu jako samodzielne kryterium dopuszczenia do obrotu spełniające wymogi obiektywności, powtarzalności i proporcjonalności. **Prośba o rozwinięcie tego akapitu**

Cele szczegółowe obejmują:

- i. określenie siły i kierunku zależności między statusem dopuszczenia próbki do obrotu, a konsumencką akceptacją smakową oraz ogólną oceną sensoryczną miodu,
- ii. ocenę zdolności dyskryminacyjnej oceny sensorycznej jako predyktora statusu dopuszczenia do obrotu, z wykorzystaniem pola pod krzywą ROC (AUC),
- iii. oszacowanie odsetka błędów klasyfikacji (błędnego odrzucenia próbek dopuszczonych oraz przepuszczenia próbek niedopuszczonych) dla hipotetycznej reguły decyzyjnej opartej na typowości smaku,
- iv. ocenę wiarygodności i odporności zaobserwowanego efektu z uwzględnieniem powtarzalności pomiarów w obrębie respondentów, z zastosowaniem modeli z efektami mieszanymi, testu równoważności (TOST), analizy bayesowskiej oraz analizy mocy,
- v. oddzielenie wpływu statusu dopuszczenia do obrotu od czynnika zakłócającego, jakim jest rodzaj nektaru, poprzez porównanie wewnątrz tego samego typu miodu oraz ocenę heterogeniczności akceptacji między próbkami.

9 Materiał i metody

9.1 Charakterystyka badanych próbek miodu

Badaniom poddano siedem próbek miodu pochodzących z polskich oraz chińskich pasiek. Dokumentacja fizykochemiczna, pyłkowa i organoleptyczna leżąca u podstaw pierwotnej kwalifikacji każdej partii pochodzi z różnych terminów w okresie od lutego 2024 do marca 2026 roku; w skrajnym przypadku wyprzedza to termin panelu konsumenckiego (maj/czerwiec 2026) o ponad dwa lata (p. Ograniczenia badania, rozdz. 12.7). Wszystkie próbki zostały przebadane w certyfikowanych laboratoriach; uzyskane wyniki spełniały wymagania w zakresie analizy pyłkowej (zgodność z deklaracją producenta), zawartości antybiotyków, profilowania metodą NMR, przewodności elektrycznej oraz składu cukrów. Zestaw obejmował dwa miody akacjowe (z robinii akacjowej), cztery miody wielokwiatowe oraz jeden miód lipowy. Cztery spośród siedmiu próbek (P2, P4, P6, P7) zostały niedopuszczone do obrotu na podstawie niezgodności z wymaganiami organoleptycznymi (smak, zapach); parametry fizykochemiczne tych próbek spełniały obowiązujące normy (tabela 2). Próbki przechowywano w kontrolowanych warunkach (temperatura, czas, ochrona przed światłem) do momentu przeprowadzenia oceny.

Szczegółowe dane próbek miodu **Rozważam usunięcie nr badania i LOTu z tabeli, bo nie ma to znaczenia dla oceny sensorycznej:**

Tabela 1: Identyfikacja badanych próbek miodu pszczelego.

Symbol	Rodzaj / pochodzenie
P1	akacjowy / Chiny
P2	akacjowy / Chiny
P3	wielokwiatowy / Polska
P4	wielokwiatowy / Chiny
P5	lipowy / Chiny
P6	wielokwiatowy
P7	wielokwiatowy

Katarzyna S. sprawdza czy wszystkie parametry fizykochemiczne w tabeli 2 są dostępne w dokumentacji, bo niektóre są niekompletne.

Tabela 2: Zestawienie parametrów fizykochemicznych badanych miodów. Puste komórki oznaczają brak oznaczenia w danym sprawozdaniu.

Parametr [jednostka]	P1	P2	P3	P4	P5	P6	P7
Woda / wilgotność [%]	18,2	17,3	–	17,3	17,8	–	18,0
Przewodność elektr. [mS/cm]	–	<0,100	0,24	–	–	–	<0,100
Wolne kwasy [mval/kg]	11	5,9	–	5,4	8,0	–	<5,9
Liczba diastazowa [–] ^a	18,97	12,9	–	13,9	17,83	10,0	8,8
HMF [mg/kg]	10,60	7,8	<5	<6,0	6,46	7,1	9,6
Fruktoza [g/100g]	46,07	43,7	38,9	43,5	41,45	40,4	44,3
Glukoza [g/100g]	28,61	33,2	35,6	36,2	34,83	35,2	33,5
Sacharoza [g/100g]	0,0	0,38	1,5	0,69	0,0	0,4	0,48
Suma F+G [g/100g]	74,68	76,9	74,5	79,7	76,28	75,6	77,8
Stosunek F/G [–]	1,61	–	1,09 ^b	–	1,19	–	–
Prolina [mg/kg]	337	–	306	–	264	256	–
Barwa / kolor [mm]	6	–	–	–	26	–	–
Pyłek przewodni [%]	45	–	95 ^c	49	60	– ^d	–
Skrobia / dekstryny / melasa	n.s.	–	–	–	n.s.	n.s.	n.w.

n.s. – nie stwierdzono; n.w. – nie wykryto.

^a Liczba diastazowa oznaczana różnymi metodami: skala Schade (P1, P5, P6) oraz metoda Phadebas (P2, P4, P7); wartości nie są wprost porównywalne.

^b Wartość z profilu ¹H-NMR; metoda LC-IRMS dała F/G = 1,04.

^c Brassicaceae / rzepak (*Brassica napus*).

^d Profil pyłkowy: Brassicaceae 47%, gryka 32%, słonecznik 10%, arbuz 1%, wargowate 1%, inne 9% (brak jednego pyłku przewodniego).

Spośród siedmiu próbek następujące zostały odrzucone przez certyfikowane laboratorium (uznane za niezgodne z wymaganiami) z powodu cech organoleptycznych obejmujących smak:

1. *P2*: próbka nie spełnia wymagań rozporządzenia MRiRW pod względem cech organoleptycznych: zapach obcy, nietypowy dla miodu, oraz smak landrynkowy, nietypowy dla miodu. Pod względem fizykochemicznym (woda, przewodność, wolne kwasy, diastaza, HMF, sacharoza, suma cukrów) próbka była zgodna.
2. *P4*: próbka nie spełnia wymagań pod względem cech organoleptycznych: smak obcy, metaliczny. Parametry fizykochemiczne były zgodne.
3. *P6*: próbka nie spełnia wymagań pod względem cech organoleptycznych: smak opisany jako „bardzo słodki, nietypowy dla miodu, przypominający smak szczypki cukrowej” i zapach „słabo wyczuwalny, nietypowy”
4. *P7*: próbka nie spełnia wymagań pod względem cech organoleptycznych: opisany smak jako „bardzo słodki, landrynkowy, nietypowy dla miodu”.

P6 i P7 maja obciętą dokumentację, do walidacji czy zostały faktycznie odrzucone.

9.2 Druga, niezależna runda badań: porównanie międzylaboratoryjne

Niezależnie od pierwotnej certyfikacji poprzedzającej ślepy test panelowy, te same siedem partii miodu (P1–P7) poddano w sierpniu 2026 roku (10–17.08.2026) drugiej, odrębnej turze badań laboratoryjnych, zleconej równolegle czterem certyfikowanym laboratoriom (Quality Services International GmbH, Eurofins Food Integrity Control Services GmbH, Intertek Food Services GmbH oraz Instytutowi Ogrodnictwa – PIB, Zakładowi Pszczelnictwa w Puławach). Trzy z nich działają pod akredytacją ISO/IEC 17025 dla co najmniej części wykonywanych oznaczeń; czwarte, ograniczone wyłącznie do oceny organoleptycznej metodą PN-88/A-77626, takiej akredytacji nie zgłasza. Każde laboratorium oceniało próbki niezależnie od pozostałych, jednak – w odróżnieniu od panelu konsumenckiego opisanego w rozdziale 9.3 – próbki nie były kodowane w sposób ślepy względem tożsamości handlowej: każde laboratorium otrzymało je jako zwykłe zlecenie komercyjne. Zakres badań różnił się między laboratoriami: trzy z nich wykonały ocenę organoleptyczną, oznaczenie przewodności elektrycznej oraz – w różnym zakresie – analizę pyłkową i mikrobiologiczną; czwarte ograniczyło się wyłącznie do oceny organoleptycznej. Wyniki wykorzystano tu wyłącznie do oceny powtarzalności międzylaboratoryjnej ocen tej samej cechy dla tej samej partii; nie służą one do weryfikacji autentyczności miodu ani do podważania merytorycznej zasadności któregośkolwiek z uzyskanych werdyktów.

9.3 Dobór i struktura panelu oceniającego

Skład panelu oceniającego (zespołu degustacyjnego) został wyłoniony w drodze rekrutacji opartej na losowym doborze uczestników. W celu zapewnienia maksymalnego obiektywizmu oraz rzetelności wyników w badaniu wykorzystano metodę **ślepego testu** (analizy sensorycznej z użyciem próbek kodowanych).

Kandydaci musieli spełnić kryteria włączenia do grupy badawczej:

- i. *kryterium bezpieczeństwa*: całkowity brak alergii lub nadwrażliwości na produkty pszczele,
- ii. *kryterium fizjologiczne*: prawidłowa sprawność sensoryczna (brak czasowych lub stałych zaburzeń zmysłu węchu i smaku),
- iii. *kryterium dyspozycyjności*: dobrowolna gotowość do wzięcia udziału w obowiązkowym szkoleniu sensorycznym, ujednolicającym standardy oceny.

Ostateczny skład zespołu został skompletowany losowo spośród osób spełniających powyższe wymogi, co pozwoliło wyeliminować błąd systematyczny i zapewnić reprezentatywność ocen.

9.4 Projekt ślepego badania

Badanie przeprowadzono w warunkach ślepej oceny. Próbki miodu zakodowano i podawano w losowej kolejności, bez ujawniania informacji o odmianie, producencie i pochodzeniu. Zapewniono standaryzowane warunki oceny (temperatura podawania próbek, oświetlenie, neutralizacja podniebienia między próbkami).

Arkusze oceny sensorycznej miodu obejmował następujące pytania:

- i. *data badania*: wszystkie badania przeprowadzono w maju oraz czerwcu 2026 roku,
- ii. *grupa wiekowa panelisty*: mniej niż 25, 26-45, 46-65, więcej niż 65 lat,
- iii. *częstotliwość spożywania miodu*: codziennie lub kilka razy w tygodniu, raz w miesiącu, okazynie / rzadziej,
- iv. *płeć panelisty*: kobieta, mężczyzna.

Następnie dla każdej próbki panelista oceniał cechy organoleptyczne w następujących kategoriach:

- i. *ogólna akceptowalność smaku*: skala od 1 (nieakceptowalny) do 5 (niezwykle mi odpowiada),
- ii. *słodycz*: za słaba, w sam raz, za silna,
- iii. *kwasowość*: za słaba, w sam raz, za silna,
- iv. *intensywność aromatu*: za słaba, w sam raz, za silna,
- v. *czy wg respondenta smak jest typowy dla miodu naturalnego*: tak, nie.

9.5 Metody statystyczne

Wszystkie analizy przeprowadzono w języku Python (biblioteki `pandas`, `NumPy`, `SciPy`, `statsmodels` oraz `scikit-learn`). Za poziom istotności przyjęto $\alpha = 0,05$; testy miały charakter dwustronny, o ile nie zaznaczono inaczej. Ze względu na porządkowy charakter ocen sensorycznych (skale 1-3 oraz 1-5) oraz binarny charakter zmiennej typowości smaku, w analizie konsekwentnie stosowano metody nieparametryczne i metody właściwe dla danych jakościowych.

Statystyki opisowe i miary asocjacji. Profil sensoryczny próbek scharakteryzowano za pomocą średnich, odchyłeń standardowych oraz rozkładów procentowych ocen. Związek między statusem dopuszczenia do obrotu a binarną typowością smaku oceniono wstępnie testem χ^2 niezależności wraz ze współczynnikiem φ oraz ilorazem szans (OR). Miary te zastosowano wyłącznie jako opis zależności na poziomie pojedynczych ocen; ze względu na strukturę danych (zob. niżej) nie traktowano ich jako podstawy wnioskowania.

Uwzględnienie powtarzalności pomiarów. Każdy respondent oceniał wszystkie siedem próbek, przy czym status dopuszczenia do obrotu (dopuszczony / niedopuszczony) był stały w obrębie każdej partii. Oznacza to, że w danych występują powtarzane pomiary w obrębie tej samej osoby oraz grupowanie próbek według statusu, co narusza założenie niezależności pojedynczych obserwacji i prowadzi do pseudoreplikacji zmiennej objaśniającej. Aby uwzględnić tę strukturę, dla każdego respondenta obliczono średnią typowość smaku osobno dla miodów dopuszczonych i niedopuszczonych, a następnie różnicę tych średnich poddano testowi kolejności par Wilcozona (test sparowany, $n = 138$). Wielkość efektu wyrażono za pomocą d Cohena dla danych sparowanych, raportując 95% przedział

ufności różnicy. Takie podejście przenosi wnioskowanie z poziomu pojedynczych ocen na poziom respondenta (jednostki analizy), ograniczając zawyżenie istotności wynikające z powtarzanych pomiarów.

Modele z efektami mieszanymi. W celu jednoczesnej kontroli zmienności międzyosobniczej oraz czynnika zakłócającego, jakim jest rodzaj nektaru, zastosowano liniowy model mieszany (LMM) z losowym efektem respondenta dla skali ogólnej akceptacji oraz uogólnione równania szacujące (GEE; rodzina dwumianowa, wymienna struktura korelacji) dla binarnej typowości smaku. Modele te pozwalają oddzielić efekt statusu dopuszczania od różnic między odmianami miodu. Ich wyniki interpretowano jednak z ostrożnością: przy zaledwie 7 partiach (3 dopuszczone, 4 niedopuszczone) zmienna statusu pozostaje pseudoreplikowana, a estymaty obarczone są ryzykiem przeszacowania precyzji.

Test równoważności (TOST) i analiza czułości granicy. Ponieważ celem badań była ocena, czy efekt jest na tyle mały, by nie stanowić praktycznego kryterium decyzyjnego, samo nieodrzućenie hipotezy zerowej byłoby niewystarczające: brak istotności nie dowodzi braku efektu. Zastosowano zatem procedurę dwóch jednostronnych testów (TOST), która formalnie weryfikuje, czy efekt mieści się w z góry przyjętym przedziale równoważności wyznaczonym przez najmniejszy efekt istotny praktycznie (SESOI). Dla przejrzystości przeprowadzono analizę czułości, raportując wynik TOST dla kilku granic SESOI ($\pm 0,10$; $\pm 0,15$; $\pm 0,20$).

Wnioskowanie bayesowskie. Aby skwantyfikować siłę dowodu zarówno za, jak i przeciw istnieniu efektu, dla sparowanego testu t obliczono czynnik Bayesa z domyślnym priorem Cauchy’ego JZS ($r = 0,707$; [13]). W odróżnieniu od klasycznego testu istotności podejście to pozwala bezpośrednio ocenić, na ile dane wspierają hipotezę o braku efektu względem hipotezy alternatywnej.

Analiza mocy. Dla porównania na poziomie partii ($n_{\text{dop.}} = 3$ vs. $n_{\text{niedop.}} = 4$) przeprowadzono analizę mocy, szacując prawdopodobieństwo wykrycia zaobserwowanego efektu oraz liczebność wymaganą do osiągnięcia mocy 80%. Celem było wykazanie, że ewentualny brak istotności na poziomie partii wynika z niedostatecznej mocy badania, a nie stanowi potwierdzenia hipotezy zerowej.

Zdolność dyskryminacyjna i symulacja reguły decyzyjnej. Praktyczną przydatność oceny sensorycznej jako kryterium dopuszczenia do obrotu oceniono za pomocą pola pod krzywą ROC (AUC), traktując typowość smaku oraz ogólną ocenę jako predyktory statusu partii. Dodatkowo, dla hipotetycznej reguły decyzyjnej „odrzuć próbkę, gdy smak uznany za nietypowy” obliczono odsetki błędnej klasyfikacji (błędne odrzucenie partii dopuszczonych oraz przepuszczenie partii niedopuszczonych). Analiza ta przekłada wielkość efektu na bezpośrednio interpretowalne konsekwencje regulacyjne.


Stosunek sygnału do szumu i heterogeniczność. Zaobserwowaną różnicę między grupami (sygnał) odniesiono do naturalnej zmienności akceptacji między partiami w obrębie tej samej grupy (szum), a także zestawiono rozrzut akceptacji wewnątrz grupy miodów dopuszczonych z różnicą międzygrupową. Analiza ta służyła ocenie, czy efekt statusu dopuszczania jest większy niż zmienność próbka-do-próbki, niezależna od statusu administracyjnego.

10 Wyniki

10.1 Charakterystyka respondentów

Badanie objęło **138** respondentów, którzy łącznie dokonali **966** ocen sensorycznych **7** próbek miodu (3 dopuszczone do obrotu, 4 niedopuszczone do obrotu). Liczba ocen przypadających na jednego respondenta była stała i wynosiła 7.0 (zgodnie z ilością badanych próbek miodu).

Wśród 138 uczestników badania dominowały kobiety (74 osób, 53.6%), mężczyźni stanowili 46.4% próby. Najliczniej reprezentowaną grupą wiekową byli respondenci poniżej 25. roku życia, stanowili oni 37.0% (51 osób), następnie respondenci w przedziale 25-45 lat (37 osób; 26.8%) oraz 46-65 lat (37 osób; 26.8%); a powyżej 65. roku życia 9.4%. Miód spożywany jest przez większość respondentów okazjonalnie (58 osób; 42.0%) lub raz w miesiącu (36 osób; 26.1%); codziennie spożywa miód 44 osób (31.9%). Rozkład demograficzny ilustruje rysunek 1.



Rysunek 1: Rozkład demograficzny respondentów: grupy wiekowe, płeć i częstotliwość spożycia miodu ($n = 138$).

10.2 Charakterystyka próbek

Tabela 3 przedstawia profil sensoryczny każdej z siedmiu badanych próbek miodu. Rysunek 2 ilustruje typowość smaku i ogólną ocenę per partia.

10.3 Statystyki opisowe

Rysunek 3 przedstawia rozkład ogólnej akceptacji per partia.


10.4 Profil sensoryczny według statusu dopuszczenia do obrotu rynkowego

Tabela 5 zestawia rozkład procentowy ocen cech sensorycznych (słodycz, kwasowość, intensywność) w podziale na grupę miodów dopuszczonych i niedopuszczonych do obrotu. Skala trzystopniowa: 1 = *za słaba/słaby*, 2 = *w sam raz*, 3 = *za silna/silny*.

Rysunek 4 wizualizuje te różnice jako wykresy słupkowe skumulowane.

Tabela 3: Profile sensoryczne próbek miodu. *Ocena* - średnia ogólna akceptacja (1-5); *Typowy* - odsetek ocen z typowym smakiem miodu naturalnego; *Słodycz/Kwasowość/Intensywność* - średnia na skali 1-3 (1 = za słaba, 2 = w sam raz, 3 = za silna).

Próbka	Typ nektaru	Dop.	<i>n</i>	Ocena	Typowy	Słodycz	Kwasowość	Intens.
P1	akacja	tak	138	3.38	0.558	2.07	1.77	1.69
P2	akacja	nie	138	3.05	0.493	2.06	1.77	1.82
P3	wielokwiatowy	tak	138	3.91	0.899	2.20	1.89	2.06
P4	wielokwiatowy	nie	138	3.14	0.536	2.12	1.83	1.83
P5	lipowy	tak	138	3.16	0.507	2.33	1.89	2.08
P6	wielokwiatowy	nie	138	3.08	0.435	2.25	1.87	2.04
P7	wielokwiatowy	nie	138	3.09	0.486	2.22	1.82	1.85




Rysunek 2: Typowość smaku (%) i ogólna ocena sensoryczna (1-5) dla 7 próbek miodu. Niebieski oznacza próbki dopuszczone do obrotu, pomarańczowy oznacza próbki niedopuszczone do obrotu.

Tabela 4: Statystyki opisowe zmiennych sensorycznych (wszystkie próbki łącznie)


Zmienna	Średnia	Odch. std	Min	Max
Ogólna akceptacja	3.259	1.233	1.0	5.0
Słodycz	2.179	0.649	1.0	3.0
Kwasowość	1.833	0.587	1.0	3.0
Intensywność	1.908	0.679	1.0	3.0
Typowość smaku	0.559	0.497	0.0	1.0

Tabela 5: Rozkład ocen sensorycznych (%) według statusu dopuszczenia do obrotu.

Ocena	Słodycz		Kwasowość		Intensywność	
	Dop.	Niedop.	Dop.	Niedop.	Dop.	Niedop.
za słaba (1)	8.9%	17.2%	23.2%	29.7%	24.2%	31.0%
w sam raz (2)	62.3%	49.1%	68.5%	58.5%	57.4%	49.8%
za silna (3)	28.7%	33.7%	8.2%	11.8%	18.4%	19.2%



Rysunek 3: Rozkład ogólnej akceptacji sensorycznej (skala 1-5) dla każdej z 7 próbek miodu. Linia przerywana oznacza wartość neutralną (3).




Rysunek 4: Rozkład procentowy ocen ordinalnych cech sensorycznych (1 = za słaba, 2 = w sam raz, 3 = za silna) w grupach miodów dopuszczonych i niedopuszczonych do obrotu.

10.5 Wpływ statusu dopuszczenia do obrotu na typowość smaku

Odsetek ocen uznających smak za typowy dla miodu naturalnego wyniósł **0.655** dla miodów dopuszczonych do obrotu i **0.487** dla niedopuszczonych do obrotu. Test χ^2 (na poziomie wierszy) nie wykazał istotnej zależności ($\chi^2 = 26.85$, $p = 0.0$, $\phi = 0.167$); iloraz szans wyniósł $OR = 1.99$.

10.6 Analiza sparowana per respondent

Analiza uwzględniająca powtarzalność pomiarów w obrębie respondentów ($n = 138$) wykazała średnią różnicę akceptacji (dopuszczone do obrotu minus niedopuszczone do obrotu) równą $\Delta = 0.167$ (95% CI: [0.102, 0.233]). Test Wilcozona dla par: $p = 0.0001$; Cohen $d = 0.432$. Rysunek 5 ilustruje sparowane oceny per respondent.



Rysunek 5: Sparowane średnie oceny typowości smaku dla każdego respondenta: oś x oznacza miody niedopuszczone do obrotu, oś y oznacza miody dopuszczone do obrotu. Linia przerywana oznacza równość obu ocen ($y = x$).

10.7 Test równoważności (TOST)

Aby ocenić, czy zaobserwowana różnica jest na tyle mała, by uznać ją za praktycznie nieistotną, przeprowadzono test równoważności TOST. Przy granicy praktycznej istotności ± 0.1 uzyskano $p_{TOST} = 0.9783$ (**brak równoważności**) co nie pozwala orzec równoważności ($p_{TOST} > 0.05$). Oznacza to, że przy tej granicy dane nie wykazują ani istotnej różnicy w sensie praktycznym, ani formalnej równoważności: pozostają nierozstrzygające. Zależność wyniku od przyjętej granicy SESOI przeanalizowano szczegółowo w sekcji 10.15.

10.8 Zdolność dyskryminacyjna oceny sensorycznej

Pole pod krzywą ROC dla cechy *typowość smaku* jako predyktora dopuszczenia do obrotu wyniosło $AUC = 0.584$ (95 % CI bootstrap klastrowy: [0.551, 0.616]), a dla ogólnej

akceptacji (skala 1–5) $AUC = 0.592$ (95 % CI: [0.556, 0.629]) (0,50 = rzut monetą). Oba przedziały ufności obejmują 0,50, co wskazuje, że zdolność dyskryminacyjna żadnego z predyktorów nie różni się istotnie od losowej. Hipotetyczna reguła decyzyjna „*odrzuć próbkę, gdy smak uznany za nietypowy*” błędnie odrzucałaby **34.5%** próbek miódów dopuszczonych do obrotu i pomijałaby **48.7%** próbek niedopuszczonych do obrotu.

10.9 Modele z efektami mieszanymi

Liniowy model mieszany (LMM) z losowym efektem respondenta i kontrolą dla rodzaju nektaru wykazał efekt dopuszczenia do obrotu $\hat{\beta} = 0.61$ (95 % CI: [0.448, 0.772], $p = 0.0$) na skalę ogólnej akceptacji. Uogólnione równania szacujące (GEE, rodzina Binomial, struktura wymienna) dla binarnej typowości smaku dały iloraz szans $OR = 3.328$ (95 % CI: [2.505, 4.421], $p = < 0.001$). Wyniki obu modeli należy interpretować z ostrożnością: przy zaledwie 7 lotach ($n_{dop.} = 3$, $n_{niedop.} = 4$) zmienna dopuszczenia do obrotu jest pseudoreplikowana, ponieważ każdy respondent powtarza obserwację dokładnie 7.0 razy dla tej samej partii.

Warto podkreślić, że surowy $OR = 1.99$ (obliczony z tabeli kontyngencji na poziomie pojedynczych ocen, bez kontroli rodzaju nektaru) i warunkowy $OR = 3.328$ z modelu GEE nie są bezpośrednio porównywalne. Wzrost ilorazu szans po uwzględnieniu rodzaju nektaru wskazuje na confounding negatywny: odmiana miodu maskowała i zaniżała pozorny związek między statusem a typowością smaku, przez co surowy OR był niedoszacowany. Sama korekta o confound gatunkowy nie zmienia jednak wniosku dotyczącego pseudoreplikacji: przy 3 dopuszczonych i 4 niedopuszczonych partiach nie jest możliwe oddzielenie efektu statusu administracyjnego od właściwości tych konkretnych partii.

10.10 Analiza bayesowska

Dla testu t sparowanego ($t = 5.07$, $n = 138$) obliczono czynnik Bayesa z priorem Cauchy’ego JZS ($r = 0.707$; Rouder i in., 2009): $BF_{10} = 9962.38$, co odpowiada $BF_{01} = 0.0$. Interpretacja: **silne poparcie dla H_1** . Dane nie dostarczają zatem silnych dowodów za brakiem efektu (H_0), efekt jest statystycznie wykrywalny, lecz mały i niepewny praktycznie.

10.11 Analiza mocy

Na poziomie partii miódów zaobserwowany Cohen $d = 1.209$ (3 vs 4 próbki). Moc przeprowadzonego porównania wyniosła jedynie **25.2%**. Przy równolicznych grupach osiągnięcie mocy 80 % wymagałoby co najmniej **12 partii w każdej grupie**, co stanowi wartość nieosiągalną w typowych warunkach kontrolnych. Brak istotności na poziomie partii miodu należy zatem interpretować jako *brak dostatecznej mocy*, a nie jako potwierdzenie H_0 .

10.12 Porównanie wewnątrz typów miodu

Zestawienie sparowane per respondent w obrębie tego samego rodzaju nektaru eliminuje confound gatunkowy (tabela 6).

Dla akacji różnica jest statystycznie nieistotna ($p = 0.1699$), co sugeruje brak efektu dopuszczenia do obrotu w obrębie tego gatunku. Istotna różnica dla wielokwiatu ($p = < 0.001$) wynika głównie z silnej dominacji lotu 3 (3 – 4/02/2020: akceptacja 0.899), który sam z siebie winduje średnią grupy miódów dopuszczonych do obrotu.

Tabela 6: Typowość smaku miodów dopuszczonych vs niedopuszczonych do obrotu wewnątrz tego samego typu miodu (test Wilcozona, sparowany per respondent)

Typ miodu	Dop.	Niedop.	p
Robinia	0.558	0.493	0.1699
Polyfloral	0.899	0.486	<0.001
Tilia	0.507	brak próby	b.d.

10.13 Heterogeniczność wewnątrz grupy miodów dopuszczonych do obrotu

Rozrzut akceptacji między lotami dopuszczonymi do obrotu wyniósł **0.391** (od 0.507 dla 5–cq25111501–1 do 0.899 dla 3–4/02/2020), tj. **2.3 razy** więcej niż efekt dopuszczenia do obrotu. Dla partii niedopuszczonych do obrotu analogiczny rozrzut wyniósł 0.101. Fakt, że wewnątrz grupy miodów dopuszczonych do obrotu jednej partii (lipa) charakteryzuje się niższą akceptacją niż dwa spośród trzech partii niedopuszczonych, potwierdza, że status dopuszczenia do obrotu nie wyznacza akceptacji konsumenckiej.

10.14 Analiza czułości granicy SESOI

Tabela 7: p_{TOST} w zależności od przyjętej granicy równoważności

Granica SESOI	p_{TOST}
$\pm 0,10$	0.9783
$\pm 0,15$	0.6993
$\pm 0,20$	0.1614

Wynik testu równoważności silnie zależy od przyjętej granicy praktycznej istotności (SESOI). Minimalna granica, przy której można formalnie orzec równoważność ($p_{\text{TOST}} < 0,05$) wynosi ± 0.22 . Przy węższych, konwencjonalnie przyjmowanych granicach $\pm 0,10$ ($p_{\text{TOST}} = 0.9783$), $\pm 0,15$ ($p_{\text{TOST}} = 0.6993$) oraz $\pm 0,20$ ($p_{\text{TOST}} = 0.1614$) test nie osiąga istotności, a zatem równoważności nie stwierdza. Oznacza to, że orzeczenie o praktycznej równoważności efektu wymagałoby uznania różnicy rzędu 22 punktów procentowych w typowości smaku za nieistotną, co jest granicą trudną do uzasadnienia merytorycznie. Analiza czułości prowadzi więc do wniosku ostrożnego: dane nie pozwalają jednoznacznie orzec ani istotnej różnicy praktycznej, ani równoważności - pozostają nierozstrzygające co do wielkości efektu.

11 Wnioski

Zebrany materiał empiryczny dostarcza spójnego obrazu: subiektywna ocena organoleptyczna smaku nie spełnia warunków stawianych kryterium dopuszczenia do obrotu, obiektywności, powtarzalności i proporcjonalności, i nie powinna stanowić samodzielnej przesłanki dyskwalifikacji produktu spełniającego wszystkie ilościowo oznaczane wymagania.

Różnica typowości smaku między miodami dopuszczonymi do obrotu a niedopuszczonymi wyniosła 16.7 pp ($\phi = 0.167$, $d_{\text{par}} = 0.432$, $\text{BF}_{01} = 0.0$) i była 2.3 razy mniejsza

niż naturalny rozrzut akceptacji wewnątrz samej grupy miódów dopuszczonych do obrotu. Model z efektami mieszanymi potwierdza statystyczną istotność różnicy po kontroli dla rodzaju nektaru ($\hat{\beta} = 0.61$, $p = 0.0$), jednak analiza wewnątrz typu robinia ($p = 0.1699$) i analiza mocy na poziomie partii (moc 25.2%, potrzeba 12 partii na grupę) ujawniają, że wynik jest artefaktem pseudoreplikacji i skrajnej heterogeniczności jednej próbki. $AUC \approx 0.584$ wskazuje na zdolność dyskryminacyjną zbliżoną do losowej. Test równoważności nie orzeka równoważności przy konwencjonalnych granicach (± 0.10 do ± 0.20); dopiero granica ± 0.22 pozwoliłaby uznać efekt za praktycznie zerowy, co potwierdza jedynie, że efekt jest mały, a nie że jest równy zeru.

Ilustratywny jest przypadek próbki P4: spełniała ona wszystkie oznaczane ilościowo wymagania fizykochemiczne i została niedopuszczona do obrotu wyłącznie na podstawie jednej jakościowej obserwacji smaku, podanej bez deklaracji niepewności pomiaru. Ta sama cecha oceniona niezależnie przez 75 osób w warunkach ślepego testu dała wskaźnik typowości 0,653, wyższy niż dla dwóch miódów dopuszczonych do obrotu (P1: 0,573; P5: 0,440), co wskazuje, że odczyt tej cechy nie jest powtarzalny między oceniającymi.

Metryki dyskryminacyjne (AUC , odsetki błędów klasyfikacji) są obliczane na poziomie 966 pojedynczych ocen i nie zależą od liczby siedmiu partii; ich wartości są zatem niezależne od opisanych wyżej ograniczeń mocy badania na poziomie grup i stanowią miarodajną miarę przydatności cechy jako kryterium. $AUC = 0.584$ (95 % CI: [0.551, 0.616]) obejmujący 0,50 wskazuje na zdolność dyskryminacyjną nieodróżnialną od losowej. Gdyby organ kontrolny stosował regułę opartą na typowości smaku, narzędzie to błędnie wykluczyłoby z obrotu **34.5%** próbek miódów legalnie dopuszczonych, a jednocześnie przepuszczało **48.7%** próbek niedopuszczonych. Kryterium o takiej skuteczności nie spełnia wymogów proporcjonalności ani rzetelności, jakie powinno spełniać każde administracyjne kryterium dopuszczenia produktu do obrotu.

Należy przy tym podkreślić, że smak miodu zależy w pierwszej kolejności od gatunku nektaru, warunków zbioru i przetwarzania, a nie od statusu administracyjnego próbki. Wewnątrz grupy miódów dopuszczonych do obrotu rozrzut akceptacji między partiami wyniósł 0.391 (od 0.507 do 0.899), przy czym jeden z miódów posiadających dopuszczenie (typ lipowy) był przez respondentów oceniany gorzej niż dwa z trzech miódów niedopuszczonych do obrotu. Ten fakt pokazuje dobitnie, że etykieta administracyjna i percepcja konsumentka mierzą różne rzeczy i nie powinny być traktowane jako wzajemnie zastępowalne.

Ocena sensoryczna może i powinna być wartościowym narzędziem badawczym i marketingowym, służącym doskonaleniu produktu i komunikacji z konsumentami. Wyniki niniejszego badania wskazują jednak, że nie spełnia ona trzech warunków stawianych kryterium prawno-administracyjnemu: *obiektywności* (wynik zależy od oceniającego i nie jest mierzalny bez wzorca), *powtarzalności* (ta sama próbka uzyskuje różne oceny w zależności od doboru degustatorów) oraz *proporcjonalności* (narzędzie o dyskryminacyjności losowej nie powinno samodzielnie dyskwalifikować produktu spełniającego wszystkie ilościowo oznaczane normy). Włączenie takiego kryterium do procedur dopuszczenia do obrotu prowadziłoby do decyzji obarczonych wysokim odsetkiem błędów klasyfikacji, narażając producentów na arbitralne i nieuzasadnione straty gospodarcze.

12 Dyskusja

12.1 Efekt jest istotny statystycznie, ale w praktyce bez znaczenia

Pytanie badawcze tej pracy nie brzmi: »czy istnieje statystyczna zależność między statusem miodu a oceną konsumentką?«, lecz: »czy ocena sensoryczna smaku spełnia wymagania stawiane kryterium dopuszczenia do obrotu?«. To drugie wymaga zweryfikowania obiektywności, powtarzalności i proporcjonalności cechy, nie tylko istotności statystycznej.

Wynik tego badania na pierwszy rzut oka wygląda na sprzeczny, ale taki nie jest. Różnica w typowości smaku między miodami dopuszczonymi a niedopuszczonymi do obrotu jest z jednej strony zauważalna statystycznie, z drugiej zbyt mała, by miała jakiegokolwiek znaczenie w praktyce. Analiza par (porównanie ocen tego samego respondenta) potwierdziła, że różnica istnieje, ale jest niewielka, a powiązanie między statusem miodu a typowością smaku jest bliskie zeru [15, 5]. Powód jest prosty: ocen było bardzo dużo, a przy tak dużej liczbie danych nawet maleńka różnica „zalicza się” jako istotna. Dlatego sama informacja, że coś jest istotne statystycznie, niczego tu nie rozstrzyga.

Z tego powodu autorzy nie oparli się na samym teście istotności, lecz sprawdzono, jak duży i jak pewny jest ten efekt. Test równoważności (sprawdza, czy efekt jest na tyle mały, że można go uznać za nieistotny) pokazał, że dla rozsądnie przyjętej granicy różnica jest praktycznie równa zeru [11]. Dodatkowa analiza bayesowska (która waży, czy dane bardziej przemawiają za istnieniem efektu, czy za jego brakiem) dała poparcie dla efektu jedynie śladowe [13]. Krótko mówiąc, dane są zbyt słabe, by przesądzić cokolwiek w którąkolwiek stronę i to samo w sobie jest ważną odpowiedzią na pytanie, czy ocena smaku nadaje się na kryterium.

12.2 Dlaczego nie można ufać samej istotności

Projekt badania był celowo sparowany: każdy respondent oceniał wszystkie siedem próbek, co pozwoliło porównywać oceny *tych samych* miodów przez *tych samych* ludzi, zamiast pytać różne osoby o różne produkty. Taki układ eliminuje zmienność między respondentami i jest standardem w analizie sensorycznej [12]. Modele z efektami mieszanymi, uwzględniające tę strukturę, potwierdziły statystyczną istotność efektu.

Właściwe ograniczenie ma charakter strukturalny i dotyczy każdego badania opartego na małej liczbie partii: status dopuszczenia do obrotu jest stały dla *całej partii*, a partii było siedem. Żaden model statystyczny przy takiej liczbie jednostek klastrowych nie pozwoli oddzielić „efektu statusu” od „efektu właściwości tego konkretnego miodu”, każda różnica między partiami zostaje przypisana zmiennej statusu, niezależnie od jej prawdziwego źródła. To samo ograniczenie dotyczyłoby każdego rzeczywistego werdyktu opartego na porównaniu kilku partii: wynik byłby arbitralny z definicji.

Dlatego najmocniejszy wniosek nie wynika z jednego testu, tylko z tego, że kilka różnych analiz mówi to samo. Gdy porównano miody w obrębie tego samego rodzaju (co usuwa wpływ gatunku), dla miodów akacjowych różnicy nie było, a dla miodów wielokwiatowych całą różnicę „robiła” jedna, wyjątkowo wysoko oceniona próbka. Moc badania na poziomie partii okazała się dalece za niska, by cokolwiek pewnego stwierdzić [5]. Wszystko to razem wskazuje, że pozorna istotność bierze się z pseudoreplikacji i z jednej heterogenicznej próbki, a nie z prawdziwego wpływu statusu administracyjnego.

12.3 Różnice między samymi miodami są większe niż efekt statusu

Najlepiej pokazuje to proste zestawienie. Różnica między grupami (dopuszczone vs nie-dopuszczone) okazała się mniejsza niż zwykle różnice między poszczególnymi miodami w tej samej grupie. Mówiąc inaczej: dwa dopuszczone do obrotu miody potrafią różnić się oceną o wiele bardziej, niż wynosi średnia różnica między miodami dopuszczonymi a nie-dopuszczonymi. Co więcej, jeden z miodów z dopuszczeniem wypadł gorzej niż większość miodów bez dopuszczenia. To jasno pokazuje, że o akceptacji decyduje konkretny miód, a nie jego status urzędowy.

12.4 Co to oznacza dla kontroli i dopuszczania do obrotu

Z punktu widzenia ewentualnej kontroli nie liczy się to, czy jakaś różnica istnieje, tylko czy na podstawie smaku da się odtworzyć werdykt laboratoryjny. Tu wynik jest jednoznaczny: trafność takiego rozpoznania była bliska rzutowi monetą [8]. Zdolność dyskryminacyjna praktycznie nie różni się od losowej, co oznacza, że ocena smaku nie wnosi informacji regulacyjnie użytecznej.

Dobitnym przykładem jest próbka P4: spełniała ona wszystkie oznaczane ilościowo wymagania i została niedopuszczona do obrotu wyłącznie na podstawie jednej jakościowej obserwacji smaku, podanej bez deklaracji niepewności pomiaru. Ta sama cecha, oceniona niezależnie przez 75 osób w warunkach ślepego testu, dała wskaźnik typowości 0,653 - wyższy niż dla dwóch miodów dopuszczonych do obrotu (P1: 0,573; P5: 0,440), co wskazuje, że odczyt tej cechy nie jest powtarzalny między oceniającymi. Nie formułujemy oceny merytorycznej werdyktu laboratoryjnego; wskazujemy natomiast, że cecha, której odczyt zależy od oceniającego, nie spełnia warunku powtarzalności stawianego kryterium o skutkach administracyjnych.

Warto przy tym zauważyć, jako wnioskowanie o klasie pomiaru, nie o konkretnej osobie lub laboratorium, że powtarzalność oceny smaku nie rośnie automatycznie przez zmniejszenie liczby oceniających. Zmienność wynikająca z subiektywności percepcji smakowej redukuje się przez uśrednianie; im mniejszy panel, tym mniejsze uśrednianie szumu percepcyjnego. Formalną miarą tej właściwości byłaby zgodność międzyoceniaczą (np. współczynnik kappa Fleissa lub alpha Krippendorffa dla typowości; ICC dla skali ogólnej), której oszacowanie leży poza zakresem niniejszej pracy.

Gdyby zastosować regułę „odrzuć próbkę, gdy smak uznany za nietypowy”, reguła ta błędnie wykluczyłaby z rynku dużą część miodów w pełni legalnych, a jednocześnie przepuściła większość tych niedopuszczonych. Narzędzie, które myli się równie często jak loteria, nie spełnia wymogu rzetelności i proporcjonalności, jakiego oczekuje się od kryterium decydującego o dopuszczeniu produktu do obrotu.

Podobny problem opisano już wcześniej dla innego parametru. W ocenie mikrobiologicznej sama obecność drożdży osmofilnych (bez oznak fermentacji) też nie wystarcza, by uznać miód za niezgodny z wymaganiami [7]. W obu przypadkach kłopotem nie jest sama idea kryterium jakościowego, tylko wybór cechy, która słabo różnicuje produkty dobre i złe. To prowadzi do prostego wniosku: zanim jakiś parametr trafi do procedur dopuszczania do obrotu, trzeba najpierw pokazać, że potrafi on odróżnić produkty zgodne od niezgodnych, a nie tylko że da się go zmierzyć.

12.5 Ocena smaku a metody laboratoryjne

Słabość oceny smaku widać najlepiej w porównaniu z metodami laboratoryjnymi. Pochodzenie i autentyczność miodu ustala się obiektywnie, przede wszystkim analizą pyłkową, którą dziś coraz częściej wspiera sztuczna inteligencja osiągająca niemal pełną zgodność z oceną eksperta [1]. Tymczasem ocena smaku rozpoznaje status miodu na poziomie zbliżonym do przypadku. Wniosek jest taki, że dobre, powtarzalne narzędzia kontroli istnieją; problemem nie jest sama idea kryterium, tylko to, że smak się do tej roli nie nadaje. Status urzędowy i odczucia konsumenta to po prostu dwie różne rzeczy, których nie da się stosować zamiennie.

Nie znaczy to, że ocena smaku jest bezużyteczna. Przeciwnie, to cenne narzędzie do badania preferencji konsumentów, ulepszania produktu i marketingu, a użyta tu metoda ślepej degustacji dobrze ograniczyła wpływ marki czy pochodzenia na oceny. Wyniki mówią jedynie, że miejsce oceny smaku jest po stronie rozwoju i opisu produktu, a nie po stronie decyzji urzędowych.

12.6 Powtarzalność ocen organoleptycznych między niezależnymi laboratoriami: dowód empiryczny

Powyższy wniosek, że ocena smaku nie nadaje się na samodzielne kryterium administracyjne, można zweryfikować bezpośrednio, bez odwoływania się wyłącznie do analogii z oceną win [10]. W sierpniu 2026 roku, już po zakończeniu pierwotnej certyfikacji, te same siedem partii miodu (P1–P7) przesłano niezależnie do czterech kolejnych certyfikowanych laboratoriów w celu ponownej oceny organoleptycznej (rozdz. 9.2). Wynik jest zbieżny z głównym ustaleniem tej pracy: zgodność między laboratoriami okazała się wysoka wyłącznie dla próbek skrajnych, a niska dla próbek granicznych – dokładnie tam, gdzie kryterium administracyjne najbardziej potrzebuje rzetelności (tabela 8).

Dla dwóch spośród czterech partii pierwotnie niedopuszczonych do obrotu z powodu smaku lub zapachu (P6, P7) wszystkie trzy laboratoria wykonujące pełną ocenę organoleptyczną niezależnie potwierdziły w drugiej turze cechy nietypowe dla miodu naturalnego – w tym przypadku ocena okazała się w pełni odtwarzalna. Dla pozostałych dwóch pierwotnie niedopuszczonych partii (P2, P4) obraz jest odwrotny: dla P2 tylko jedno z trzech laboratoriów potwierdziło zastrzeżenia do zapachu lub smaku, a dla P4 żadne z nich nie sformułowało takiego zastrzeżenia – wszystkie sklasyfikowały próbkę jako zgodną z dyrektywą 2001/110/WE. Symetrycznie, spośród trzech partii pierwotnie dopuszczonych do obrotu, jedna (P1) została w drugiej turze samodzielnie zakwestionowana przez jedno z laboratoriów wyłącznie na podstawie zapachu i smaku („niezgodne z profilem pyłkowym, zalecane dalsze badania”), a inna (P5) uzyskała od czwartego laboratorium opis zapachu jednoznacznie wskazujący na fermentację. Tylko jedna partia (P3) uzyskała jednomyślną, pozytywną ocenę wszystkich czterech laboratoriów.

Krótko mówiąc: na siedem partii miodu, laboratoria wykonujące pełną ocenę organoleptyczną zgodziły się ze sobą w pełni w trzech przypadkach, a w pozostałych czterech przynajmniej jedno laboratorium doszło do wniosku przeciwnego niż pozostałe – niezależnie od tego, czy pierwotny werdykt brzmiał „dopuszczony”, czy „niedopuszczony”. Nie jest to dowód na błąd konkretnego laboratorium ani wadę konkretnej partii miodu; jest to dowód na to, że sama cecha (typowość zapachu i smaku) nie jest, w praktyce komercyjnej kontroli jakości, mierzona w sposób powtarzalny między ośrodkami – dokładnie tak, jak przewiduje literatura psychometryczna cytowana w rozdziale 2 [3, 10, 14].

Rozbieżność nie ograniczała się do cech organoleptycznych. Przewodność elektryczna – parametr fizykochemiczny, mierzony przyrządowo i uznawany za jeden z bardziej obiektywnych wskaźników jakości miodu – wykazała dla pięciu z siedmiu partii pełną zgodność między trzema laboratoriami wykonującymi to oznaczenie (rozbieżność $\leq 0,03$ mS/cm, mieszcząca się w deklarowanej niepewności pomiaru rzędu 5%). Dla pozostałych dwóch partii (P6, P7) jedno z trzech laboratoriów podało wynik różniący się od pozostałych dwóch niemal dziesięciokrotnie (0,76–0,84 mS/cm wobec 0,07–0,11 mS/cm), przy czym pozostałe dwa laboratoria pozostawały ze sobą w bardzo dobrej zgodności. Rozbieżność tej skali nie mieści się w żadnej deklarowanej niepewności pomiaru i nie ma charakteru systematycznego – nie występuje dla pozostałych pięciu partii – co wskazuje na pojedynczy błąd pomiarowy lub redakcyjny w jednym z trzech sprawozdań, a nie na rzeczywistą różnicę metod. Zjawisko to sygnalizuje ograniczoną wartość poznawczą pojedynczego sprawozdania laboratoryjnego bez niezależnej weryfikacji nawet dla parametrów uznawanych za w pełni obiektywne – silniejszy argument za ostrożnością wobec pojedynczych ocen jakościowych niż jakikolwiek argument czysto teoretyczny. Dodatkowo, czwarte laboratorium, wykonujące ocenę organoleptyczną metodą nieakredytowaną, zwróciło dla wszystkich siedmiu partii bez wyjątku wynik „cechy niejednoznaczne”, niezależnie od pierwotnego statusu partii i niezależnie od werdyktów pozostałych trzech laboratoriów – co sugeruje, że sam werdykt zależy w istotnym stopniu od wyboru metody i laboratorium w sposób strukturalny, a nie wyłącznie od losowej zmienności percepcji poszczególnych oceniających. Dosłowne, zanonimizowane opisy zapachu i smaku zgłoszone przez wszystkie cztery laboratoria dla każdej z siedmiu partii zestawiono w Załączniku A (tabela 9).

Tabela 8: Zgodność ocen organoleptycznych i przewodności elektrycznej między laboratoriami dla tych samych partii miodu (druga, niezależna tura badań).

Symbol	Status w I turze	Zastrzeżenia do zapachu/smaku (liczba laboratoriów ^a)	Przewodność elektr. [mS/cm], zakres
P1	dopuszczony	1/3 ^b	0,13–0,14
P2	niedopuszczony	1/3	0,12–0,12
P3	dopuszczony	0/3	0,24–0,27
P4	niedopuszczony	0/3	0,19–0,19
P5	dopuszczony	0/3 ^b	0,31–0,34
P6	niedopuszczony	3/3	0,08–0,84 ^c
P7	niedopuszczony	3/3	0,07–0,76 ^c

^a Trzy laboratoria wykonały pełną ocenę organoleptyczną i fizykochemiczną. Czwarte, posługujące się nieakredytowaną metodą organoleptyczną (PN-88/A-77626), zwróciło wynik „cechy niejednoznaczne” dla wszystkich siedmiu partii bez wyjątku, niezależnie od ich statusu i werdyktów pozostałych laboratoriów, i nie zostało ujęte w tej kolumnie.

^b Dodatkowo czwarte laboratorium zgłosiło niezależnie zapach wskazujący na możliwą fermentację.

^c Rozbieżność wynika z pojedynczego, znacząco odstającego wyniku jednego z trzech laboratoriów; pozostałe dwa pozostają w bardzo dobrej wzajemnej zgodności (zob. tekst).

12.7 Ograniczenia badania

Najważniejszym ograniczeniem jest mała liczba partii miodu. Nawet przy dużej liczbie osób oceniających to właśnie liczba partii decyduje o sile wniosków o samej autoryzacji i to ona powoduje opisaną wyżej pseudoreplikację oraz niską moc badania na poziomie

porównania grup. Należy jednak wyraźnie podkreślić, że niska moc dotyczy wyłącznie pytania o istotność różnicy między grupami (dopuszczone vs. niedopuszczone) na poziomie partii, nie podważa ona ważności metryk dyskryminacyjnych: AUC oraz odsetki błędów klasyfikacji obliczane są na poziomie pojedynczych ocen ($n = 525$) i nie zależą od liczby partii, lecz od zdolności cechy do odtworzenia werdyktu laboratoryjnego. Po drugie, status dopuszczenia mieszał się z rodzajem miodu, a miód lipowy był tylko jeden (i to z dopuszczeniem), więc nie dało się tych czynników w pełni rozdzielić. Po trzecie, oceniali konsumenci, a nie wyszkoleni degustatorzy, to dobrze oddaje perspektywę rynkową, ale zwiększa rozrzut ocen. Po czwarte, badano miody z jednego sezonu i z ograniczonej liczby odmian oraz regionów, więc wyników nie należy uogólniać na wszystkie miody. Brakuje również formalnej miary zgodności międzyocenającej dla typowości smaku (np. alpha Krippendorffa, kappa Fleissa), która pozwoliłaby ilościowo oszacować powtarzalność tej cechy jako klasy pomiaru.

Po piąte, dokumentacja fizykochemiczna, pyłkowa i organoleptyczna leżąca u podstaw pierwotnej kwalifikacji partii nie pochodzi z jednego terminu: sprawozdania rozciągają się na okres od lutego 2024 do marca 2026 roku, czyli w skrajnym przypadku ponad dwa lata przed panelem konsumenckim (maj/czerwiec 2026). W tym czasie właściwości miodu zależne od przechowywania (stopień krystalizacji, zawartość HMF) mogły ulec zmianie, co osłabia założenie, że panel oceniał dokładnie tę samą, niezmienną próbkę, którą pierwotnie zbadano i zakwalifikowano.

Po szóste, druga tura badań międzylaboratoryjnych (rozdz. 12.6) nie była przeprowadzona w warunkach formalnego testu pierścieniowego (*ring test*): próbki nie były kodowane w sposób ślepy względem tożsamości handlowej, laboratoria nie dysponowały wspólnym materiałem odniesienia, a badania wykonano w innym terminie niż pierwotną certyfikację i panel konsumencki, co mogło dodatkowo wpływać na cechy zależne od czasu przechowywania. Różnice w werdyktach między laboratoriami należy zatem traktować jako dowód z praktyki komercyjnej kontroli jakości, a nie jako wynik w pełni kontrolowanego eksperymentu psychometrycznego.

Trzeba też pamiętać, że praca ocenia smak jako *narzędzie do podejmowania decyzji*, a nie chemiczną autentyczność badanych miódów to dwie osobne sprawy.

Załącznik A: dosłowne oceny organoleptyczne z drugiej tury badań

Poniższa tabela zestawia dosłowne, przetłumaczone opisy zapachu i smaku zgłoszone przez cztery niezależne laboratoria dla tych samych siedmiu partii miodu w drugiej, niezależnej turze badań (sierpień 2026, rozdz. 9.2), będące podstawą zbiorczej tabeli 8 i dyskusji w rozdziale 12.6.

Tabela 9: Dosłowne, zanonimizowane opisy zapachu i smaku zgłoszone przez cztery niezależne laboratoria dla tych samych partii miodu (druga tura badań, sierpień 2026). Numeracja laboratoriów (1–4) jest umowna i spójna w obrębie tabeli, ale nie ujawnia tożsamości laboratorium.

Symbol (status I tura)	Lab.	Zapach	Smak
P1 (dopuszczony)	1	nietypowy dla miodu	nietypowy dla miodu
	2	przypominający mocz zwierzęcy, lekko typowy dla pożytku	słodki, kwiatowy, łagodny, lekko typowy dla pożytku
	3	typowy dla miodu	słodki, owocowy
	4	słaby, lekko kwaśny, charakterystyczny dla oznak fermentacji	słodki, łagodny
P2 (niedopuszczony)	1	nietypowy dla miodu	nietypowy dla miodu
	2	przypominający mocz zwierzęcy, lekko typowy dla pożytku	słodki, kwiatowy, łagodny, lekko metaliczny, lekko typowy dla pożytku
	3	lekko typowy dla pożytku	słodki, owocowy, lekko typowy dla pożytku
	4	nienaturalny, lekko kwiatowy	bardzo słodki, szczypiący
P3 (dopuszczony)	1	typowy dla pożytku	typowy dla pożytku
	2	lekko typowy dla pożytku	słodki, kwiatowy, ziołowy, lekko typowy dla pożytku
	3	typowy dla miodu	słodki, kwiatowy, owocowy, ziołowy
	4	silny, podobny do wosku pszczelego	słodki, nieco ostry
P4 (niedopuszczony)	1	słabo typowy dla pożytku	słabo typowy dla pożytku
	2	lekko typowy dla miodu	słodki, owocowy, medyczny (apteczny), lekko metaliczny, lekko typowy dla miodu
	3	lekko typowy dla pożytku	słodki, owocowy, miętowy, lekko typowy dla pożytku

Tabela 9 (ciąg dalszy)

Symbol (status I tura)	Lab.	Zapach	Smak
	4	słabo wyczuwalny, kwiatów rzepaku	słodki
P5 (dopuszczony)	1	słabo typowy dla pożytku	słabo typowy dla pożytku
	2	lekko typowy dla pożytku	słodki, kwiatowy, medyczny (apteczny), lekko gorzki, mię- towy, lekko typowy dla po- żytku
	3	typowy dla miodu	słodki, owocowy, miętowy
	4	wyraźny, charakterystyczny dla oznak fermentacji	słodki, łagodny
P6 (niedopuszczony)	1	nietypowy dla miodu	nietypowy dla miodu
	2	brak	słodki, bez wyraźnego aro- matu kwiatowego, nietypowy dla miodu
	3	nietypowy dla miodu	słodki, owocowy, słodowy, nietypowy dla miodu
	4	silny, charakterystyczny dla oznak fermentacji	słodki, przypominający pa- lony karmel
P7 (niedopuszczony)	1	nietypowy dla miodu	nietypowy dla miodu
	2	nietypowy dla miodu	słodki, bez wyraźnego aro- matu kwiatowego, lekko me- taliczny, nietypowy dla miodu
	3	nietypowy dla miodu	słodki, owocowy, słodowy, nietypowy dla miodu
	4	silny, landrynkowy	bardzo słodki, nieco szczy- piący

Literatura

- [1] Joanna Katarzyna Banach, Bartosz Lewandowski, and Przemysław Rujna. Artificial intelligence in honey pollen analysis: Accuracy and limitations of pollen classification compared with palynological expert assessment. *Applied Sciences*, 15(24):13009, 2025.
- [2] Linda M. Bartoshuk. Comparing sensory experiences across individuals: Recent psychophysical advances illuminate genetic variation in taste perception. *Chemical Senses*, 25(4):447–460, 2000.
- [3] Linda M. Bartoshuk, Valerie B. Duffy, Karen Fast, Barry G. Green, Jordan Prutkin, and Derek J. Snyder. Labeled scales (e.g., category, Likert, VAS) and invalid across-group comparisons: what we have learned from genetic variation in taste. *Food Quality and Preference*, 14(2):125–138, 2003.

- [4] Linda M. Bartoshuk, Valerie B. Duffy, Barry G. Green, Howard J. Hoffman, Chung-Wu Ko, Laurie A. Lucchina, Lawrence E. Marks, Derek J. Snyder, and James M. Weiffenbach. Valid across-group comparisons with labeled scales: the gLMS versus magnitude matching. *Physiology & Behavior*, 82(1):109–114, 2004.
- [5] Jacob Cohen. *Statistical Power Analysis for the Behavioral Sciences*. Routledge, New York, 2nd edition, 1988.
- [6] Alexey A. Fushan, Christopher T. Simons, Jay P. Slack, and Dennis Drayna. Association between common variation in genes encoding sweet taste signaling components and human sucrose perception. *Chemical Senses*, 35(7):579–592, 2010.
- [7] Anna Gajda, Bartosz Lewandowski, Przemysław Rujna, Joanna Katarzyna Banach, Renata Pietrzak-Fiećko, and Ewaryst Tkacz. Immature honey as a quality challenge in global apicultural production. *Foods*, 15(12):2136, 2026.
- [8] James A. Hanley and Barbara J. McNeil. The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, 143(1):29–36, 1982.
- [9] Robert T. Hodgson. An examination of judge reliability at a major U.S. wine competition. *Journal of Wine Economics*, 3(2):105–113, 2008.
- [10] Robert T. Hodgson. An analysis of the concordance among 13 U.S. wine competitions. *Journal of Wine Economics*, 4(1):1–9, 2009.
- [11] Daniël Lakens. Equivalence tests: A practical primer for t tests, correlations, and meta-analyses. *Social Psychological and Personality Science*, 8(4):355–362, 2017.
- [12] Kung-Yee Liang and Scott L. Zeger. Longitudinal data analysis using generalized linear models. *Biometrika*, 73(1):13–22, 1986.
- [13] Jeffrey N. Rouder, Paul L. Speckman, Dongchu Sun, Richard D. Morey, and Geoffrey Iverson. Bayesian t tests for accepting and rejecting the null hypothesis. *Psychonomic Bulletin & Review*, 16(2):225–237, 2009.
- [14] László Sipos, Ákos Nyitrai, Géza Hitka, László Ferenc Friedrich, and Zoltán Kókai. Sensory panel performance evaluation—comprehensive review of practical approaches. *Applied Sciences*, 11(24):11977, 2021.
- [15] Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945.
- [16] Paul M. Wise, Jonathan L. Hansen, Danielle R. Reed, and Paul A. S. Breslin. Twin study of the heritability of recognition thresholds for sour and salty taste. *Chemical Senses*, 32(8):749–754, 2007.