Przyrost wiedzy bez transferu: skuteczność mikrouczenia z powtórkami rozłożonymi w czasie w szkoleniach pracowniczych

Bartosz Lewandowski (ORCID:0009-0004-1158-0693)[1,*], Monika Szerszeń (ORCID: 0009-0009-6625-3979)[2], Magdalena Dowgalec (ORCID:0009-0005-4469-2832)[3], Ewaryst Tkacz (ORCID:0000-0003-2580-7954)[4] i Maciej J. Wróbel (ORCID:0000-0003-1865-2122)[5]

[1,4]Department of Clinical Engineering, Academy of Silesia in Katowice
[3]Powiślański Bank Spółdzieczy w Kwidzynie
[4]Atende SA
[5]Department of Otolaryngology and Oncological Laryngology Collegium Medicum NCU
[*]Autor korespondencyjny: dr Bartosz Lewandowski, bartosz.lewandowski@akademiaslaska.pl

xx

Streszczenie

Wprowadzenie. Przypominanie rozłożone w czasie poprawia zapamiętywanie w warunkach laboratoryjnych i edukacyjnych, jednak dowodów z wieloletnich programów szkoleń w miejscu pracy jest niewiele. **Metody.** Przeanalizowano 60 962 odpowiedzi udzielonych przez 187 pracowników na 164 pytań wielokrotnego wyboru w 9 modułach programu mikrouczenia opartego na quizach (od kwietnia 2023 do czerwca 2026). Każde pytanie było ponownie zadawane temu samemu pracownikowi w stałym, nieadaptacyjnym odstępie (mediana 36 dni). Poprawność odpowiedzi modelowano regresją logistyczną z efektami stałymi pracownika i pytania; oszacowania opisowe podano z przedziałami ufności z bootstrapu klastrowego. **Wyniki.** Odsetek poprawnych odpowiedzi wzrósł z 82,5% w pierwszej próbie do 91,8% w próbie 10. i kolejnych. Każde podwojenie liczby prób zwiększało szanse poprawnej odpowiedzi 1,38-krotnie (95% PU [1,32; 1,45]; zakres w dziesięciu specyfikacjach analiz wrażliwości 1,29–1,50). Dłuższy odstęp od poprzedniej próby wiązał się z niższą poprawnością (OR 0,88 na podwojenie odstępu). Powtarzane błędy koncentrowały się na tym samym dystraktorze (71,6% wobec oczekiwanych 59,6%). Poprawność odpowiedzi na nowo napotkane pytania nie rosła wraz ze stażem (OR 0,88 na rok). **Wnioski.** Powtarzanemu przypominaniu w rutynowych szkoleniach pracowniczych towarzyszyła systematyczna poprawa specyficzna dla powtarzanych pytań oraz mierzalne zapominanie między powtórkami. Adaptacyjny harmonogram powtórek, ukierunkowana informacja zwrotna dotycząca utrwalonych błędnych przekonań oraz zmiana słabo funkcjonujących pytań mogłyby zwiększyć skuteczność programu.

Słowa kluczowe: powtórki rozłożone w czasie; praktyka przypominania; mikrouczenie; szkolenia pracownicze; analityka uczenia się; analiza pytań testowych

1 Wprowadzenie

Przypominanie sobie informacji z pamięci wzmacnia ich późniejsze utrwalenie silniej niż ponowne ich przeczytanie (efekt testowania), a nauka rozłożona w czasie jest zapamiętywana lepiej niż nauka skumulowana (efekt rozłożenia w czasie) [3, 4, 24]. W randomizowanych badaniach z udziałem lekarzy w trakcie kształcenia tzw. edukacja rozłożona w czasie (ang. *spaced education*), w której

krótkie pytania wielokrotnego wyboru są dostarczane wielokrotnie przez tygodnie lub miesiące, poprawiała przyswajanie i utrwalanie wiedzy [10–12], a przeglądy systematyczne wskazują na małe lub umiarkowane korzyści u pracowników ochrony zdrowia [17, 22].

W organizacjach powszechnie stosuje się krótkie formy *mikrouczenia* (ang. *microlearning*) oparte na quizach, jednak dostępne dowody pochodzą głównie z małych badań lub z tzw. szarej literatury [28]. Ewaluacje obowiązkowych szkoleń organizacyjnych, np. z zakresu świadomości bezpieczeństwa, często wykazują efekty niewielkie lub zanikające w czasie [9, 14, 23]. Jednocześnie dane z dzienników (logów) takich platform pozwalają obserwować uczenie się na poziomie pojedynczych odpowiedzi, podobnie jak w modelach ucznia rozwijanych dla inteligentnych systemów tutorskich i aplikacji do nauki języków [5, 13, 21, 25, 26].

Badanie przeprowadzono w banku, w którym pracownicy odpowiadali na krótkie pytania wielokrotnego wyboru dotyczące wymogów regulacyjnych, produktów bankowych, umiejętności miękkich oraz – w przypadku kadry kierowniczej – zarządzania, wyświetlane przez aplikację na komputerze w trakcie dnia pracy. Na podstawie trzyletnich logów odpowiedzi z tego programu mikrouczenia odpowiedziano na następujące pytania badawcze: (PB1) czy odsetek poprawnych odpowiedzi rośnie wraz z kolejnymi przypomnieniami tego samego pytania przez tego samego pracownika; (PB2) jak poprawność zależy od wyniku poprzedniej próby i od czasu, który od niej upłynął; (PB3) czy powtarzane błędy są trwałe, co wskazywałoby raczej na błędne przekonania niż na zgadywanie; (PB4) czy poprawa przenosi się na nowo napotykane pytania; oraz (PB5) jakie są właściwości psychometryczne pytań?

2 Materiał i metody

2.1 Środowisko i program szkoleniowy

Program prowadzono w banku. Jego treść stanowiły pytania ogólne pogrupowane w cztery kategorie: wymogi regulacyjne, produkty bankowe, umiejętności miękkie oraz moduł dla kadry kierowniczej. Każde pytanie było pytaniem wielokrotnego wyboru z trzema do pięciu opcjami odpowiedzi, z których dokładnie jedna była poprawna, i zawierało wyjaśnienie poprawnej odpowiedzi. Dedykowana aplikacja uruchamiała się automatycznie na ekranach komputerów pracowników i wyświetlała od jednego do trzech pytań dziennie w godzinach 10:00–14:00; po każdej odpowiedzi pokazywano poprawną odpowiedź wraz z wyjaśnieniem. To samo pytanie mogło zostać ponownie zadane temu samemu pracownikowi nie wcześniej niż siedem dni po poprzedniej odpowiedzi, a harmonogram powtórek nie zależał od tego, czy odpowiedź była poprawna. Na czas przeglądu i aktualizacji pytań program był zawieszany. O udziale w programie decydował Departament Digitalizacji i Procesów banku, który był również autorem pytań. Pytania prezentowano w modułach tematycznych (mediana 3 zaobserwowanych opcji odpowiedzi na pytanie). W analizowanych danych pracownicy odpowiadali na medianę 3 pytań w dniu aktywności, 100,0% odpowiedzi udzielono w dni robocze, a to samo pytanie było ponownie zadawane temu samemu pracownikowi po medianie 36 dni (IQR 18–90).

2.2 Dane

Log platformy zawierał dla każdej odpowiedzi: identyfikator rekordu, moduł, pytanie, wybraną opcję, zanonimizowany kod pracownika, znacznik czasu oraz poprawność odpowiedzi. Usunięto rekordy z brakującymi lub nieprawidłowymi wartościami (0 rekordów). Wykluczono moduł(y) testowe (mnk-tst; 212 odpowiedzi) oraz 2 pytania, w których zarejestrowano tylko jedną opcję odpowiedzi (348 odpowiedzi), ponieważ nie niosą one informacji o błędach. Zbiór analityczny obejmował 60 962 odpowiedzi (tab. 1). Bank przekazał autorom dane w pełni zanonimizowane: pracownicy byli reprezen-

towani wyłącznie przez kody, których nie można było powiązać z ich tożsamością, i nie przekazano żadnych danych osobowych ani demograficznych. Ponieważ dane zanonimizowane nie są danymi osobowymi w rozumieniu RODO, nie była wymagana dodatkowa podstawa prawna przetwarzania. [Zgoda komisji bioetycznej lub zwolnienie z obowiązku jej uzyskania, jeśli wymaga tego czasopismo.]

2.3 Definicje

Sekwencja to uporządkowana chronologicznie seria prób jednego pracownika dotyczących jednego pytania; *numer próby* to pozycja odpowiedzi w jej sekwencji (przy jednakowym czasie o kolejności decydował identyfikator rekordu). *Poprawność* to odsetek poprawnych odpowiedzi. *Odstęp* to czas w dniach od poprzedniej próby w tej samej sekwencji. *Staż* to czas od pierwszej odpowiedzi pracownika w programie. Zmianę na poziomie pracownika zdefiniowano jako różnicę odsetka poprawnych odpowiedzi między próbą 3 a próbą 1, obliczoną na podstawie własnych sekwencji pracownika liczących co najmniej trzy próby.

2.4 Analiza statystyczna

Opisowe odsetki poprawnych odpowiedzi podano z 95-procentowymi przedziałami ufności (PU) z bootstrapu klastrowego, w którym losowano pracowników ze zwracaniem (2000 replikacji); uwzględnia to zależność odpowiedzi tej samej osoby. Ponieważ osoby kontynuujące do kolejnych prób mogą różnić się od tych, które przestają, zagregowane krzywe uczenia mogą być zniekształcone przez ubywanie obserwacji [8, 18]; dlatego krzywe uczenia obliczono dodatkowo dla zbalansowanej kohorty sekwencji liczących co najmniej 5 prób. Zależność odsetka błędów od numeru próby opisano funkcją potęgową [20]. Ponieważ harmonogram powtórek nie był adaptacyjny, sprawdzono, czy ponowne zadanie pytania zależało od wyniku poprzedniej próby.

Poprawność odpowiedzi modelowano regresją logistyczną z efektami stałymi pracownika i pytania oraz błędami standardowymi klastrowanymi względem pracowników, tak aby efekt numeru próby był szacowany w obrębie osób i w obrębie pytań. Model 1 zawierał numer próby w skali $\log_2$, dzięki czemu iloraz szans (OR) odnosi się do podwojenia liczby prób. Model 2, dopasowany do prób powtórnych, uwzględniał dodatkowo wynik poprzedniej próby, odstęp od poprzedniej próby ($\log_2$ dni) oraz staż – analogicznie do modeli *performance factors analysis* i *half-life regression* stosowanych do logów uczących się [21, 25]. Model 3, dopasowany wyłącznie do pierwszych prób, weryfikował, czy poprawność odpowiedzi na nowo napotkane pytania zmieniała się wraz ze stażem (PB4). W analizach wrażliwości wykorzystano zbalansowaną kohortę, obcięcie do 10 prób, warstwy według długości sekwencji (kontrola obciążenia typu *pattern-mixture*), wykluczenie pracowników o niskiej aktywności, korektę o staż, uogólnione równania estymujące (GEE) z wymienną macierzą korelacji roboczej [15] oraz model mieszany ze skrzyżowanymi losowymi wyrazami wolnymi pracowników i pytań [1], na podstawie którego wyznaczono współczynniki korelacji wewnątrzklasowej (ICC) w skali latentnej oraz brzegowy i warunkowy współczynnik R^2 [19].

Zestawiono przejścia między kolejnymi próbami. Dla kolejnych błędów porównano odsetek ponownych wyborów tego samego dystraktora z odsetkiem oczekiwanym przy losowym wyborze spośród zaobserwowanych dystraktorów oraz przy wyborze proporcjonalnym do popularności każdego dystraktora w danym pytaniu. Zmianę na poziomie pracowników testowano testem znaków i testem rangowanych znaków Wilcoxona (korelacja rangowo-dwuseryjna jako miara wielkości efektu). Pytania opisano wskaźnikami klasycznej teorii testu obliczonymi na pierwszych próbach: trudnością (odsetek poprawnych odpowiedzi), dyskryminacją (korelacja pytanie–reszta, tj. z poprawnością pracownika w pozostałych pytaniach) oraz funkcjonowaniem dystraktorów; dystraktory wybierane przez mniej niż 5% odpowiadających uznano za niefunkcjonalne [7, 27]. Trendy poprawności w ko-

lejnych próbach dla poszczególnych pytań testowano regresją logistyczną z błędami standardowymi klastrowanymi względem pracowników, kontrolując odsetek fałszywych odkryć (FDR) na poziomie 0,05 [2]. Analizy wykonano w języku Python 3.14.4 z użyciem bibliotek pandas 2.3.3, NumPy 2.3.5, SciPy 1.16.3, statsmodels 0.14.6 i Matplotlib 3.10.7 (ziarno generatora liczb losowych 2026).

3 Wyniki

3.1 Próba i zaangażowanie

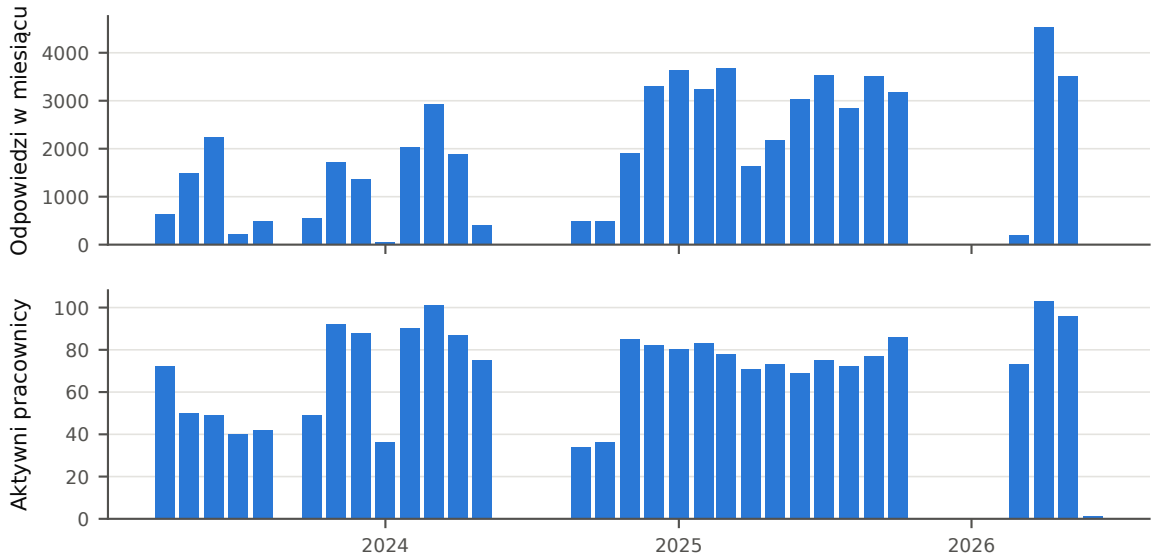
Zbiór danych obejmował 60 962 odpowiedzi 187 pracowników na 164 pytań w 9 modułach, zebranych od kwietnia 2023 do czerwca 2026 (tab. 1). Mediana liczby odpowiedzi na pracownika wynosiła 218 (IQR 67–592), udzielonych na 90 różnych pytań w ciągu 84 dni aktywności; mediana czasu uczestnictwa w programie wynosiła 18 miesięcy, a 56,1% pracowników było aktywnych w ostatnich 90 dniach obserwacji. Aktywność zmieniała się w czasie i występowały okresy bez odpowiedzi (rys. 1); odpowiadają one zawieszeniom programu na czas przeglądu i aktualizacji pytań. Ogólny odsetek poprawnych odpowiedzi wynosił 86,5%, a w pierwszych próbach 82,5%.

Harmonogram powtórek nie zależał od wyniku poprzedniej próby: prawdopodobieństwo kolejnej próby wynosiło 74,0% po odpowiedzi poprawnej i 74,7% po błędnej, a mediana odstępu do kolejnej próby – odpowiednio 36 i 38 dni. Kontynuacja sekwencji nie była więc selekcjonowana według wyników.

Tabela 1: Charakterystyka zbioru danych.

Cecha	Wartość
Odpowiedzi	60 962
Pracownicy	187
Pytania	164
Okres obserwacji	2023-04-24 – 2026-06-08
Sekwencje pracownik–pytanie	15 783
Zaobserwowane opcje odpowiedzi na pytanie, mediana (zakres)	3 (2–5)
Odpowiedzi na pracownika, mediana [IQR]	218 [67; 592]
Pytania na pracownika, mediana [IQR]	90 [26; 139]
Dni aktywności na pracownika, mediana [IQR]	84 [28; 220]
Odpowiedzi na dzień aktywności, mediana [IQR]	3 [2; 4]
Odpowiedzi w dni robocze (%)	100,0
Miesiące między pierwszą a ostatnią odpowiedzią, mediana [IQR]	18 [5; 30]
Pracownicy aktywni w ostatnich 90 dniach danych (%)	56,1
Próby w sekwencji, mediana [IQR] (maks.)	3 [2; 5] (19)
Sekwencje z $\geq$2 / $\geq$3 próbami (%)	78,6 / 60,6
Dni między próbami, mediana [IQR]	36 [18; 90]
Odpowiedzi poprawne, ogółem (%)	86,5
Odpowiedzi poprawne, pierwsze próby (%)	82,5

IQR – rozstęp międzykwartylowy. Sekwencja to seria prób jednego pracownika dotyczących jednego pytania. Wykluczone moduły testowe: mnk-tst (212 odpowiedzi). Wykluczone pytania z jedną zaobserwowaną opcją odpowiedzi: 2 (348 odpowiedzi).



Rysunek 1: Miesięczna liczba odpowiedzi (u góry) i aktywnych pracowników (u dołu) w okresie obserwacji.

3.2 Uczenie się w kolejnych próbach (PB1)

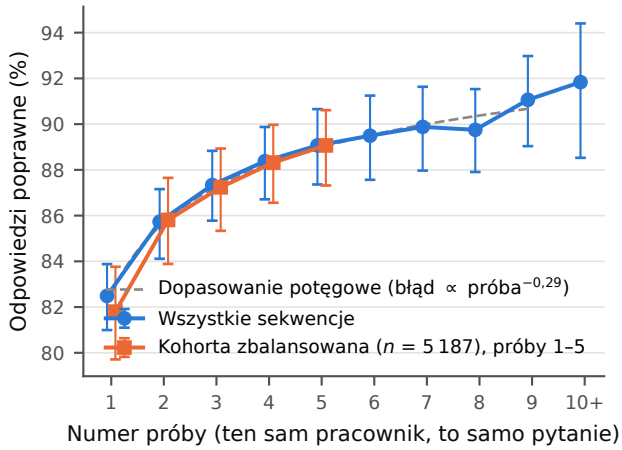
Odsetek poprawnych odpowiedzi rósł systematycznie wraz z numerem próby: z 82,5% [81,0; 83,9] w pierwszej próbie do 91,8% [88,5; 94,4] w próbie 10. i kolejnych (rys. 2, tab. 2). Wzrost był podobny w zbalansowanej kohorcie 5187 sekwencji liczących co najmniej 5 prób (81,8% [79,7; 83,8] w próbie 1 wobec 89,1% [87,3; 90,6] w próbie 5), nie wynika więc z selektywnej kontynuacji przez pracowników osiągających lepsze wyniki. Odsetek błędów był funkcją potęgową numeru próby (wykładnik 0,29, $R^2 = 0{,}98$), zgodnie z potęgowym prawem praktyki [20].

W modelu 1 każde podwojenie liczby prób wiązało się z 1,38-krotnie wyższymi szansami poprawnej odpowiedzi (95% PU [1,32; 1,45]; tab. 3). Pytania odpowiadały za większą część wariancji niż pracownicy (ICC w skali latentnej 0,24 wobec 0,09; brzegowy $R^2 = 0{,}021$, warunkowy $R^2 = 0{,}35$).

Tabela 2: Odsetek poprawnych odpowiedzi według numeru próby w sekwencjach pracownik–pytanie.

Próba	n	Pracownicy	%	95% PU	n (kohorta)	% (kohorta)	95% PU (kohorta)
1	15 783	187	82,5	[81,0; 83,9]	5187	81,8	[79,7; 83,8]
2	12 413	160	85,7	[84,1; 87,2]	5187	85,8	[83,9; 87,7]
3	9563	149	87,3	[85,8; 88,8]	5187	87,2	[85,3; 88,9]
4	7124	141	88,4	[86,7; 89,9]	5187	88,3	[86,6; 90,0]
5	5187	129	89,1	[87,4; 90,7]	5187	89,1	[87,3; 90,6]
6	3693	106	89,5	[87,6; 91,2]			
7	2638	90	89,9	[88,0; 91,6]			
8	1844	81	89,8	[87,9; 91,5]			
9	1186	70	91,1	[89,0; 93,0]			
10+	1531	57	91,8	[88,5; 94,4]			

Kohorta: sekwencje liczące ≥5 prób, co utrzymuje stały zbiór sekwencji w próbach 1–5 i eliminuje obciążenie przeżywalności. 95% PU z bootstrapu klastrowego, w którym losowano pracowników (2000 replikacji).

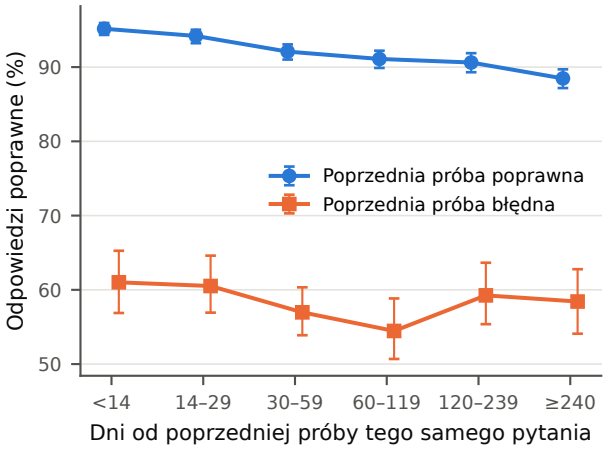


Rysunek 2: Odsetek poprawnych odpowiedzi według numeru próby w sekwencjach pracownik–pytanie. Koła: wszystkie sekwencje dostępne w danej próbie (ich liczba maleje wraz z numerem próby). Kwadraty: zbalansowana kohorta, tj. te same 5187 sekwencje, które osiągnęły co najmniej 5 prób, obserwowane wyłącznie w próbach 1–5, dzięki czemu każdy punkt opiera się na identycznych sekwencjach. Słupki błędów: 95% PU z bootstrapu klastrowego po pracownikach (2000 replikacji). Linia przerywana: dopasowanie funkcji potęgowej do odsetka błędów. Próby 10. i dalsze połączono.

Tabela 3: Regresja logistyczna poprawności odpowiedzi: ilorazy szans [95% PU].

Predyktor	Model 1	Model 2	Model 3
Numer próby (na podwojenie)	1,38 [1,32; 1,45]	1,33 [1,24; 1,42]	
Poprzednia próba poprawna		3,85 [3,49; 4,26]	
Dni od poprzedniej próby (na podwojenie)		0,88 [0,86; 0,90]	
Staż pracownika (na rok)		0,87 [0,77; 1,00]	0,88 [0,76; 1,01]
Dane	Wszystkie próby	Próby ≥2	Pierwsze próby
Odpowiedzi	60 680	44 499	15 333
Pracownicy / pytania	163 / 164	146 / 163	162 / 161

Wszystkie modele zawierają efekty stałe pracownika i pytania; błędy standardowe klastrowane względem pracowników. Pracownicy i pytania bez zmienności poprawności są pomijani przez warunkową funkcję wiarygodności (model 1: 282 odpowiedzi). Model 3 weryfikuje, czy poprawność odpowiedzi na nowo napotkane pytania rośnie wraz z czasem uczestnictwa w programie.



Rysunek 3: Odsetek poprawnych odpowiedzi według odstępu od poprzedniej próby tego samego pytania, osobno dla odpowiedzi poprzednio poprawnych (koła) i poprzednio błędnych (kwadraty). Słupki błędów: 95% PU z bootstrapu klastrowego po pracownikach.

3.3 Wynik poprzedniej próby, odstęp i zapominanie (PB2)

Po uwzględnieniu numeru próby poprawna poprzednia odpowiedź wiązała się z wyższymi szansami poprawnej odpowiedzi (model 2: OR 3,85, 95% PU [3,49; 4,26]), a dłuższy odstęp od poprzedniej próby – z niższymi (OR 0,88 na podwojenie odstępu, 95% PU [0,86; 0,90]; tab. 3). Wśród odpowiedzi poprzednio poprawnych odsetek poprawnych zmniejszał się z 95,2%, gdy pytanie powtórzono w ciągu 14 dni, do 88,5% po 240 dniach lub dłużej; odpowiedzi poprzednio błędne były korygowane odpowiednio w 61,0% i 58,4% przypadków (rys. 3, tab. 4). Wzorzec ten jest zgodny z zapominaniem między powtórkami [3, 4].

Tabela 4: Odsetek poprawnych odpowiedzi według odstępu od poprzedniej próby tego samego pytania, dla odpowiedzi poprzednio poprawnych (po lewej) i błędnych (po prawej).

Dni od poprzedniej	n	Poprawne, % [95% PU]	n	Poprawne, % [95% PU]
<14	6288	95,2 [94,3; 95,9]	949	61,0 [56,9; 65,3]
14–29	10 816	94,2 [93,2; 95,0]	1631	60,5 [56,9; 64,6]
30–59	8326	92,1 [91,0; 93,1]	1327	57,0 [53,9; 60,3]
60–119	6212	91,1 [89,9; 92,2]	964	54,5 [50,7; 58,8]
120–239	4220	90,6 [89,3; 91,9]	724	59,3 [55,4; 63,7]
≥240	3176	88,5 [87,2; 89,7]	546	58,4 [54,1; 62,8]

95% PU z bootstrapu klastrowego, w którym losowano pracowników (2000 replikacji).

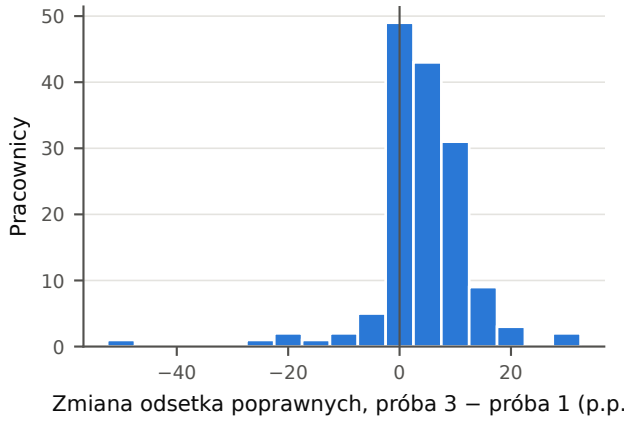
3.4 Przejścia i utrwalone błędy (PB3)

Spośród odpowiedzi poprzednio poprawnych 92,6% [91,7; 93,3] było poprawnych również w kolejnej próbie (7,4% zapomniano); spośród odpowiedzi poprzednio błędnych 58,5% [55,7; 61,3] skorygowano, a 41,5% pozostało błędnych (tab. 5). Gdy błąd się powtarzał (2546 przypadków), pracownicy wybierali ten sam dystraktor w 71,6% [69,4; 73,8] przypadków, wobec 47,1% oczekiwanych przy wyborze losowym i 59,6% oczekiwanych przy uwzględnieniu popularności poszczególnych dystraktorów, co wskazuje na trwałe błędne przekonania, a nie na zgadywanie.

Tabela 5: Przejścia między kolejnymi próbami tego samego pytania.

Poprzednia próba	n	Kolejna poprawna (%)	95% PU	Kolejna błędna (%)
Poprawna	39 038	92,6	[91,7; 93,3]	7,4
Błędna	6141	58,5	[55,7; 61,3]	41,5

Po dwóch kolejnych błędach ten sam dystraktor wybrano w 71,6% [69,4; 73,8] przypadków ($n = 2546$); wartość oczekiwana przy losowym wyborze spośród zaobserwowanych dystraktorów wynosiła 47,1%, a przy ważeniu ogólną popularnością każdego dystraktora w danym pytaniu – 59,6%. 95% PU z bootstrapu klastrowego, w którym losowano pracowników (2000 replikacji).



Rysunek 4: Rozkład zmiany odsetka poprawnych odpowiedzi na poziomie pracownika między próbą 3 a próbą 1 w jego własnych sekwencjach liczących co najmniej trzy próby ($n = 149$ pracowników; przedziały o szerokości 5 punktów procentowych wyśrodkowane na zerze).

3.5 Zmiana na poziomie pracowników

Spośród 149 pracowników (79,7% wszystkich), którzy mieli co najmniej jedną sekwencję liczącą trzy lub więcej prób, 102 poprawiło wynik, 20 go pogorszyło, a u 27 nie zmienił się on między pierwszą a trzecią próbą (test znaków: $p < 0{,}001$; test Wilcoxona: $p < 0{,}001$; korelacja rangowo-dwuseryjna $r = 0{,}72$). Średnia zmiana wyniosła 3,8 punktu procentowego (95% PU [2,4; 5,2]; rys. 4, tab. 6).

3.6 Przenoszenie na nowe pytania (PB4)

Odsetek poprawnych odpowiedzi przy pierwszym kontakcie z nowym pytaniem nie rósł wraz ze stażem (model 3: OR 0,88 na rok, 95% PU [0,76; 1,01]; tab. 3), a po uwzględnieniu numeru próby staż nie wiązał się dodatnio z poprawnością w próbach powtórnych (model 2: OR 0,87, 95% PU [0,77; 1,00]). Korzyści wydają się więc specyficzne dla powtarzanych pytań.

3.7 Analiza pytań (PB5)

Mediana trudności pytań wynosiła 85,3% poprawnych odpowiedzi w pierwszej próbie: na 4 pytania poprawnie odpowiedziało mniej niż 50% pracowników, na 102 – 50–90%, a na 58 – ponad 90% (tab. 7). Mediana korelacji pytanie–reszta wynosiła 0,22; 70 z 161 pytań miało korelację poniżej 0,20, a 49 – co najmniej 0,30 (rys. 5). Błędy koncentrowały się na jednym dystraktorze (mediana 71,8% błędów w pytaniu), a 193 z 349 zaobserwowanych dystraktorów (55,3%) było niefunkcjonalnych.

Tabela 6: Zmiana odsetka poprawnych odpowiedzi między pierwszą a trzecią próbą tych samych pytań.

Miara	Wartość
Pracownicy z ≥1 sekwencją o ≥3 próbach	149
Poprawa / pogorszenie / bez zmian	102 / 20 / 27
Średnia zmiana, p.p. [95% PU]	3,8 [2,4; 5,2]
Mediana zmiany, p.p.	3,7
Test znaków: odsetek z poprawą [95% PU]; p	0,84 [0,76; 0,90]; <0,001
Test Wilcoxona W; p; korelacja rangowo-dwuseryjna r	1052; <0,001; 0,72
Sekwencje (pracownik–pytanie) z ≥3 próbami	9563
Poprawne w próbie 1 / próbie 3 (%)	82,6 / 87,3
Błędna→poprawna / poprawna→błędna	1075 / 625
Test McNemara χ^2; p (bez uwzględnienia klastrów)	118,6; <0,001

Zmiana na poziomie pracownika: różnica odsetka poprawnych odpowiedzi między próbą 3 a próbą 1 we własnych sekwencjach pracownika liczących ≥3 próby; remisy wykluczono z testu znaków i testu Wilcoxona. p.p. – punkty procentowe.

Poprawność istotnie rosła wraz z powtórkami w 44 z 164 testowalnych pytań, a malała w 1 (po korekcie FDR). Najtrudniejsze pytania zestawiono w tab. 8.

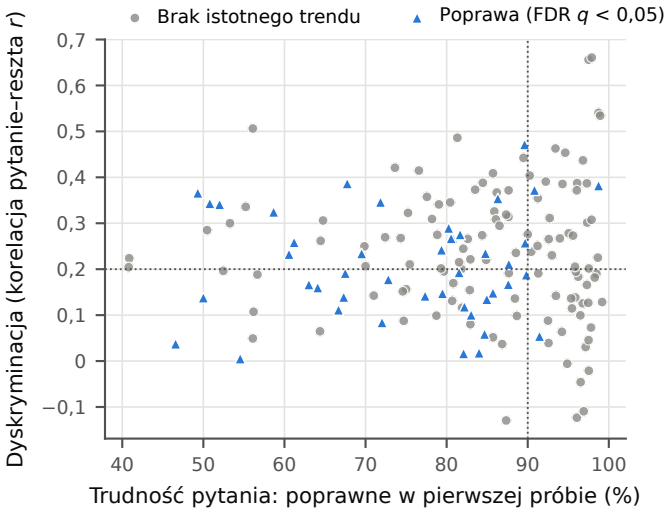
Tabela 7: Analiza pytań (klasyczna teoria testu).

Miara	Wartość
Analizowane pytania	164
Trudność (% poprawnych w pierwszej próbie), mediana [IQR]	85,3 [75,2; 94,2]
Pytania z <50% / 50–90% / >90% poprawnych	4 / 102 / 58
Dyskryminacja (korelacja pytanie–reszta r), mediana [IQR], pytania z n ≥30	0,22 [0,14; 0,32] (k = 161)
Pytania z r < 0,20 / 0,20–0,29 / ≥ 0,30	70 / 42 / 49
Udział błędów przypadających na najczęstszy dystraktor (%), mediana [IQR]	71,8 [58,4; 84,3]
Zaobserwowane dystraktory wybierane w <5% odpowiedzi (niefunkcjonalne)	193 z 349 (55,3%)
Pytania z poprawą / pogorszeniem przy powtórkach (FDR q < 0,05)	44 / 1 (z 164 testowalnych)

Trudność i dyskryminację obliczono na pierwszych próbach; korelacja pytanie–reszta wykorzystuje poprawność pracownika w pozostałych pytaniach (pracownicy z ≥10 pierwszymi próbami). Trend: regresja logistyczna poprawności względem $\log_2$(numeru próby) dla każdego pytania z błędami standardowymi klastrowanymi względem pracowników, korekta Benjaminiego–Hochberga. Dystraktory, których nigdy nie wybrano, nie są widoczne w logu i nie zostały uwzględnione.

3.8 Analizy wrażliwości

Efekt numeru próby był stabilny w różnych specyfikacjach, z OR od 1,29–1,50 (rys. 6, tab. 9): 1,36 w zbalansowanej kohorcie, 1,30, 1,35 i 1,40 w sekwencjach liczących 3–4, 5–7 i co najmniej 8 prób, 1,29 w uśrednionym populacyjnie modelu GEE oraz 1,37 w modelu mieszanym. Oszacowanie było wyższe po korekcie o staż (1,50), który jest skorelowany z numerem próby.

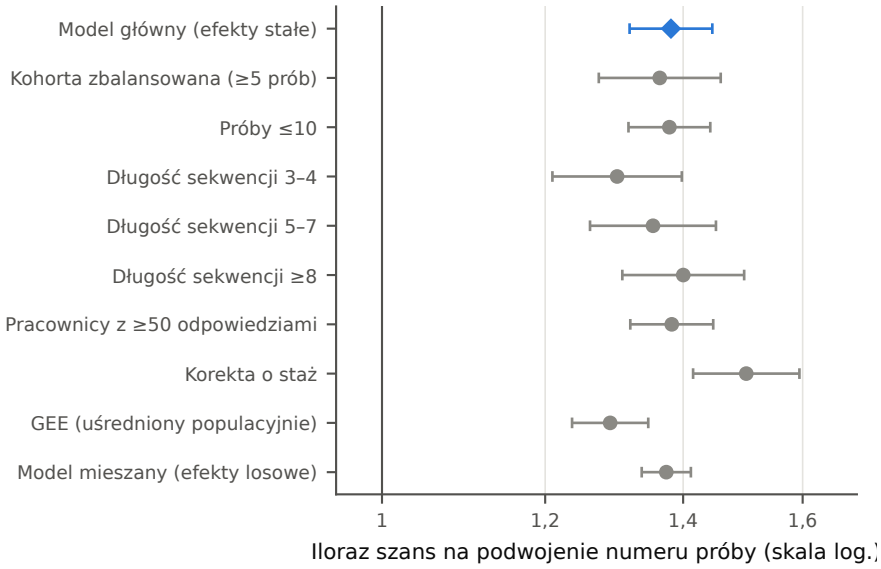


Rysunek 5: Trudność pytania (odsetek poprawnych w pierwszej próbie) a dyskryminacja (korelacja pytanie–reszta). Trójkąty: pytania, w których poprawność istotnie rosła wraz z powtórkami (Benjamini–Hochberg, $q < 0{,}05$). Linie kropkowane: $r = 0{,}20$ i 90% poprawnych.

Tabela 8: 10 najtrudniejszych pytań.

Pytanie	Moduł	n	Pierwsza (%)	Kolejne (%)	Dom. dystr. (%)	r_{it}	OR trendu	q
127	qo3-q5s	150	40,8	51,4	76,5	0,20	1,15	0,759
66	ier-4pm	285	40,9	42,2	55,4	0,22	0,99	0,973
261	g25-pwd	214	46,6	69,5	75,6	0,04	1,95	<0,001
140	ier-4pm	175	49,3	83,3	100,0	0,37	3,44	<0,001
305	cgn-jqc	248	50,0	75,3	43,5	0,14	2,37	<0,001
35	ier-4pm	416	50,5	65,8	71,7	0,29	1,23	0,185
160	2qx-6t6	623	50,8	67,4	82,1	0,34	1,60	<0,001
71	ier-4pm	431	52,0	73,1	73,7	0,34	1,52	0,004
206	d6s-bu8	553	52,5	60,8	54,2	0,20	1,22	0,190
132	s5m-mc2	558	53,3	67,2	82,0	0,30	1,18	0,216

Pierwsza/Kolejne – odsetek poprawnych w pierwszej i w późniejszych próbach; Dom. dystr. – udział błędów przypadających na najczęstszy dystraktor; r_{it} – korelacja pytanie–reszta; OR trendu – iloraz szans na podwojenie numeru próby; q – wartość p skorygowana metodą Benjaminiego–Hochberga.



Rysunek 6: Iloraz szans (95% PU) poprawnej odpowiedzi na podwojenie numeru próby w różnych specyfikacjach modelu. Romb: model główny; linia pionowa: brak efektu.

Tabela 9: Analizy wrażliwości: iloraz szans poprawnej odpowiedzi na podwojenie numeru próby.

Analiza	Odpowiedzi	OR [95% PU]
Efekty stałe pracownika i pytania (model główny)	60 680	1,38 [1,32; 1,45]
Kohorta zbalansowana (sekwencje z ≥5 próbami, próby 1–5)	24 920	1,36 [1,27; 1,46]
Próby obcięte do 10	59 877	1,38 [1,32; 1,44]
Wyłącznie sekwencje o długości 3–4	14 218	1,30 [1,21; 1,40]
Wyłącznie sekwencje o długości 5–7	18 154	1,35 [1,26; 1,45]
Wyłącznie sekwencje o długości ≥8	16 884	1,40 [1,31; 1,50]
Pracownicy z ≥50 odpowiedziami	60 256	1,38 [1,32; 1,45]
Z korektą o staż pracownika	60 680	1,50 [1,42; 1,59]
GEE, korelacja wymienna w obrębie pracownika (efekt uśredniony populacyjnie)	60 962	1,29 [1,24; 1,35]
Skrzyżowane losowe wyrazy wolne pracownika i pytania (aproksymacja Laplace'a)	60 962	1,37 [1,34; 1,41]

Odchylenia standardowe losowych wyrazów wolnych (skala logitowa): pracownik SD = 0,69, pytanie SD = 1,10; ICC w skali latentnej: pracownik = 0,09, pytanie = 0,24; R^2 Nakagawy: brzegowy = 0,021, warunkowy = 0,35. Warstwy według długości sekwencji służą kontroli obciążenia typu *pattern-mixture* (ubywania obserwacji) w krzywej uczenia.

4 Dyskusja

4.1 Główne wyniki

W ciągu trzech lat rutynowego stosowania programu mikrouczenia w miejscu pracy odsetek poprawnych odpowiedzi na wielokrotnie prezentowane pytania rósł systematycznie wraz z liczbą przypomnień, zgodnie z funkcją potęgową, a efekt był odporny na ubywanie obserwacji, specyfikację modelu i klastrowanie danych. Poprawność malała wraz z odstępem od poprzedniego przypomnienia, wcześniejsze błędy były w kolejnej próbie korygowane tylko częściowo, a powtarzane błędy w większości odtwarzały ten sam dystraktor. Poprawność odpowiedzi na nowe pytania nie rosła wraz ze stażem.

4.2 Porównanie z wcześniejszymi badaniami

Stopniowy, regularny przyrost przypomina krzywe uczenia obserwowane w wielu zbiorach danych edukacyjnych [13] i jest zgodny z efektami testowania i rozłożenia w czasie [3, 24]. Randomizowane badania edukacji rozłożonej w czasie wykazały lepsze utrwalenie wiedzy [10, 12]; nasze dane obserwacyjne rozszerzają te wyniki na niemedyczne środowisko pracy z długimi odstępami między powtórkami. Ujemny związek między odstępem a poprawnością jest zgodny z modelami krzywej zapominania dopasowywanymi do logów uczących się [25, 26]. Podobnie jak w badaniach, w których wielokrotnie wykorzystywano te same pytania [6], poprawy w powtarzanych pytaniach nie da się oddzielić od zapamiętania konkretnego pytania i jego odpowiedzi; brak efektu stażu w nowych pytaniach sugeruje ograniczony transfer.

4.3 Implikacje praktyczne

Program ponownie prezentował pytania w tym samym odstępie niezależnie od wyniku poprzedniej próby. Harmonogramy adaptacyjne, które skracają odstęp po błędach i wydłużają go po poprawnych odpowiedziach, efektywniej wykorzystują historię uczącego się [16, 25, 26]. Konkretne dystraktory utrzymywały się, mimo że po każdej odpowiedzi wyświetlano wyjaśnienie poprawnej odpowiedzi, co sugeruje, że ogólne wyjaśnienie nie wystarcza do skorygowania błędnych przekonań; skuteczniejsza może być informacja zwrotna odnosząca się do konkretnego wybranego dystraktora. Analiza pytań wskazała kandydatów do zmiany: pytania o niskiej dyskryminacji, pytania, na które niemal wszyscy odpowiadali poprawnie już w pierwszej próbie (mało miejsca na uczenie się), oraz dystraktory niefunkcjonalne [7, 27].

4.4 Ograniczenia

Badanie ma charakter obserwacyjny i nie obejmuje grupy kontrolnej, nie można więc przypisać przyrostu wiedzy programowi w sensie przyczynowym; poprawa w powtarzanych pytaniach może częściowo odzwierciedlać rozpoznawanie pytania, a nie jego zrozumienie. Udział i aktywność różniły się między pracownikami, a wyniki dla sekwencji z wieloma próbami opisują bardziej aktywnych uczestników, choć analizy zbalansowanej kohorty i długości sekwencji nie wskazały na obciążenie wynikające z ubywania obserwacji. Wysoka poprawność w pierwszych próbach (82,5%) ogranicza możliwość poprawy (efekt sufitowy). Dystraktory, których nigdy nie wybrano, nie są widoczne w logu, więc funkcjonowanie dystraktorów może być przeszacowane. Nie dysponowano informacjami o stanowiskach pracowników, ich wcześniejszej wiedzy ani danych demograficznych. Znaczniki czasu nie zawierały informacji o strefie czasowej. Model mieszany zawierał wyłącznie losowe wyrazy wolne; nie modelowano indywidualnego tempa uczenia się pracowników. Dane pochodzą z jednej organizacji. [Dodaj ograniczenia specyficzne dla kontekstu.]

5 Wnioski

Rutynowemu, powtarzanemu przypominaniu w szkoleniach pracowniczych towarzyszyła systematyczna poprawa specyficzna dla powtarzanych pytań oraz zapominanie między powtórkami. Dane z logów takich programów mogą służyć do monitorowania uczenia się, oceny pytań i projektowania adaptacyjnych harmonogramów powtórek.

Oświadczenia

Etyka. W badaniu wykorzystano w pełni zanonimizowane dane przekazane przez bank; nie przetwarzano danych osobowych. [Zgoda komisji bioetycznej lub zwolnienie z obowiązku jej uzyskania, jeśli wymaga tego czasopismo.]
Dostępność danych. [Dostępność zanonimizowanych danych i kodu analizy.]
Finansowanie. [Źródła finansowania.]
Konflikt interesów. [Oświadczenie.]
Wykorzystanie narzędzi AI. [Oświadczenie o użyciu generatywnej AI, jeśli wymaga tego czasopismo.]

Literatura

[1] R. Harald Baayen, Douglas J. Davidson, and Douglas M. Bates. Mixed-effects modeling with crossed random effects for subjects and items. *Journal of Memory and Language*, 59(4):390–412, 2008. doi:10.1016/j.jml.2007.12.005.

[2] Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B (Methodological)*, 57(1):289–300, 1995. doi:10.1111/j.2517-6161.1995.tb02031.x.

[3] Nicholas J. Cepeda, Harold Pashler, Edward Vul, John T. Wixted, and Doug Rohrer. Distributed practice in verbal recall tasks: a review and quantitative synthesis. *Psychological Bulletin*, 132(3):354–380, 2006. doi:10.1037/0033-2909.132.3.354.

[4] Nicholas J. Cepeda, Edward Vul, Doug Rohrer, John T. Wixted, and Harold Pashler. Spacing effects in learning: a temporal ridgeline of optimal retention. *Psychological Science*, 19(11): 1095–1102, 2008. doi:10.1111/j.1467-9280.2008.02209.x.

[5] Albert T. Corbett and John R. Anderson. Knowledge tracing: modeling the acquisition of procedural knowledge. *User Modeling and User-Adapted Interaction*, 4:253–278, 1994. doi:10.1007/BF01099821.

[6] Stella C. M. Donker, Marc A. T. M. Vorstenbosch, Marie-José T. Gerhardus, and Dick H. J. Thijssen. Retrieval practice and spaced learning: preventing loss of knowledge in Dutch medical sciences students in an ecologically valid setting. *BMC Medical Education*, 22:65, 2022. doi:10.1186/s12909-021-03075-y.

[7] Mark J. Gierl, Okan Bulut, Qi Guo, and Xinxin Zhang. Developing, analyzing, and using distractors for multiple-choice tests in education: a comprehensive review. *Review of Educational Research*, 87(6):1082–1116, 2017. doi:10.3102/0034654317726529.

[8] Cyril Goutte, Guillaume Durand, and Serge Léger. On the learning curve attrition bias in additive factor modeling. In *Artificial Intelligence in Education (AIED 2018)*, LNCS, 2018. doi:10.1007/978-3-319-93846-2_21.

[9] Grant Ho, Ariana Mirian, Elisa Luo, Khang Tong, Euyhyun Lee, Lin Liu, and Geoffrey M. Voelker. Understanding the efficacy of phishing training in practice. In *2025 IEEE Symposium on Security and Privacy (SP)*, pages 37–54, 2025. DOI to verify.

[10] B. Price Kerfoot. Learning benefits of on-line spaced education persist for 2 years. *Journal of Urology*, 181(6):2671–2673, 2009. doi:10.1016/j.juro.2009.02.024.

[11] B. Price Kerfoot, Harley E. Baker, Michael O. Koch, David Connelly, David B. Joseph, and Michael L. Ritchey. Randomized, controlled trial of spaced education to urology residents in the United States and Canada. *Journal of Urology*, 177(4):1481–1487, 2007. doi:10.1016/j.juro.2006.11.074.

[12] B. Price Kerfoot, William C. DeWolf, Barbara A. Masser, Paul A. Church, and Daniel D. Federman. Spaced education improves the retention of clinical knowledge by medical students: a randomised controlled trial. *Medical Education*, 41(1):23–31, 2007. doi:10.1111/j.1365-2929.2006.02644.x.

[13] Kenneth R. Koedinger, Paulo F. Carvalho, Ran Liu, and Elizabeth A. McLaughlin. An astonishing regularity in student learning rate. *Proceedings of the National Academy of Sciences*, 120 (13):e2221311120, 2023. doi:10.1073/pnas.2221311120.

[14] Daniele Lain, Kari Kostiainen, and Srdjan Čapkun. Phishing in organizations: findings from a large-scale and long-term study. In *2022 IEEE Symposium on Security and Privacy (SP)*, pages 842–859, 2022. DOI to verify; arXiv:2112.07498.

[15] Kung-Yee Liang and Scott L. Zeger. Longitudinal data analysis using generalized linear models. *Biometrika*, 73(1):13–22, 1986. doi:10.1093/biomet/73.1.13.

[16] Robert V. Lindsey, Jeffery D. Shroyer, Harold Pashler, and Michael C. Mozer. Improving students' long-term knowledge retention through personalized review. *Psychological Science*, 25 (3):639–647, 2014. doi:10.1177/0956797613504302.

[17] Laura Martinengo, Marcus Sheng Pin Ng, Tabitha Dora Ruo Ng, Yu-Ian Ang, Ahmad Ishqi Jabir, Bhone Myint Kyaw, and Lorainne Tudor Car. Spaced digital education for health professionals: systematic review and meta-analysis. *Journal of Medical Internet Research*, 26:e57760, 2024. doi:10.2196/57760.

[18] R. Charles Murray, Steven Ritter, Tristan Nixon, Ryan Schwiebert, Robert G. M. Hausmann, Brendon Towle, Stephen E. Fancsali, and Annalies Vuong. Revealing the learning in learning curves. In *Artificial Intelligence in Education (AIED 2013)*, volume 7926 of *LNCS*, 2013. doi:10.1007/978-3-642-39112-5_48. author list to verify.

[19] Shinichi Nakagawa and Holger Schielzeth. A general and simple method for obtaining R^2 from generalized linear mixed-effects models. *Methods in Ecology and Evolution*, 4(2):133–142, 2013. doi:10.1111/j.2041-210x.2012.00261.x.

[20] Allen Newell and Paul S. Rosenbloom. Mechanisms of skill acquisition and the law of practice. In John R. Anderson, editor, *Cognitive Skills and Their Acquisition*, pages 1–55. Lawrence Erlbaum, Hillsdale, NJ, 1981.

[21] Philip I. Pavlik, Hao Cen, and Kenneth R. Koedinger. Performance factors analysis - a new alternative to knowledge tracing. In *Artificial Intelligence in Education (AIED 2009)*, volume 200 of *Frontiers in Artificial Intelligence and Applications*, pages 531–538. IOS Press, 2009. doi:10.3233/978-1-60750-028-5-531.

[22] Jane L. Phillips, Nicole Heneka, Priyanka Bhattarai, Clare Fraser, and Tim Shaw. Effectiveness of the spaced education pedagogy for clinicians' continuing professional development: a systematic review. *Medical Education*, 53(9):886–902, 2019. doi:10.1111/medu.13895.

[23] Benjamin Reinheimer, Lina Aldag, Peter Mayer, Mattia Mossano, Reyhan Duezguen, Bettina Lofthouse, Tatiana von Landesberger, and Melanie Volkamer. An investigation of phishing awareness and education over time: when and how to best remind users. In *Sixteenth Symposium on Usable Privacy and Security (SOUPS 2020)*. USENIX Association, 2020.

[24] Henry L. Roediger and Jeffrey D. Karpicke. Test-enhanced learning: taking memory tests improves long-term retention. *Psychological Science*, 17(3):249–255, 2006. doi:10.1111/j.1467-9280.2006.01693.x.

[25] Burr Settles and Brendan Meeder. A trainable spaced repetition model for language learning. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics*, pages 1848–1858, 2016. URL `https://aclanthology.org/P16-1174`.

[26] Behzad Tabibian, Utkarsh Upadhyay, Abir De, Ali Zarezade, Bernhard Schölkopf, and Manuel Gomez-Rodriguez. Enhancing human learning via spaced repetition optimization. *Proceedings of the National Academy of Sciences*, 116(10):3988–3993, 2019. doi:10.1073/pnas.1815156116.

[27] Marie Tarrant, James Ware, and Ahmed M. Mohammed. An assessment of functioning and non-functioning distractors in multiple-choice questions: a descriptive analysis. *BMC Medical Education*, 9:40, 2009. doi:10.1186/1472-6920-9-40.

[28] Allison D. Taylor and Woei Hung. The effects of microlearning: a scoping review. *Educational Technology Research and Development*, 70:363–395, 2022. doi:10.1007/s11423-022-10084-1.