Powtarzane pytania, poprawność odpowiedzi i trwałość błędów: trzyletnia analiza mikrouczenia w organizacji

Bartosz Lewandowski (ORCID:0009-0004-1158-0693)[1,*], Monika Szerszeń (ORCID: 0009-0009-6625-3979)[2], Magdalena Dowgalec (ORCID:0009-0005-4469-2832)[3], Ewaryst Tkacz (ORCID:0000-0003-2580-7954)[4] i Maciej J. Wróbel (ORCID:0000-0003-1865-2122)[5]

[1,4]Department of Clinical Engineering, Academy of Silesia, Katowice, Poland
[3]Banking Process Support and Optimization Department, Powiślański Cooperative Bank, Kwidzyn, Poland
[4]Legal Department, Atende SA, Warsaw, Poland
[5]Department of Otolaryngology and Oncological Laryngology, Collegium Medicum NCU, Toruń, Poland
[*]Autor korespondencyjny: dr inż. Bartosz Lewandowski, bartosz.lewandowski@akademiaslaska.pl

Streszczenie

Wprowadzenie. Przypominanie rozłożone w czasie poprawia zapamiętywanie w warunkach laboratoryjnych i edukacyjnych, jednak skuteczność mikrouczenia w organizacjach rzadko oceniano na podstawie wieloletnich danych o odpowiedziach. Dane rejestrowane przez platformy mikrouczenia pozwalają zweryfikować, czy wiedza sprawdzana przez pytania jest nabywana i utrwalana. **Metody.** Przeanalizowano 60 962 odpowiedzi 187 pracowników banku na 164 pytań wielokrotnego wyboru, udzielonych od kwietnia 2023 do czerwca 2026. Pytania wracały w stałym, nieadaptacyjnym odstępie (mediana 36 dni), a po każdej odpowiedzi wyświetlano poprawną odpowiedź z wyjaśnieniem. Poprawność analizowano w sekwencjach pracownik–pytanie, w kohorcie sekwencji liczących co najmniej 5 prób oraz według wyniku poprzedniej próby i odstępu; przedziały ufności wyznaczono metodą bootstrap. **Wyniki.** Poprawność w pierwszej próbie wynosiła 82,5%. W kohorcie wzrosła z 81,8% do 89,1% (o 7,3 p.p., 95% PU [5,7; 8,9]), a tempo wzrostu nie zależało od wieku pracowników. Wzrost wynikał z przewagi korekt błędów (58,5%) nad zapominaniem (7,4%), przy czym odsetek utrzymanych odpowiedzi poprawnych malał z 95,2% przy odstępie krótszym niż 14 dni do 88,5% przy odstępie co najmniej 240 dni. Szansa korekty malała z każdym kolejnym błędem z rzędu (z 64,5% do 34,2%), a powtórzone błędy w 71,6% przypadków dotyczyły tego samego dystraktora (oczekiwane 59,6%), niezależnie od odstępu. **Wnioski.** Program utrwalał wiedzę sprawdzaną przez pytania, lecz wymagała ona podtrzymywania powtórkami, a część błędnych przekonań opierała się informacji zwrotnej ograniczonej do wyświetlenia poprawnej odpowiedzi. Adaptacyjny harmonogram powtórek i informacja zwrotna odnosząca się do wybranego dystraktora mogą zwiększyć skuteczność takich programów. Dane nie pozwalają odróżnić utrwalenia wiedzy od zapamiętania odpowiedzi na konkretne pytania.

Słowa kluczowe: powtórki rozłożone w czasie; praktyka przypominania; mikrouczenie; szkolenia pracownicze; analityka uczenia się; informacja zwrotna; zapominanie

1 Wprowadzenie

Przypominanie sobie informacji z pamięci wzmacnia ich późniejsze utrwalenie silniej niż ponowne ich przeczytanie (efekt testowania), a nauka rozłożona w czasie jest zapamiętywana lepiej niż nauka skumulowana (efekt rozłożenia w czasie) [3, 4, 17]. W randomizowanych badaniach z udziałem

lekarzy w trakcie kształcenia tzw. edukacja rozłożona w czasie (ang. *spaced education*), w której krótkie pytania wielokrotnego wyboru przesyła się cyklicznie przez tygodnie lub miesiące, poprawiała przyswajanie i utrwalanie wiedzy [8–10].

W szkoleniach organizacyjnych stosuje się *mikrouczenie* (ang. *microlearning*), czyli krótkie jednostki szkoleniowe, często w formie quizów. Dowody jego skuteczności pochodzą jednak głównie z badań na małych próbach lub z tzw. szarej literatury [20], a ewaluacje obowiązkowych szkoleń organizacyjnych, np. z zakresu świadomości bezpieczeństwa, często wykazują efekty niewielkie albo zanikające z upływem czasu [7, 12, 16]. Otwarte pozostaje więc pytanie, czy wiedza sprawdzana w trakcie takich szkoleń jest nabywana i utrwalana.

Skuteczność szkoleń organizacyjnych ocenia się zwykle przez transfer, rozumiany jako zastosowanie nabytej wiedzy i umiejętności w pracy [1, 2]. Warunkiem transferu jest jednak wcześniejsze nabycie i utrwalenie wiedzy, a ten etap można zweryfikować na podstawie danych gromadzonych przez platformy mikrouczenia. Platformy te zapisują każdą odpowiedź wraz z czasem i wynikiem, a to samo pytanie wraca do tego samego pracownika wielokrotnie. Kolejne próby tworzą zatem serię pomiarów tej samej wiedzy u tej samej osoby, co pozwala ocenić, czy poprawność rośnie, czy wiedza utrzymuje się między powtórkami i czy błędy się utrwalają. Dane na poziomie pojedynczych odpowiedzi wykorzystuje się w podobny sposób w modelach ucznia rozwijanych dla inteligentnych systemów tutorskich i aplikacji do nauki języków [5, 11, 15, 18, 19]. W niniejszym badaniu podejście to zastosowano do walidacji wiedzy nabywanej w ramach mikrouczenia w organizacji.

Badanie przeprowadzono w banku, w którym pracownicy odpowiadali na krótkie pytania wielokrotnego wyboru dotyczące wymogów regulacyjnych, produktów bankowych, umiejętności miękkich oraz, w przypadku kadry kierowniczej, zarządzania, wyświetlane przez aplikację na komputerze w trakcie dnia pracy. Pytania wracały do pracownika w stałym, nieadaptacyjnym odstępie, a po każdej odpowiedzi wyświetlano odpowiedź poprawną. Na podstawie analizy odpowiedzi z okresu trzech lat, sformułowano trzy pytania badawcze: (PB1) czy odsetek poprawnych odpowiedzi rośnie wraz z kolejnymi przypomnieniami tego samego pytania przez tego samego pracownika; (PB2) jak poprawność zależy od wyniku poprzedniej próby i od czasu, który od niej upłynął; (PB3) czy powtórzone błędy są trwałe, co wskazywałoby raczej na utrwalone błędne przekonania niż na zgadywanie, mimo informacji zwrotnej po każdej odpowiedzi.

2 Materiał i metody

2.1 Środowisko i program szkoleniowy

Badania prowadzono w siedzibie banku. Polegały one na zadawaniu pracownikom losowo wybranych pytań, pogrupowanych w cztery kategorie: wymogi regulacyjne, produkty bankowe, umiejętności miękkie oraz moduł dla kadry kierowniczej. Każde pytanie było pytaniem wielokrotnego wyboru z trzema do pięciu opcjami odpowiedzi, z których dokładnie jedna była poprawna. Każde pytanie zawierało wyjaśnienie definiujące kontekst poprawnej odpowiedzi. Aplikacja szkoleniowa uruchamiała się automatycznie na ekranach komputerów PC pracowników i wyświetlała od jednego do trzech pytań dziennie w godzinach 10:00–14:00; po każdej odpowiedzi pokazywano poprawną odpowiedź wraz z wyjaśnieniem. To samo pytanie mogło zostać ponownie zadane temu samemu pracownikowi nie wcześniej niż siedem dni po poprzedniej odpowiedzi, a harmonogram powtórek nie zależał od tego, czy odpowiedź była poprawna. Na czas przeglądu i aktualizacji pytań program był zawieszany. O udziale w programie decydował *Wydziału wsparcia i optymalizacji procesów bankowych*, który był również autorem pytań. Pytania prezentowano w modułach tematycznych (mediana 3 zaobserwowanych opcji odpowiedzi na pytanie). W analizowanych danych pracownicy odpowiadali na medianę 3 pytań w dniu aktywności, a to samo pytanie było ponownie zadawane temu samemu pracownikowi

po medianie 36 dni (IQR 18–90).

2.2 Definicje

[Ten rozdział zostanie usunięty w wersji docelowej, a ewentualne definicje zostaną wstawione przy pierwszym użyciu.] W badaniu stosowano następujące definicje:

I. *Sekwencja* to uporządkowana chronologicznie seria prób jednego pracownika dotyczących jednego pytania.

II. *Numer próby* to pozycja odpowiedzi w jej sekwencji; przy jednakowym czasie o kolejności decydował identyfikator rekordu.

III. *Pierwsza próba* to próba o numerze 1, czyli pierwszy kontakt pracownika z danym pytaniem.

IV. *Poprawność* to odsetek poprawnych odpowiedzi.

V. *Odstęp* to czas w dniach od poprzedniej próby w tej samej sekwencji.

VI. *Staż* to czas od pierwszej odpowiedzi pracownika w programie.

VII. *Dystraktor* to błędna opcja odpowiedzi w pytaniu wielokrotnego wyboru.

VIII. *Informacja zwrotna* to wyświetlenie poprawnej odpowiedzi wraz z wyjaśnieniem po każdej udzielonej odpowiedzi, niezależnie od jej poprawności.

IX. *Korekta błędu* to odpowiedź poprawna w próbie następującej bezpośrednio po próbie z odpowiedzią błędną w tej samej sekwencji.

X. *Zapominanie* to odpowiedź błędna w próbie następującej bezpośrednio po próbie z odpowiedzią poprawną w tej samej sekwencji.

XI. *Powtórzony błąd* to odpowiedź błędna w próbie następującej bezpośrednio po próbie z odpowiedzią błędną w tej samej sekwencji.

XII. *Błędy z rzędu* to liczba kolejnych prób zakończonych odpowiedzią błędną, które bezpośrednio poprzedzają daną próbę w tej samej sekwencji.

XIII. *Kohorta* to zbiór sekwencji liczących co najmniej 5 prób, analizowanych wyłącznie w próbach od 1 do 5. Poprawność w każdej z tych prób obliczano dla tych samych sekwencji, co eliminuje wpływ ubywania sekwencji wraz z numerem próby.

XIV. *Bootstrap* to procedura wyznaczania 95-procentowych przedziałów ufności (PU), w której pracowników losowano ze zwracaniem (2000 replikacji), a granice przedziału stanowiły 2,5. i 97,5. percentyl rozkładu statystyki. Losowanie całych pracowników uwzględnia zależność odpowiedzi udzielanych przez tę samą osobę.

2.3 Grupa badana oraz charakterystyka danych

Źródło danych stanowiła lista odpowiedzi zawierająca moduł, pytanie, wybraną opcję, kod odpowiadającego, znacznik czasu oraz poprawność odpowiedzi (wartość logiczna). Zbiór analityczny obejmował 60 962 odpowiedzi (tab. 1). Dane osób odpowiadających przekazano w formie metadanych zawierających płeć pracownika, przedział wiekowy (co 10 lat) oraz medianę wieku.

Tabela 1: Charakterystyka zbioru danych.

Cecha	Wartość
Odpowiedzi	60 962
Pracownicy	187
Pytania	164
Okres obserwacji	2023-04-24 – 2026-06-08
Sekwencje pracownik–pytanie	15 783
Zaobserwowane opcje odpowiedzi na pytanie, mediana (zakres)	3 (2–5)
Odpowiedzi na pracownika, mediana [IQR]	218 [67; 592]
Pytania na pracownika, mediana [IQR]	90 [26; 139]
Dni aktywności na pracownika, mediana [IQR]	84 [28; 220]
Odpowiedzi na dzień aktywności, mediana [IQR]	3 [2; 4]
Miesiące między pierwszą a ostatnią odpowiedzią, mediana [IQR]	18 [5; 30]
Próby w sekwencji, mediana [IQR] (maks.)	3 [2; 5] (19)
Sekwencje z $\geq$2 / $\geq$3 próbami (%)	78,6 / 60,6
Dni między próbami, mediana [IQR]	36 [18; 90]
Odpowiedzi poprawne, ogółem (%)	86,5
Odpowiedzi poprawne, pierwsze próby (%)	82,5

IQR: rozstęp międzykwartylowy. Sekwencja to seria prób jednego pracownika dotyczących jednego pytania. Wykluczone moduły testowe: mnk-tst (212 odpowiedzi). Wykluczone pytania z jedną zaobserwowaną opcją odpowiedzi: 2 (348 odpowiedzi).

Dane demograficzne były dostępne dla 151 z 187 pracowników (80,7%); pozostałych 36 osób nie obejmowało zestawienie demograficzne. Wśród osób o znanej płci kobiety stanowiły 80,1% ($n = 121$), a mężczyźni 19,9% ($n = 30$). Mediana wieku wynosiła 47 lat (IQR 41–56; zakres 22–67), a najliczniejszy przedział wiekowy stanowił 50–59 lat (34,0% osób o znanym wieku, $n = 150$; tab. 2). Wiek uwzględniono w analizie poprawności w pierwszej próbie i tempa jej wzrostu; płci nie uwzględniano w analizach.

Tabela 2: Charakterystyka demograficzna pracowników objętych analizą.

Cecha	Wartość
Pracownicy objęci analizą	187
w tym z danymi demograficznymi, n (%)	151 (80,7)
Kobiety, n (%)	121 (80,1)
Mężczyźni, n (%)	30 (19,9)
Brak danych o płci, n	36
Wiek (lata), mediana [IQR]	47 [41; 56]
Wiek (lata), średnia (SD)	47,2 (10,6)
Wiek (lata), zakres	22–67
20–29 lat, n (%)	13 (8,7)
30–39 lat, n (%)	21 (14,0)
40–49 lat, n (%)	49 (32,7)
50–59 lat, n (%)	51 (34,0)
60–69 lat, n (%)	16 (10,7)
Brak danych o wieku, n	37

Odsetki płci liczono wśród osób o znanej płci, a odsetki przedziałów wieku wśród osób o znanym wieku ($n = 150$). Brak danych dotyczy głównie pracowników nieobecnych w zestawieniu demograficznym (36). IQR: rozstęp międzykwartylowy; SD: odchylenie standardowe.

[Podstawa prawna przetwarzania danych anonimizowanych (wiek, płeć) i podstawa przekazania przez Bank do analizy.]

2.4 Analiza statystyczna

[Rozważam usunięcie całego tego punktu lub wtłoczenia w wyniki. Stąd jest napisany mniejszą czcionką.]

Poprawność podawano z 95% PU wyznaczonymi metodą bootstrap. Analizę podzielono na etap opisu pierwszej próby oraz trzy etapy odpowiadające pytaniom badawczym.

Pierwsza próba. Poprawność w pierwszej próbie porównano między przedziałami wieku. Zależność od wieku oszacowano regresją logistyczną poprawności pierwszej próby względem środka przedziału wieku (na 10 lat), z efektami stałymi pytania uwzględniającymi różnice trudności pytań i z błędami standardowymi klastrowanymi względem pracowników.

Zmiany w sekwencji (PB1). Poprawność obliczono dla kolejnych numerów prób we wszystkich sekwencjach; próby 10. i dalsze połączono. Pracownicy kontynuujący sekwencje mogą różnić się od tych, którzy je kończą, a krzywe zagregowane mogą być wówczas zniekształcone przez ubywanie sekwencji [6, 13]. Zmianę oceniono więc także w kohorcie, jako różnicę poprawności między próbą 5 a próbą 1 wyrażoną w punktach procentowych (p.p.). Zależność odsetka błędów od numeru próby opisano funkcją potęgową [14], dopasowaną ważoną metodą najmniejszych kwadratów w skali logarytmicznej. Zależność tempa wzrostu od wieku sprawdzono w kohorcie regresją logistyczną poprawności względem $\log_2$ numeru próby i jego interakcji z wiekiem, z efektami stałymi pracownika i pytania oraz błędami standardowymi klastrowanymi względem pracowników. Pracowników i pytania bez zmienności poprawności usuwano przed estymacją, ponieważ ich efekty stałe nie są identyfikowalne.

Wynik poprzedniej próby i odstęp (PB2). Każdą próbę od drugiej wzwyż zaklasyfikowano jako odpowiedź poprawną po poprawnej, korektę błędu, zapominanie albo powtórzony błąd, a odsetki przejść porównano w sześciu przedziałach odstępu, od krótszego niż 14 dni do co najmniej 240 dni. Ponieważ harmonogram powtórek nie był adaptacyjny, sprawdzono, czy prawdopodobieństwo ponownego zadania pytania i odstęp zależały od wyniku poprzedniej próby.

Utrwalone błędy (PB3). Poprawność porównano według liczby błędów z rzędu, od 0 do co najmniej 4. W parach dwóch kolejnych błędów odsetek ponownych wyborów tego samego dystraktora porównano z odsetkiem oczekiwanym przy losowym wyborze spośród zaobserwowanych dystraktorów oraz przy wyborze proporcjonalnym do popularności dystraktorów w danym pytaniu, a następnie zestawiono go w trzech przedziałach odstępu. Koncentrację powtórzonych błędów opisano udziałem 10% pytań o największej liczbie takich błędów.

Obliczenia wykonano w języku Python 3.14.4 z użyciem bibliotek pandas 2.3.3, NumPy 2.3.5, SciPy 1.16.3, statsmodels 0.14.6 i Matplotlib 3.10.7.

3 Wyniki

W pierwszych próbach, czyli przy pierwszym kontakcie pracownika z danym pytaniem, zarejestrowano 15 783 odpowiedzi 187 pracowników. Poprawność wynosiła 82,5% (95% PU [81,0; 83,9]; tab. 3). W przedziałach wieku mieściła się w zakresie od 75,0% (30–39 lat) do 84,1% (50–59 lat), a przedziały ufności w grupach o mniejszej liczbie pracowników były szerokie. Po uwzględnieniu trudności pytań szanse poprawnej odpowiedzi w pierwszej próbie rosły wraz z wiekiem (OR 1,16 na 10 lat, 95% PU [1,03; 1,30]; $p = 0{,}015$). Zależność ta nie miała jednak charakteru monotonicznego, ponieważ najniższą poprawność odnotowano w przedziale 30–39 lat, a nie w przedziale najmłodszym.

Tabela 3: Poprawność w pierwszej próbie ogółem i według przedziału wieku pracownika.

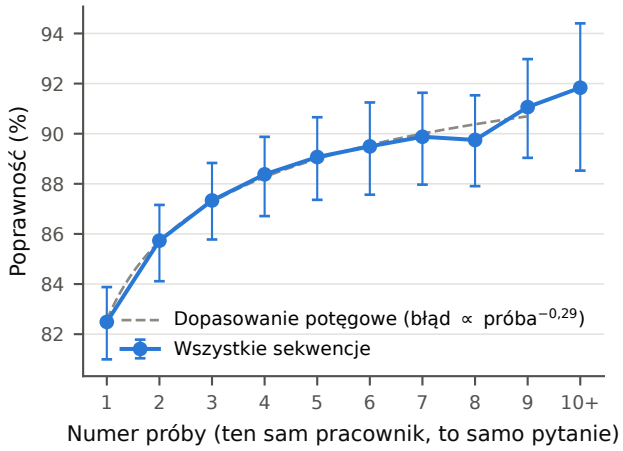
Przedział wieku (lata)	Ogółem	20–29	30–39	40–49	50–59	60–69	Brak danych
Pracownicy	187	13	21	49	51	16	37
Pierwsze próby, n	15 783	970	2037	4428	5191	1487	1670
Poprawność (%)	82,5	82,5	75,0	83,9	84,1	82,3	82,8
95% PU	[81,0; 83,9]	[77,4; 89,0]	[68,3; 81,0]	[81,4; 86,3]	[82,1; 86,2]	[78,4; 86,0]	[79,7; 85,8]

Pierwsza próba to pierwsza odpowiedź w sekwencji. 95% PU wyznaczono metodą bootstrap. Zależność od wieku oszacowano regresją logistyczną poprawności pierwszej próby względem środka przedziału wieku (na 10 lat) z efektami stałymi pytania i błędami standardowymi klastrowanymi względem pracowników (13 860 odpowiedzi 150 pracowników o znanym wieku): OR 1,16, 95% PU [1,03; 1,30], $p = 0{,}015$.

3.1 Zmiany w sekwencji (PB1)

Poprawność rosła wraz z numerem próby: z 82,5% [81,0; 83,9] w pierwszej próbie do 91,8% [88,5; 94,4] w próbie 10. i kolejnych (rys. 1). Liczba sekwencji malała jednak wraz z numerem próby, dlatego zmianę oceniono również w kohorcie 5187 sekwencji. W kohorcie poprawność wzrosła z 81,8% [79,7; 83,8] w próbie 1 do 89,1% [87,3; 90,6] w próbie 5, czyli o 7,3 p.p. (95% PU [5,7; 8,9]; tab. 4). Wzrost obserwowany w tych samych sekwencjach wskazuje, że poprawa nie wynika z wcześniejszego kończenia sekwencji z niższą poprawnością. Odsetek błędów był funkcją potęgową numeru próby (wykładnik 0,29, $R^2 = 0{,}98$), zgodnie z potęgowym prawem praktyki [14].

Wzrost poprawności w kohorcie wystąpił we wszystkich przedziałach wieku i wynosił od 4,8 p.p. (60–69 lat) do 9,0 p.p. (40–49 lat; tab. 4). Tempo poprawy nie zależało od wieku: iloraz szans dla interakcji numeru próby z wiekiem wynosił 0,98 na 10 lat (95% PU [0,91; 1,05]; $p = 0{,}551$). Różnice między przedziałami wieku dotyczyły zatem raczej poziomu wyjściowego niż przyrostu poprawności w kolejnych próbach.



Rysunek 1: Poprawność według numeru próby we wszystkich sekwencjach dostępnych w danej próbie (ich liczba maleje wraz z numerem próby). Słupki błędów: 95% PU (bootstrap). Linia przerywana: dopasowanie funkcji potęgowej do odsetka błędów. Próby 10. i dalsze połączono. Przebieg w kohorcie przedstawiono na rys. 3.

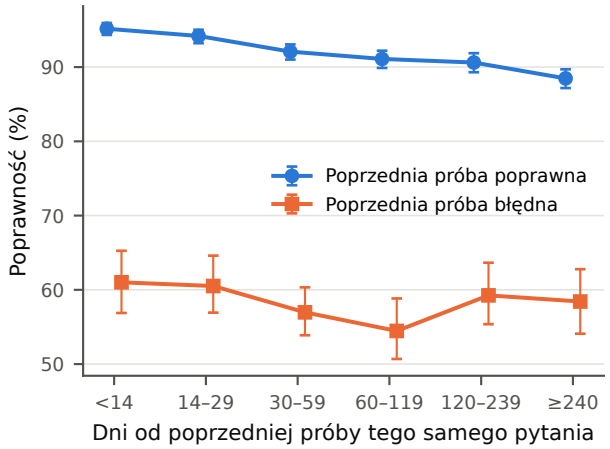
Tabela 4: Poprawność w kolejnych próbach w kohorcie, ogółem i według przedziału wieku pracownika.

Przedział wieku (lata)	Ogółem	20–29	30–39	40–49	50–59	60–69	Brak danych
Pracownicy	129	9	15	35	40	13	17
Sekwencje, n	5187	199	687	1865	1745	521	170
Próba 1 (%)	81,8	81,4	77,0	81,6	83,6	81,6	86,5
Próba 2 (%)	85,8	80,4	79,5	86,0	87,8	86,9	91,8
Próba 3 (%)	87,2	84,9	82,0	88,5	88,1	85,2	94,7
Próba 4 (%)	88,3	88,9	82,1	89,3	89,8	85,8	94,7
Próba 5 (%)	89,1	86,9	83,8	90,5	90,1	86,4	94,7
Zmiana, próba 5 wobec 1 (p.p.)	7,3	5,5	6,8	9,0	6,5	4,8	8,2
95% PU	[5,7; 8,9]	[0,0; 14,9]	[2,4; 12,8]	[6,0; 11,8]	[4,5; 8,3]	[0,5; 10,0]	[3,3; 14,2]

Kohorta: sekwencje liczące co najmniej 5 prób, próby od 1 do 5. p.p.: punkty procentowe; 95% PU zmiany wyznaczono metodą bootstrap. Zależność tempa poprawy od wieku oszacowano regresją logistyczną poprawności względem $\log_2$(numer próby) i jego interakcji z wiekiem (środek przedziału, na 10 lat), z efektami stałymi pracownika i pytania oraz błędami standardowymi klastrowanymi względem pracowników (24 180 odpowiedzi pracowników o znanym wieku).

3.2 Wynik poprzedniej próby, odstęp i zapominanie (PB2)

Wzrost poprawności opisany w PB1 jest wynikiem netto dwóch procesów zachodzących między kolejnymi próbami: korygowania błędów i zapominania odpowiedzi poprawnych. Aby je rozdzielić, każdą próbę od drugiej wzwyż powiązano z wynikiem próby poprzedniej i odstępem od niej. Harmonogram powtórek nie zniekształcał tego porównania, ponieważ pytanie wracało po odpowiedzi poprawnej i błędnej z podobnym prawdopodobieństwem (74,0% i 74,7%) i po podobnym odstępie (mediana 36 i 38 dni). Odpowiedź poprawna powtórzyła się w kolejnej próbie w 92,6% [91,7; 93,3] przypadków, a odpowiedź błędna została skorygowana w 58,5% [55,7; 61,3] (tab. 5). Korekty błędów przeważały zatem nad zapominaniem (7,4%), co tłumaczy przyrost poprawności w kolejnych próbach. Upływ czasu działał w przeciwnym kierunku, lecz tylko w odniesieniu do odpowiedzi poprawnych: odsetek ich powtórzeń malał z 95,2% przy odstępie krótszym niż 14 dni do 88,5% przy odstępie wynoszącym co najmniej 240 dni, podczas gdy odsetek skorygowanych błędów nie wykazywał wyraźnego trendu (61,0% i 58,4% w tych samych przedziałach; rys. 2). Wiedza potwierdzona poprawną odpowiedzią podlegała więc zapominaniu między powtórkami [3, 4], natomiast szansa skorygowania błędu po informacji zwrotnej nie zależała od czasu, który upłynął do kolejnego kontaktu z pytaniem.



Rysunek 2: Poprawność według odstępu, osobno dla prób poprzedzonych odpowiedzią poprawną (koła) i błędną (kwadraty). Słupki błędów: 95% PU (bootstrap).

Tabela 5: Przejścia między kolejnymi próbami tego samego pytania.

Poprzednia próba	n	Kolejna poprawna (%)	95% PU	Kolejna błędna (%)
Poprawna	39 038	92,6	[91,7; 93,3]	7,4
Błędna	6141	58,5	[55,7; 61,3]	41,5

Próby od drugiej wzwyż według wyniku próby poprzedniej. 95% PU wyznaczono metodą bootstrap.

3.3 Utrwalone błędy (PB3)

Większość błędów miała charakter przejściowy: w 82,1% z 2170 sekwencji rozpoczętych odpowiedzią błędną pracownik odpowiedział poprawnie w którejś z kolejnych prób. Szansa korekty malała jednak z każdym kolejnym błędem. Po jednym błędzie poprawność wynosiła 64,5% [62,3; 66,8], po dwóch błędach z rzędu 49,0%, po trzech 41,9%, a po co najmniej 4 błędach 34,2% [27,9; 41,1] (tab. 6). Każde kolejne wyświetlenie poprawnej odpowiedzi przynosiło więc mniejszy efekt. Spadek ten może częściowo wynikać z tego, że wiele błędów z rzędu występowało w trudniejszych pytaniach, nie musi zatem w całości odzwierciedlać utrwalania się błędu.

O naturze powtórzonych błędów świadczy wybór dystraktora. Gdy pracownik pomylił się w dwóch kolejnych próbach, w 71,6% [69,4; 73,8] przypadków ($n = 2546$) wskazał ten sam dystraktor, wobec 47,1% oczekiwanych przy wyborze losowym i 59,6% oczekiwanych przy uwzględnieniu popularności poszczególnych dystraktorów w danym pytaniu. Powtórzony błąd był zatem wyborem konkretnej odpowiedzi, a nie zgadywaniem. Tendencja ta nie słabła z upływem czasu: do tego samego dystraktora wracano w 70,4% przypadków przy odstępie krótszym niż 30 dni, w 73,4% przy odstępie od 30 do 89 dni i w 71,1% przy odstępie wynoszącym co najmniej 90 dni. Powtórzone błędy skupiały się przy tym w niewielkiej części materiału, ponieważ na 15 spośród 146 pytań, w których wystąpiły, przypadało 41,4% wszystkich powtórzonych błędów.

Zestawienie wyników PB2 i PB3 ujawnia asymetrię. Odpowiedzi poprawne słabły wraz z odstępem, natomiast błędne przekonanie, które przetrwało pierwszą korektę, utrzymywało się niezależnie od upływu czasu i w coraz mniejszym stopniu ulegało informacji zwrotnej. Wyświetlenie poprawnej odpowiedzi wystarczało do skorygowania większości błędów, ale nie usuwało przyczyny, dla której pracownik wybierał określony dystraktor.

Tabela 6: Poprawność według liczby błędów popełnionych z rzędu bezpośrednio przed daną próbą.

Błędy z rzędu przed próbą	0	1	2	3	≥4
Próby, n	39 038	4262	1142	427	310
Pracownicy	160	151	115	80	48
Poprawność (%)	92,6	64,5	49,0	41,9	34,2
95% PU	[91,8; 93,3]	[62,3; 66,8]	[45,7; 52,7]	[36,6; 47,6]	[27,9; 41,1]

Próby od drugiej wzwyż. Kolumna 0: próby poprzedzone odpowiedzią poprawną. 95% PU wyznaczono metodą bootstrap.

3.4 Podsumowanie wyników

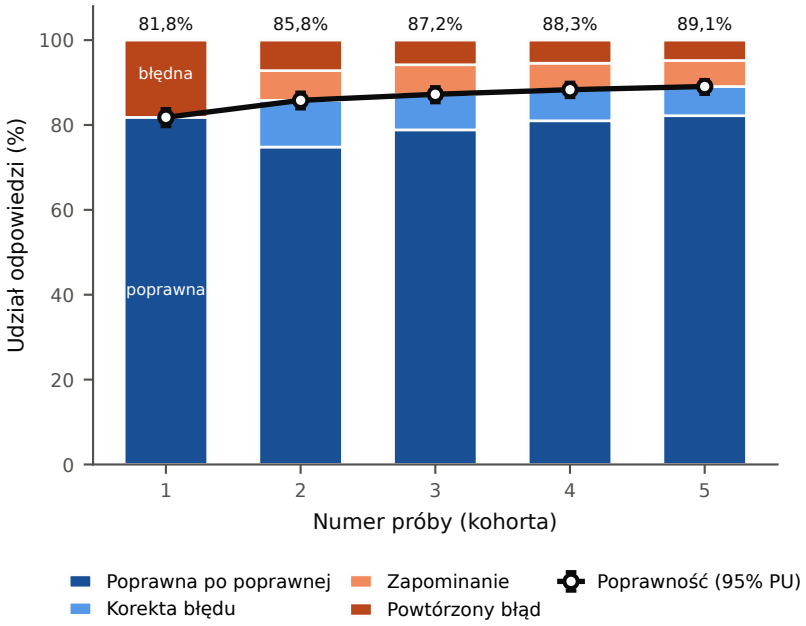
Wyniki pozwalają odpowiedzieć na trzy pytania badawcze.

(PB1) Poprawność rosła wraz z numerem próby, również w kohorcie, w której zwiększyła się o 7,3 p.p. między próbą 1 a próbą 5. Przyrost nie zależał od wieku pracownika, a wiek wiązał się jedynie z poprawnością w pierwszej próbie.

(PB2) Przyrost poprawności wynikał z przewagi korekt błędów (58,5%) nad zapominaniem (7,4%). Zapominanie nasilało się wraz z odstępem, natomiast odsetek korekt błędów od odstępu nie zależał.

(PB3) Większość błędów korygowano (82,1% sekwencji rozpoczętych odpowiedzią błędną), lecz powtórzone błędy polegały na wyborze tego samego dystraktora (71,6%), nie słabły wraz z odstępem, a szansa ich korekty malała z każdym kolejnym błędem z rzędu, do 34,2% po co najmniej 4 błędach.

Łącznie wyniki wskazują, że program utrwalał wiedzę sprawdzaną przez pytania, przy czym wiedza ta wymagała podtrzymywania kolejnymi powtórkami, a niewielka część pytań generowała błędy odporne na informację zwrotną ograniczoną do wyświetlenia poprawnej odpowiedzi. Rys. 3 zestawia te wyniki w kohorcie: linia poprawności rośnie (PB1), korekty błędów przeważają nad zapominaniem (PB2), a powtórzone błędy utrzymują się we wszystkich kolejnych próbach (PB3).



Rysunek 3: Poprawność i stan odpowiedzi w kohorcie (5187 sekwencji, próby od 1 do 5). Słupki: udział odpowiedzi według wyniku bieżącej i poprzedniej próby (definicje IX–XI w podrozdziale 2.2); w próbie 1 tylko odpowiedzi poprawne i błędne. Linia: poprawność z 95% PU (bootstrap), wartości nad słupkami.

4 Dyskusja

[DOPISAĆ po akceptacji treści - metodologia i wyniki]

Oświadczenia

Etyka. W badaniu wykorzystano dane przekazane przez bank, w których pracownicy byli reprezentowani przez kody. Dane dotyczące wieku i płci raportowano wyłącznie w postaci zagregowanej. [Informacja o zgodzie banku i warunkach przekazania (chociaż jest o tym wzmianka w metodologii).]
Dostępność danych. Dane wykorzystane w badaniu stanowią własność banku i nie są udostępniane publicznie.
Finansowanie. Badanie nie otrzymało finansowania.
Konflikt interesów. Autorzy deklarują brak konfliktu interesów.

Literatura

[1] Timothy T. Baldwin and J. Kevin Ford. Transfer of training: a review and directions for future research. *Personnel Psychology*, 41(1):63–105, 1988. doi:10.1111/j.1744-6570.1988.tb00632.x.

[2] Brian D. Blume, J. Kevin Ford, Timothy T. Baldwin, and Jason L. Huang. Transfer of training: a meta-analytic review. *Journal of Management*, 36(4):1065–1105, 2010. doi:10.1177/0149206309352880.

[3] Nicholas J. Cepeda, Harold Pashler, Edward Vul, John T. Wixted, and Doug Rohrer. Distributed practice in verbal recall tasks: a review and quantitative synthesis. *Psychological Bulletin*, 132(3):354–380, 2006. doi:10.1037/0033-2909.132.3.354.

[4] Nicholas J. Cepeda, Edward Vul, Doug Rohrer, John T. Wixted, and Harold Pashler. Spacing effects in learning: a temporal ridgeline of optimal retention. *Psychological Science*, 19(11): 1095–1102, 2008. doi:10.1111/j.1467-9280.2008.02209.x.

[5] Albert T. Corbett and John R. Anderson. Knowledge tracing: modeling the acquisition of procedural knowledge. *User Modeling and User-Adapted Interaction*, 4:253–278, 1994. doi:10.1007/BF01099821.

[6] Cyril Goutte, Guillaume Durand, and Serge Léger. On the learning curve attrition bias in additive factor modeling. In *Artificial Intelligence in Education (AIED 2018)*, LNCS, 2018. doi:10.1007/978-3-319-93846-2_21.

[7] Grant Ho, Ariana Mirian, Elisa Luo, Khang Tong, Euyhyun Lee, Lin Liu, Christopher A. Longhurst, Christian Dameff, Stefan Savage, and Geoffrey M. Voelker. Understanding the efficacy of phishing training in practice. In *2025 IEEE Symposium on Security and Privacy (SP)*, pages 37–54, 2025. doi:10.1109/sp61157.2025.00076.

[8] B. Price Kerfoot. Learning benefits of on-line spaced education persist for 2 years. *Journal of Urology*, 181(6):2671–2673, 2009. doi:10.1016/j.juro.2009.02.024.

[9] B. Price Kerfoot, Harley E. Baker, Michael O. Koch, David Connelly, David B. Joseph, and Michael L. Ritchey. Randomized, controlled trial of spaced education to urology residents in the United States and Canada. *Journal of Urology*, 177(4):1481–1487, 2007. doi:10.1016/j.juro.2006.11.074.

[10] B. Price Kerfoot, William C. DeWolf, Barbara A. Masser, Paul A. Church, and Daniel D. Federman. Spaced education improves the retention of clinical knowledge by medical students: a randomised controlled trial. *Medical Education*, 41(1):23–31, 2007. doi:10.1111/j.1365-2929.2006.02644.x.

[11] Kenneth R. Koedinger, Paulo F. Carvalho, Ran Liu, and Elizabeth A. McLaughlin. An astonishing regularity in student learning rate. *Proceedings of the National Academy of Sciences*, 120 (13):e2221311120, 2023. doi:10.1073/pnas.2221311120.

[12] Daniele Lain, Kari Kostiainen, and Srdjan Čapkun. Phishing in organizations: findings from a large-scale and long-term study. In *2022 IEEE Symposium on Security and Privacy (SP)*, pages 842–859, 2022. doi:10.1109/sp46214.2022.9833766.

[13] R. Charles Murray, Steven Ritter, Tristan Nixon, Ryan Schwiebert, Robert G. M. Hausmann, Brendon Towle, Stephen E. Fancsali, and Annalies Vuong. Revealing the learning in learning curves. In *Artificial Intelligence in Education (AIED 2013)*, volume 7926 of *LNCS*, pages 473–482, 2013. doi:10.1007/978-3-642-39112-5_48.

[14] Allen Newell and Paul S. Rosenbloom. Mechanisms of skill acquisition and the law of practice. In John R. Anderson, editor, *Cognitive Skills and Their Acquisition*, pages 1–55. Lawrence Erlbaum, Hillsdale, NJ, 1981.

[15] Philip I. Pavlik, Hao Cen, and Kenneth R. Koedinger. Performance factors analysis - a new alternative to knowledge tracing. In *Artificial Intelligence in Education (AIED 2009)*, volume 200 of *Frontiers in Artificial Intelligence and Applications*, pages 531–538. IOS Press, 2009. doi:10.3233/978-1-60750-028-5-531.

[16] Benjamin Reinheimer, Lina Aldag, Peter Mayer, Mattia Mossano, Reyhan Duezguen, Bettina Lofthouse, Tatiana von Landesberger, and Melanie Volkamer. An investigation of phishing awareness and education over time: when and how to best remind users. In *Sixteenth Symposium on Usable Privacy and Security (SOUPS 2020)*. USENIX Association, 2020.

[17] Henry L. Roediger and Jeffrey D. Karpicke. Test-enhanced learning: taking memory tests improves long-term retention. *Psychological Science*, 17(3):249–255, 2006. doi:10.1111/j.1467-9280.2006.01693.x.

[18] Burr Settles and Brendan Meeder. A trainable spaced repetition model for language learning. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics*, pages 1848–1858, 2016. URL `https://aclanthology.org/P16-1174`.

[19] Behzad Tabibian, Utkarsh Upadhyay, Abir De, Ali Zarezade, Bernhard Schölkopf, and Manuel Gomez-Rodriguez. Enhancing human learning via spaced repetition optimization. *Proceedings of the National Academy of Sciences*, 116(10):3988–3993, 2019. doi:10.1073/pnas.1815156116.

[20] Allison D. Taylor and Woei Hung. The effects of microlearning: a scoping review. *Educational Technology Research and Development*, 70:363–395, 2022. doi:10.1007/s11423-022-10084-1.