Poprawność odpowiedzi pracowników w powtarzanych pytaniach: zapominanie i utrwalone błędy w trzyletnim programie mikrouczenia

Bartosz Lewandowski (ORCID:0009-0004-1158-0693)[1,*], Monika Szerszeń (ORCID: 0009-0009-6625-3979)[2], Magdalena Dowgalec (ORCID:0009-0005-4469-2832)[3], Ewaryst Tkacz (ORCID:0000-0003-2580-7954)[4] i Maciej J. Wróbel (ORCID:0000-0003-1865-2122)[5]

[1,4]Department of Clinical Engineering, Academy of Silesia, Katowice, Poland
[2]Banking Process Support and Optimization Department, Powiślański Cooperative Bank, Kwidzyn, Poland
[3]Legal Department, Atende SA, Warsaw, Poland
[5]Department of Otolaryngology and Oncological Laryngology, Collegium Medicum NCU, Toruń, Poland
[*]Autor korespondencyjny: dr inż. Bartosz Lewandowski, bartosz.lewandowski@akademiaslaska.pl

Streszczenie

Wprowadzenie. Powtórki rozłożone w czasie poprawiają zapamiętywanie, jednak skuteczność mikrouczenia w organizacjach rzadko oceniano na podstawie wieloletnich danych o odpowiedziach pracowników. **Metody.** Przeanalizowano 57 997 odpowiedzi 180 pracowników banku na 164 pytania wielokrotnego wyboru, udzielonych od maja 2023 do czerwca 2026. Pytania wracały według harmonogramu niezależnego od wyniku odpowiedzi (mediana odstępu 37 dni), a po każdej odpowiedzi wyświetlano poprawną odpowiedź z wyjaśnieniem. Poprawność analizowano w kolejnych próbach tego samego pytania oraz według wyniku poprzedniej próby i odstępu. **Wyniki.** Poprawność w pierwszej próbie wynosiła 82,6%. W sekwencjach liczących co najmniej 5 prób wzrosła z 81,9% do 89,0% (o 7,2 p.p., 95% PU [5,5; 8,9]). Korekt błędów było więcej niż przypadków zapominania (3382 wobec 2719). Odsetek zapominania rósł wraz z odstępem i malał wraz z liczbą poprawnych odpowiedzi z rzędu, z 11,9% po jednej do 3,2% po co najmniej 4. Powtórzone błędy w 71,8% przypadków dotyczyły tego samego dystraktora (oczekiwane przy wyborze zgodnym z popularnością dystraktorów 60,0%), niezależnie od odstępu. **Wnioski.** Poprawność odpowiedzi na powracające pytania rosła, lecz wiedza wymagała dalszych powtórek, a część błędów utrzymywała się mimo informacji zwrotnej. Harmonogram dopasowany do wyników pracownika i informacja zwrotna odnosząca się do wybranego dystraktora mogą zwiększyć skuteczność takich programów.

Słowa kluczowe: powtórki rozłożone w czasie; mikrouczenie; szkolenia pracownicze; informacja zwrotna; zapominanie; analityka uczenia się

1 Wprowadzenie

Przypominanie informacji z pamięci utrwala je silniej niż ponowne czytanie (efekt testowania), a nauka rozłożona w czasie jest trwalsza niż nauka skumulowana (efekt rozłożenia w czasie) [4, 13]. Oba efekty łączy edukacja rozłożona w czasie (ang. *spaced education*), w której krótkie pytania wielokrotnego wyboru wracają cyklicznie przez tygodnie lub miesiące. W badaniach z udziałem lekarzy i innych pracowników ochrony zdrowia poprawiała ona przyswajanie i utrwalanie wiedzy [7, 10].

W organizacjach podobną formę ma *mikrouczenie* (ang. *microlearning*), czyli krótkie jednostki szkoleniowe, często w formie quizów. Dowody jego skuteczności pochodzą jednak głównie z badań na małych próbach i z tzw. szarej literatury [16], a efekty obowiązkowych szkoleń pracowniczych, np. z bezpieczeństwa informacji, bywają niewielkie lub zanikają z czasem [12]. Skuteczność szkoleń ocenia się zwykle przez transfer, czyli zastosowanie wiedzy w pracy [1]. Transfer wymaga jednak, aby wiedza została najpierw nabyta i utrwalona.

Ten wcześniejszy etap można sprawdzić na danych z platform mikrouczenia. Platforma zapisuje każdą odpowiedź wraz z czasem i wynikiem, a to samo pytanie wraca do tego samego pracownika wielokrotnie. Kolejne odpowiedzi stanowią więc powtarzane pomiary tej samej wiedzy u tej samej osoby. Podobne dane wykorzystuje się w modelach ucznia, stosowanych w systemach tutorskich i aplikacjach do nauki języków [5, 14].

Badanie przeprowadzono w banku, w którym pracownicy odpowiadali na krótkie pytania wyświetlane na komputerze w trakcie dnia pracy, a system gromadził odpowiedzi przez trzy lata. Pytania wracały według harmonogramu niezależnego od wyniku odpowiedzi, a po każdej odpowiedzi wyświetlano odpowiedź poprawną. Taki harmonogram pozwala porównać korekty błędów i zapominanie bez selekcji, którą wprowadzają algorytmy adaptacyjne, co w danych z platform szkoleniowych występuje rzadko. Badania laboratoryjne wskazują ponadto, że wybrany dystraktor może utrwalić się w pamięci, a błędy popełnione z wysoką pewnością mogą powracać mimo informacji zwrotnej [2, 3]. Nie wiadomo, czy zjawisko to występuje w szkoleniach pracowniczych. Sformułowano trzy pytania badawcze: (PB1) czy odsetek poprawnych odpowiedzi rośnie, gdy to samo pytanie wraca do tego samego pracownika; (PB2) jak poprawność zależy od wyniku poprzedniej próby i od czasu, który od niej upłynął; (PB3) czy powtórzone błędy utrzymują się mimo informacji zwrotnej, co wskazywałoby raczej na błędne przekonania niż na zgadywanie.

2 Materiał i metody

2.1 Program szkoleniowy

Badanie przeprowadzono w banku. Pytania przygotował *Wydział wsparcia i optymalizacji procesów bankowych*, który decydował również o udziale pracowników w programie. Pytania dotyczyły wiedzy wykorzystywanej w codziennej pracy w banku. Każde było pytaniem wielokrotnego wyboru z trzema do pięciu opcjami odpowiedzi, z których jedna była poprawna, a pozostałe stanowiły *dystraktory*. Pytania, opcje odpowiedzi i wyjaśnienia sformułowano w języku polskim. Przykładowe pytanie z zakresu cyberbezpieczeństwa brzmiało: „Która z poniższych sytuacji jest phishingiem?”. Opcje odpowiedzi: „1 - Atak typu DDoS”, „2 - Instalacja oprogramowania antywirusowego”, „3 - Tworzenie kopii zapasowych danych”, „4 - Fałszywy e-mail z linkiem do strony logowania banku (oznaczona jako odpowiedź poprawna)”. Wyjaśnienie wyświetlane po odpowiedzi: „Phishing to metoda oszustwa, w której ktoś podszywa się pod zaufaną osobę lub instytucję (np. bank, kuriera, urząd), żeby wyłudzić od Ciebie poufne dane, takie jak hasła, numery kart czy loginy. Najczęściej wygląda to jak e-mail z "banku"z pilną prośbą o zalogowanie, SMS z linkiem do "dopłaty za paczkę"albo fałszywa strona łudząco podobna do prawdziwej. Kluczowy mechanizm polega na tym, że oszust wywołuje pośpiech lub stres, żebyś kliknął/a bez zastanowienia. WAŻNE: nie klikaj w podejrzane linki, zawsze sprawdzaj adres strony (URL), nie podawaj danych logowania przez link z wiadomości, a jeśli coś wygląda na "zbyt pilne", to często oszustwo.”.

Aplikacja szkoleniowa uruchamiała się automatycznie w dni robocze na komputerach pracowników i wyświetlała od jednego do czterech losowo wybranych pytań dziennie, w godzinach 9:00–16:00. Po każdej odpowiedzi, poprawnej lub błędnej, pokazywała poprawną odpowiedź z wyjaśnieniem (*informacja zwrotna*). To samo pytanie mogło wrócić do pracownika najwcześniej po siedmiu dniach,

a harmonogram powtórek nie zależał od wyniku odpowiedzi. Na czas przeglądu i aktualizacji pytań program zawieszano. W analizowanych danych mediana liczby odpowiedzi pracownika w dniu aktywności wynosiła 3 (IQR 2–4). To samo pytanie wracało po medianie 37 dni (IQR 18–90).

2.2 Dane i grupa badana

Analizowano zarejestrowane odpowiedzi pracowników. Każdy rekord zawierał pytanie, wybraną opcję, kod pracownika, datę i godzinę odpowiedzi oraz informację, czy odpowiedź była poprawna. Zbiór analityczny liczył 57 997 odpowiedzi (tab. 1). Bank przekazał ponadto zestawienie wieku i płci pracowników.

Tabela 1: Charakterystyka zbioru danych.

Cecha	Wartość
Odpowiedzi	57 997
Pracownicy	180
Pytania	164
Okres obserwacji	2023-05-10 – 2026-06-08
Sekwencje pracownik–pytanie	15 270
Zaobserwowane opcje odpowiedzi na pytanie, mediana (zakres)	3 (2–5)
Odpowiedzi na pracownika, mediana [IQR]	195 [70; 575]
Pytania na pracownika, mediana [IQR]	86 [38; 138]
Dni aktywności na pracownika, mediana [IQR]	84 [30; 224]
Odpowiedzi na dzień aktywności, mediana [IQR]	3 [2; 4]
Miesiące między pierwszą a ostatnią odpowiedzią, mediana [IQR]	18 [5; 30]
Próby w sekwencji, mediana [IQR] (maks.)	3 [2; 5] (17)
Sekwencje z $\geq$2 / $\geq$3 próbami (%)	78,1 / 59,8
Dni między próbami, mediana [IQR]	37 [18; 90]
Odpowiedzi poprawne, ogółem (%)	86,6
Odpowiedzi poprawne, pierwsze próby (%)	82,6

IQR: rozstęp międzykwartylowy. Sekwencja to seria prób jednego pracownika dotyczących jednego pytania. Liczba zaobserwowanych opcji odpowiedzi bywa mniejsza niż liczba opcji w pytaniu, ponieważ części opcji nie wybrał żaden pracownik. Wykluczone odpowiedzi testowe: 212. Wykluczone pytania z jedną zaobserwowaną opcją odpowiedzi: 2 (348 odpowiedzi). Wykluczone powtórki udzielone wcześniej niż po 7 dniach: 88.

Dane demograficzne były dostępne dla 151 ze 180 pracowników (83,9%). Kobiety stanowiły 80,1% osób o znanej płci ($n = 121$). Mediana wieku wynosiła 47 lat (IQR 41–56; zakres 22–67), a najliczniejszy był przedział 50–59 lat (34,0%; tab. 2). Wiek uwzględniono w analizie pierwszej próby i tempa wzrostu poprawności; płci nie analizowano.

Tabela 2: Charakterystyka demograficzna pracowników objętych analizą.

Cecha	Wartość
Pracownicy objęci analizą	180
w tym z danymi demograficznymi, n (%)	151 (83,9)
Kobiety, n (%)	121 (80,1)
Mężczyźni, n (%)	30 (19,9)
Brak danych o płci, n	29
Wiek (lata), mediana [IQR]	47 [41; 56]
Wiek (lata), średnia (SD)	47,2 (10,6)
Wiek (lata), zakres	22–67
20–29 lat, n (%)	13 (8,7)
30–39 lat, n (%)	21 (14,0)
40–49 lat, n (%)	49 (32,7)
50–59 lat, n (%)	51 (34,0)
60–69 lat, n (%)	16 (10,7)
Brak danych o wieku, n	30

Odsetki płci liczono wśród osób o znanej płci, a odsetki przedziałów wieku wśród osób o znanym wieku ($n = 150$). Brak danych dotyczy głównie pracowników nieobecnych w zestawieniu demograficznym (29). IQR: rozstęp międzykwartylowy; SD: odchylenie standardowe.

W bazie danych odpowiedzi, pracowników oznaczono losowym kodem, a zestawienie demograficzne połączono z zarejestrowanymi odpowiedziami według tego kodu. Tego rodzaju kodu nie można odtworzyć przy znajomości listy pracowników, dlatego analizowane dane stanowiły dane w pełni zanonimizowane.

2.3 Analiza statystyczna

Odpowiedzi jednego pracownika na jedno pytanie, uporządkowane w czasie, tworzyły *sekwencję*. Pozycję odpowiedzi w sekwencji nazwano *numerem próby*, a pierwszą odpowiedź, czyli pierwszy kontakt pracownika z pytaniem, *pierwszą próbą*. *Odstęp* oznaczał liczbę dni od poprzedniej próby w tej samej sekwencji, a *poprawność* odsetek poprawnych odpowiedzi. Poprawność podawano z 95-procentowymi przedziałami ufności (PU) wyznaczonymi metodą bootstrap: pracowników losowano ze zwracaniem (2000 replikacji), co uwzględnia zależność odpowiedzi udzielanych przez tę samą osobę. W modelach regresji błędy standardowe klastrowano względem pracowników.

Pierwsza próba. Poprawność w pierwszej próbie porównano między przedziałami wieku. Zależność od wieku (podział grup po 10 lat) oszacowano regresją logistyczną z efektami stałymi pytania, czyli z osobnym wyrazem wolnym dla każdego pytania. Trudność pytań nie była oznaczona w danych, dlatego efekty stałe szacowano z odpowiedzi wszystkich pracowników. Model porównywał więc pracowników w różnym wieku odpowiadających na te same pytania. Dla porównania dopasowano go również bez efektów stałych pytania.

Zmiany w sekwencji (PB1). Poprawność obliczono dla kolejnych numerów prób; próby 10 i dalsze połączono. Z każdą próbą ubywało sekwencji, a pracownicy kontynuujący odpowiedzi mogli różnić się od pozostałych, co zniekształca krzywe zagregowane [9]. Zmianę oceniono więc także w *kohorcie*, czyli w sekwencjach liczących co najmniej 5 prób, ograniczonych do prób od 1 do 5. Poprawność w każdej z tych prób obliczano dla tych samych sekwencji, a miarą zmiany była różnica między próbą 5 a próbą 1 w punktach procentowych (p.p.). Związek tempa wzrostu z wiekiem sprawdzono w kohorcie regresją logistyczną z interakcją $\log_2$ numeru próby i wieku oraz z efektami stałymi pracownika i pytania.

Wynik poprzedniej próby i odstęp (PB2). Każdą próbę od drugiej wzwyż przypisano do jednej z czterech kategorii według wyniku tej i poprzedniej próby: odpowiedź poprawna po poprawnej, *korekta błędu* (poprawna po błędnej), *zapominanie* (błędna po poprawnej) albo *powtórzony błąd* (błędna po błędnej). Ponieważ odsetek korekt błędów (r) i odsetek zapominania (f) mają różne mianowniki, porównano liczby obu zdarzeń oraz wyznaczono poziom równowagi $r/(r+f)$, do którego dążyłaby poprawność przy stałych odsetkach. Odsetki porównano w sześciu przedziałach odstępu: 7–13, 14–29, 30–59, 60–119, 120–239 oraz co najmniej 240 dni. Odsetek zapominania zestawiono także według liczby poprawnych odpowiedzi z rzędu przed daną próbą oraz osobno po korekcie błędu. Odpowiedź błędną w próbie następującej po korekcie błędu określono jako *nawrót błędu* i sprawdzono, czy pracownik wybrał w niej ten sam dystraktor co przed korektą. Sprawdzono również, czy harmonogram powtórek zależał od wyniku poprzedniej próby.

Utrwalone błędy (PB3). Poprawność porównano według liczby *błędów z rzędu*, czyli kolejnych odpowiedzi błędnych bezpośrednio poprzedzających daną próbę, od 0 do co najmniej 4. Dla dwóch kolejnych błędów obliczono, jak często pracownik wybierał ten sam dystraktor, i porównano ten odsetek z oczekiwanym przy wyborze losowym oraz przy wyborze zgodnym z popularnością dystraktorów w danym pytaniu. Odsetek ten zestawiono także w trzech przedziałach odstępu: krótszym niż 30 dni, 30–89 dni oraz co najmniej 90 dni. Obliczono też, jaką część powtórzonych błędów skupia 10% pytań, w których było ich najwięcej.

Obliczenia wykonano w języku Python 3.14.4 z użyciem bibliotek pandas 3.0.3, NumPy 2.5.0, SciPy 1.18.0, statsmodels 0.14.6 i Matplotlib 3.11.0.

3 Wyniki

3.1 Pierwsza próba

Przy pierwszym kontakcie z pytaniem (15 270 odpowiedzi 180 pracowników) poprawność wynosiła 82,6% (95% PU [81,2; 84,1]; tab. 3). Poprawność zmieniała się z wiekiem niemonotonicznie: była najniższa w przedziale 30–39 lat (74,9%), a najwyższa w przedziale 50–59 lat (84,3%). Przy porównaniu odpowiedzi na te same pytania szanse poprawnej odpowiedzi rosły z wiekiem (OR 1,16 na 10 lat, 95% PU [1,03; 1,31]; $p = 0{,}012$). Bez efektów stałych pytania zależność była słabsza (OR 1,12, 95% PU [1,01; 1,24]; $p = 0{,}039$).

Tabela 3: Poprawność w pierwszej próbie ogółem i według przedziału wieku pracownika.

Przedział wieku (lata)	Ogółem	20–29	30–39	40–49	50–59	60–69	Brak danych
Pracownicy	180	13	21	49	51	16	30
Pierwsze próby, n	15 270	970	2011	4338	5096	1416	1439
Poprawność (%)	82,6	82,5	74,9	84,0	84,3	82,6	83,5
95% PU	[81,2; 84,1]	[77,5; 89,3]	[68,8; 80,7]	[81,5; 86,3]	[82,2; 86,5]	[78,7; 86,4]	[80,0; 86,8]

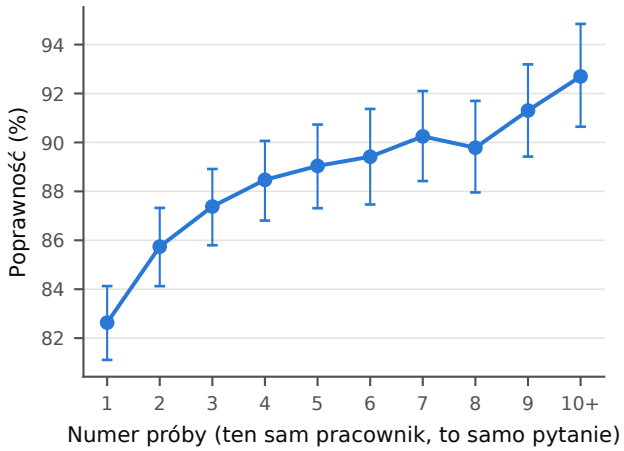
Pierwsza próba to pierwsza odpowiedź w sekwencji. 95% PU wyznaczono metodą bootstrap. Zależność od wieku oszacowano regresją logistyczną opisaną w podrozdziale 2.3 (13 578 odpowiedzi 150 pracowników o znanym wieku): OR 1,16 na 10 lat, 95% PU [1,03; 1,31], $p = 0{,}012$.

3.2 Zmiany w sekwencji (PB1)

Poprawność rosła wraz z numerem próby, z 82,6% [81,1; 84,1] w pierwszej próbie do 92,7% [90,6; 94,8] w próbie 10. i dalszych (rys. 1). Ponieważ z każdą próbą ubywało sekwencji, zmianę sprawdzono w kohorcie 4890 sekwencji. W kohorcie poprawność wzrosła z 81,9% [79,6; 84,1] w próbie 1 do 89,0%

[87,3; 90,7] w próbie 5, czyli o 7,2 p.p. (95% PU [5,5; 8,9]; tab. 4). Wzrost w tych samych sekwencjach oznacza, że poprawa nie wynikała z wcześniejszego kończenia sekwencji o niższej poprawności. Poprawność w próbie 1 w kohorcie (81,9%) była zbliżona do poprawności w pierwszej próbie we wszystkich sekwencjach (82,6%).

Oszacowanie wzrostu było dodatnie we wszystkich przedziałach wieku i wynosiło od 4,0 p.p. (60–69 lat) do 8,8 p.p. (40–49 lat), przy czym w nielicznych przedziałach skrajnych dolna granica 95% PU była bliska zera. Nie stwierdzono zależności tempa wzrostu od wieku (OR interakcji 0,97 na 10 lat wieku i podwojenie numeru próby, 95% PU [0,90; 1,05]; $p = 0{,}484$).



Rysunek 1: Poprawność według numeru próby we wszystkich sekwencjach dostępnych w danej próbie (ich liczba maleje wraz z numerem próby). Słupki błędów: 95% PU (bootstrap). Próby 10. i dalsze połączono. Przebieg w kohorcie przedstawiono na rys. 3.

Tabela 4: Poprawność w kolejnych próbach w kohorcie, ogółem i według przedziału wieku pracownika.

Przedział wieku (lata)	Ogółem	20–29	30–39	40–49	50–59	60–69	Brak danych
Pracownicy	124	9	15	35	39	13	13
Sekwencje, n	4890	199	664	1784	1689	471	83
Próba 1 (%)	81,9	81,4	77,0	81,6	83,8	82,4	86,7
Próba 2 (%)	85,6	80,4	79,4	85,7	88,0	86,6	94,0
Próba 3 (%)	87,2	85,4	81,5	88,5	88,3	86,0	95,2
Próba 4 (%)	88,4	87,9	82,7	89,5	89,7	86,2	96,4
Próba 5 (%)	89,0	86,9	84,2	90,4	90,1	86,4	97,6
Zmiana, próba 5 wobec 1 (p.p.)	7,2	5,5	7,2	8,8	6,3	4,0	10,8
95% PU	[5,5; 8,9]	[0,0; 14,7]	[3,2; 13,5]	[5,9; 11,6]	[4,3; 8,1]	[0,0; 9,3]	[1,9; 19,8]

Kohorta: sekwencje liczące co najmniej 5 prób, próby od 1 do 5. p.p.: punkty procentowe; 95% PU zmiany wyznaczono metodą bootstrap. Zależność tempa poprawy od wieku oszacowano regresją logistyczną opisaną w podrozdziale 2.3 (23 140 odpowiedzi pracowników o znanym wieku).

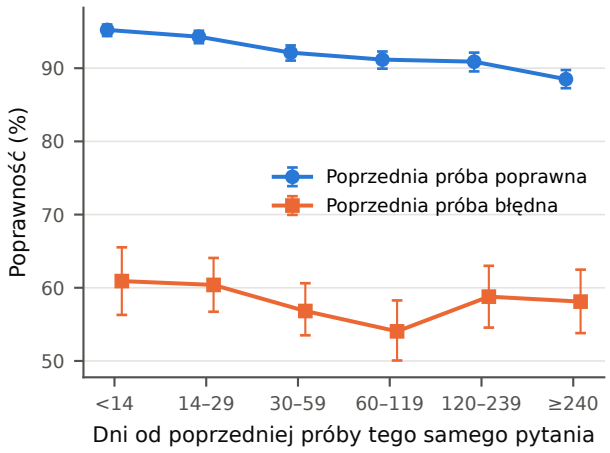
3.3 Wynik poprzedniej próby i odstęp (PB2)

Wzrost poprawności jest wynikiem dwóch przeciwnych procesów: korekty błędów i zapominania. Harmonogram nie zniekształcał ich porównania, ponieważ pytanie wracało po odpowiedzi poprawnej i błędnej z podobnym prawdopodobieństwem (73,5% i 74,5%) i po podobnym odstępie (mediana

37 i 39 dni). Po odpowiedzi poprawnej kolejna była poprawna w 92,6% [91,8; 93,4] przypadków, a w 7,4% wystąpiło zapominanie. Po odpowiedzi błędnej korekta nastąpiła w 58,3% [55,5; 61,2] przypadków. Odsetki te dotyczą różnych grup prób, dlatego porównano także liczby zdarzeń: korekt błędów było 3382, a przypadków zapominania 2719. Przewaga korekt wyjaśnia wzrost poprawności. Przy stałych odsetkach korekt błędów i zapominania poprawność dążyłaby do poziomu równowagi 88,8%. Poprawność w kohorcie w próbie 5 (89,0%) była bliska temu poziomowi, lecz w próbach 10. i dalszych wynosiła 92,7% i go przekraczała. Odsetek zapominania nie był bowiem stały, lecz zależał od odstępu i od liczby poprawnych odpowiedzi z rzędu.

Odsetek zapominania rósł wraz z odstępem, z 4,8% przy odstępie krótszym niż 14 dni do 11,5% przy odstępie co najmniej 240 dni (rys. 2). Odsetek korekt błędów zmieniał się z odstępem w mniejszym stopniu (60,9% i 58,1% w tych samych przedziałach).

Odsetek zapominania zależał także od liczby poprawnych odpowiedzi z rzędu. Po jednej odpowiedzi poprawnej wynosił 11,9% [10,7; 13,0], po dwóch 7,6%, po trzech 5,0%, a po co najmniej 4 3,2% [2,7; 3,7] (tab. 5). Różnica utrzymywała się przy każdym odstępie: przy odstępie krótszym niż 14 dni odsetek zapominania wynosił 7,7% po jednej i 2,3% po co najmniej trzech odpowiedziach poprawnych, a przy odstępie co najmniej 240 dni odpowiednio 13,9% i 5,2%. Najmniej trwałe były korekty błędów. Po korekcie nawrót błędu wystąpił w 24,9% [22,9; 26,8] przypadków ($n = 2457$), a w 73,6% [69,5; 77,7] z nich pracownik wybrał ten sam dystraktor co przed korektą. Udział ten był zbliżony do odsetka ponownych wyborów tego samego dystraktora po dwóch kolejnych błędach (71,8%; podrozdział 3.4).



Rysunek 2: Poprawność według odstępu, osobno dla prób poprzedzonych odpowiedzią poprawną (koła) i błędną (kwadraty). Dla prób poprzedzonych odpowiedzią poprawną odsetek zapominania wynosi 100% minus poprawność, a dla prób poprzedzonych odpowiedzią błędną poprawność jest odsetkiem korekt błędów. Słupki błędów: 95% PU (bootstrap).

Tabela 5: Odsetek zapominania według liczby poprawnych odpowiedzi udzielonych z rzędu bezpośrednio przed daną próbą.

Poprawne z rzędu przed próbą	1	2	3	≥4
Próby, n	12 318	8276	5597	10 734
Pracownicy	159	147	137	123
Odsetek zapominania (%)	11,9	7,6	5,0	3,2
95% PU	[10,7; 13,0]	[6,7; 8,5]	[4,2; 5,8]	[2,7; 3,7]

Próby poprzedzone odpowiedzią poprawną. Odsetek zapominania: odsetek odpowiedzi błędnych. 95% PU wyznaczono metodą bootstrap.

3.4 Utrwalone błędy (PB3)

Większość błędów korygowano: w 81,8% z 2068 sekwencji rozpoczętych odpowiedzią błędną i liczących co najmniej dwie próby pracownik co najmniej raz odpowiedział później poprawnie. Szansa korekty malała jednak z każdym kolejnym błędem. Po jednym błędzie poprawność wynosiła 64,4% [62,2; 66,8], po dwóch błędach z rzędu 48,1%, po trzech 41,8%, a po co najmniej 4 34,2% [27,6; 40,9] (tab. 6). Część tego spadku może wynikać z tego, że kilka błędów z rzędu zdarzało się głównie w trudniejszych pytaniach.

Powtórzone błędy nie były zgodne z wyborem losowym. Po dwóch kolejnych błędach pracownik w 71,8% [69,4; 74,1] przypadków ($n = 2420$) wybrał ten sam dystraktor, podczas gdy przy wyborze losowym należałoby oczekiwać 47,2%, a przy wyborze zgodnym z popularnością dystraktorów 60,0%. Odsetek ten nie zależał od odstępu (70,6% przy odstępie krótszym niż 30 dni, 73,2% przy 30–89 dniach i 71,6% przy co najmniej 90 dniach). Powtórzone błędy skupiały się w niewielu pytaniach: na 14 ze 145 pytań przypadało 39,6% z nich.

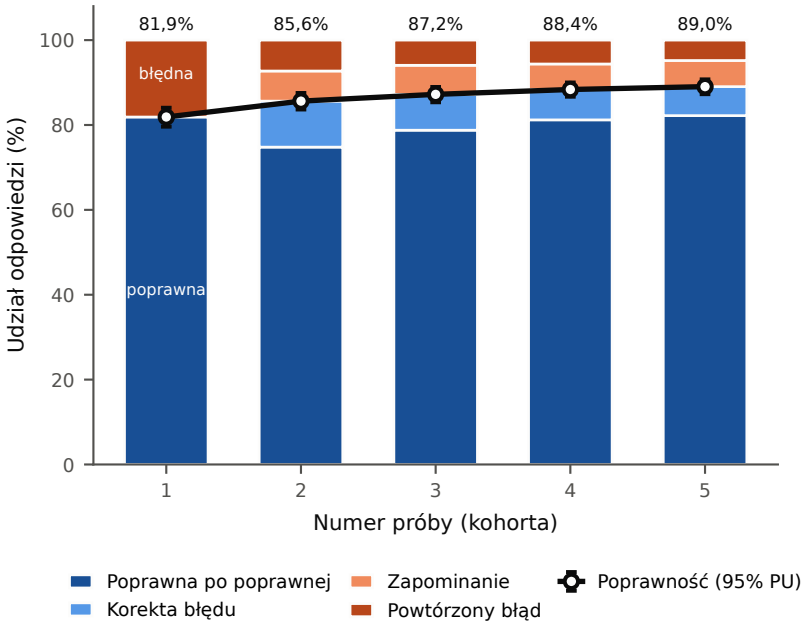
Tabela 6: Poprawność według liczby błędów popełnionych z rzędu bezpośrednio przed daną próbą.

Błędy z rzędu przed próbą	0	1	2	3	≥4
Próby, n	36 925	4024	1074	409	295
Pracownicy	159	149	110	80	48
Poprawność (%)	92,6	64,4	48,1	41,8	34,2
95% PU	[91,9; 93,4]	[62,2; 66,8]	[44,7; 51,9]	[36,4; 47,3]	[27,6; 40,9]

Próby od drugiej wzwyż. Kolumna 0: próby poprzedzone odpowiedzią poprawną. 95% PU wyznaczono metodą bootstrap.

3.5 Podsumowanie wyników

Rys. 3 zestawia wyniki w kohorcie. Poprawność rośnie z próby na próbę (PB1), korekty błędów przeważają nad zapominaniem (PB2), a w każdej próbie od drugiej wzwyż część odpowiedzi błędnych stanowią powtórzone błędy (PB3).



Rysunek 3: Poprawność i stan odpowiedzi w kohorcie (4890 sekwencji, próby od 1 do 5). Słupki: udział odpowiedzi według wyniku bieżącej i poprzedniej próby (podrozdział 2.3); w próbie 1 tylko odpowiedzi poprawne i błędne. Linia: poprawność z 95% PU (bootstrap), wartości nad słupkami.

4 Dyskusja

W programie mikrouczenia w banku poprawność rosła z każdym powrotem pytania, także w kohorcie, w której porównywano te same sekwencje. Wzrost wynikał z przewagi korekt błędów nad zapominaniem. Część błędów utrzymywała się jednak mimo informacji zwrotnej i polegała na ponownym wyborze tego samego dystraktora. Kierunek zmian jest zgodny z badaniami edukacji rozłożonej w czasie w kształceniu medycznym [7, 10].

Zapominanie wiązało się z trzema czynnikami. Pierwszym był upływ czasu: zapominanie było częstsze przy dłuższym odstępie, zgodnie z wynikami badań nad odstępem między powtórkami [4]. Drugim była krótka historia poprawnych odpowiedzi. Wiedza potwierdzona jedną poprawną odpowiedzią była zapominana od dwóch do czterech razy częściej niż wiedza potwierdzona kilka razy z rzędu, przy każdym odstępie. Podobnie w badaniach nad wielokrotnym powtarzaniem materiału każde kolejne udane przypomnienie zwiększało trwałość wiedzy [11]. Trzecim czynnikiem był nawrót błędu. Korekta błędu okazała się najmniej trwała, a jeśli się nie utrzymała, pracownik zwykle wracał do dystraktora wybranego przed korektą. Powrót pierwotnych błędów po informacji zwrotnej opisano również w badaniach laboratoryjnych [3]. Poprawna odpowiedź mogła więc nie zastępować błędnego przekonania, lecz współistnieć z nim.

Powtórzone błędy miały inny charakter niż zapominanie. Pracownicy wybierali ten sam dystraktor częściej, niż wynikałoby z przypadku, niezależnie od odstępu, a każdy kolejny błąd zmniejszał szansę korekty. Taki wzorzec jest zgodny z utrwalonym błędnym przekonaniem, a nie z brakiem wiedzy, który prowadziłby do zgadywania. Wybrany dystraktor może utrwalić się w pamięci, a informacja zwrotna ogranicza ten efekt [2]. W badanym programie informacja zwrotna podawała poprawną odpowiedź i wyjaśnienie, ale nie odnosiła się do wybranego dystraktora, choć wyjaśnienie, dlaczego wybrana odpowiedź jest błędna, działa zwykle silniej [15]. Skupienie powtórzonych

błędów w 14 pytaniach sugeruje ponadto, że część z nich wynikała z konstrukcji pytania, np. z niejednoznacznego dystraktora lub treści niezgodnej z praktyką banku. Takie pytania można wskazać standardową analizą dystraktorów [6].

W szkoleniach jednorazowych, np. z bezpieczeństwa informacji, efekty zanikały po kilku miesiącach [12]. Uzyskane wyniki wskazują, że wiedza wymaga dalszych powtórek także w programie z cyklicznie powracającymi pytaniami, a sposób planowania tych powtórek można poprawić. Ponieważ odstęp nie zależał od wyniku, pytania opanowane wracały równie często jak pytania, w których pracownik dopiero skorygował błąd. Harmonogram adaptacyjny mógłby wydłużać odstęp po kilku poprawnych odpowiedziach z rzędu i skracać go po korekcie błędu, gdy ryzyko nawrotu jest największe. Personalizacja powtórek poprawiała długotrwałe zapamiętywanie w porównaniu z harmonogramem stałym [8], a modele tempa zapominania oparte na historii odpowiedzi stosuje się już w aplikacjach do nauki języków [14]. Drugą zmianą może być informacja zwrotna odnosząca się do wybranego dystraktora, wprowadzona najpierw w pytaniach z największą liczbą powtórzonych błędów.

4.1 Ograniczenia i dalsze badania

Badanie było obserwacyjne i nie miało grupy kontrolnej, dlatego wzrostu poprawności nie można przypisać wyłącznie programowi, ponieważ pracownicy zdobywali wiedzę także w codziennej pracy. Ponieważ pytania się powtarzały, dane nie pozwalają odróżnić utrwalenia wiedzy od zapamiętania odpowiedzi na konkretne pytanie. Nie rejestrowano czasu namysłu podczas udzielania odpowiedzi ani pewności pracownika, dlatego zapominania nie można oddzielić od nieuwagi ani od trafnego zgadnięcia we wcześniejszej próbie, które modele ucznia ujmują jako poślizg i zgadywanie [5]. Na takie źródło części zapominania wskazuje jego odsetek wynoszący 4,8% już przy odstępie krótszym niż 14 dni. Najdłuższe odstępy mogły obejmować okresy zawieszenia programu, dlatego zmiany treści pytań mogły zawyżać odsetek zapominania przy tych odstępach. Porównania miały charakter opisowy i nie korygowano ich ze względu na wielokrotność testów. Przedziały ufności uwzględniały zależność odpowiedzi tego samego pracownika, lecz nie tego samego pytania. Zależności od liczby poprawnych odpowiedzi lub błędów z rzędu mogą więc częściowo odzwierciedlać różnice trudności między pytaniami.

Dalsze badania mogłyby porównać w schemacie randomizowanym harmonogram stały z adaptacyjnym oraz informację zwrotną standardową z odnoszącą się do wybranego dystraktora, z użyciem równoważnych wersji pytań, które oddzieliłyby wiedzę od zapamiętania odpowiedzi. Rejestrowanie pewności odpowiedzi pozwoliłoby sprawdzić, czy utrwalone błędy dotyczą przekonań o wysokiej pewności [3]. Wyniki mikrouczenia warto też powiązać z zastosowaniem wiedzy w pracy, np. z liczbą błędów proceduralnych [1].

5 Wnioski

W programie z cyklicznie powracającymi pytaniami poprawność odpowiedzi pracowników banku rosła z próby na próbę. Wiedza wymagała jednak dalszych powtórek, ponieważ była zapominana z upływem czasu, zwłaszcza po pierwszej poprawnej odpowiedzi i po korekcie błędu. Część błędów utrzymywała się mimo informacji zwrotnej i polegała na ponownym wyborze tego samego dystraktora. Harmonogram dopasowany do wyników pracownika i informacja zwrotna odnosząca się do wybranego dystraktora mogą zwiększyć skuteczność takich programów, ale ich wpływ wymaga potwierdzenia w badaniach z grupą kontrolną.

Oświadczenia

Etyka. W badaniu wykorzystano w pełni anonimizowane dane przekazane przez bank za jego zgodą [data i forma zgody banku]. Sposób oznaczenia pracowników i zasady ochrony danych opisano w podrozdziale 2.2. **Dostępność danych.** Dane wykorzystane w badaniu stanowią własność banku i nie są udostępniane publicznie.
Finansowanie. Badanie nie otrzymało finansowania.
Konflikt interesów. M. Szerszeń jest pracownikiem banku, w którym prowadzono program badań. Pozostali autorzy deklarują brak konfliktu interesów.
Wykorzystanie narzędzi AI. Wykorzystanie narzędzi AI. W trakcie przygotowywania artykułu wykorzystano narzędzie Antropic Claude Sonnet 5.5, do (1) redakcji językowej opisu wyników analizy przeprowadzonej przez autorów oraz (2) tłumaczenia tekstu z języka polskiego na angielski. Analiza danych, interpretacja wyników i wnioski zostały wykonane przez autora. Autorzy zweryfikowli zredagowali całość tekstu i ponoszą pełną odpowiedzialność za jego treść.

Literatura

[1] Brian D. Blume, J. Kevin Ford, Timothy T. Baldwin, and Jason L. Huang. Transfer of training: a meta-analytic review. *Journal of Management*, 36(4):1065–1105, 2010. doi:10.1177/0149206309352880.

[2] Andrew C. Butler and Henry L. Roediger. Feedback enhances the positive effects and reduces the negative effects of multiple-choice testing. *Memory & Cognition*, 36(3):604–616, 2008. doi:10.3758/MC.36.3.604.

[3] Andrew C. Butler, Lisa K. Fazio, and Elizabeth J. Marsh. The hypercorrection effect persists over a week, but high-confidence errors return. *Psychonomic Bulletin & Review*, 18(6):1238–1244, 2011. doi:10.3758/s13423-011-0173-y.

[4] Nicholas J. Cepeda, Harold Pashler, Edward Vul, John T. Wixted, and Doug Rohrer. Distributed practice in verbal recall tasks: a review and quantitative synthesis. *Psychological Bulletin*, 132(3):354–380, 2006. doi:10.1037/0033-2909.132.3.354.

[5] Albert T. Corbett and John R. Anderson. Knowledge tracing: modeling the acquisition of procedural knowledge. *User Modeling and User-Adapted Interaction*, 4:253–278, 1994. doi:10.1007/BF01099821.

[6] Mark J. Gierl, Okan Bulut, Qi Guo, and Xinxin Zhang. Developing, analyzing, and using distractors for multiple-choice tests in education: a comprehensive review. *Review of Educational Research*, 87(6):1082–1116, 2017. doi:10.3102/0034654317726529.

[7] B. Price Kerfoot. Learning benefits of on-line spaced education persist for 2 years. *Journal of Urology*, 181(6):2671–2673, 2009. doi:10.1016/j.juro.2009.02.024.

[8] Robert V. Lindsey, Jeffery D. Shroyer, Harold Pashler, and Michael C. Mozer. Improving students' long-term knowledge retention through personalized review. *Psychological Science*, 25 (3):639–647, 2014. doi:10.1177/0956797613504302.

[9] R. Charles Murray, Steven Ritter, Tristan Nixon, Ryan Schwiebert, Robert G. M. Hausmann, Brendon Towle, Stephen E. Fancsali, and Annalies Vuong. Revealing the learning in learning

curves. In *Artificial Intelligence in Education (AIED 2013)*, volume 7926 of *LNCS*, pages 473–482, 2013. doi:10.1007/978-3-642-39112-5_48.

[10] Jane L. Phillips, Nicole Heneka, Priyanka Bhattarai, Clare Fraser, and Tim Shaw. Effectiveness of the spaced education pedagogy for clinicians' continuing professional development: a systematic review. *Medical Education*, 53(9):886–902, 2019. doi:10.1111/medu.13895.

[11] Katherine A. Rawson, John Dunlosky, and Sharon M. Sciartelli. The power of successive relearning: improving performance on course exams and long-term retention. *Educational Psychology Review*, 25(4):523–548, 2013. doi:10.1007/s10648-013-9240-4.

[12] Benjamin Reinheimer, Lina Aldag, Peter Mayer, Mattia Mossano, Reyhan Duezguen, Bettina Lofthouse, Tatiana von Landesberger, and Melanie Volkamer. An investigation of phishing awareness and education over time: when and how to best remind users. In *Sixteenth Symposium on Usable Privacy and Security (SOUPS 2020)*. USENIX Association, 2020.

[13] Henry L. Roediger and Jeffrey D. Karpicke. Test-enhanced learning: taking memory tests improves long-term retention. *Psychological Science*, 17(3):249–255, 2006. doi:10.1111/j.1467-9280.2006.01693.x.

[14] Burr Settles and Brendan Meeder. A trainable spaced repetition model for language learning. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics*, pages 1848–1858, 2016. URL `https://aclanthology.org/P16-1174`.

[15] Valerie J. Shute. Focus on formative feedback. *Review of Educational Research*, 78(1):153–189, 2008. doi:10.3102/0034654307313795.

[16] Allison D. Taylor and Woei Hung. The effects of microlearning: a scoping review. *Educational Technology Research and Development*, 70:363–395, 2022. doi:10.1007/s11423-022-10084-1.