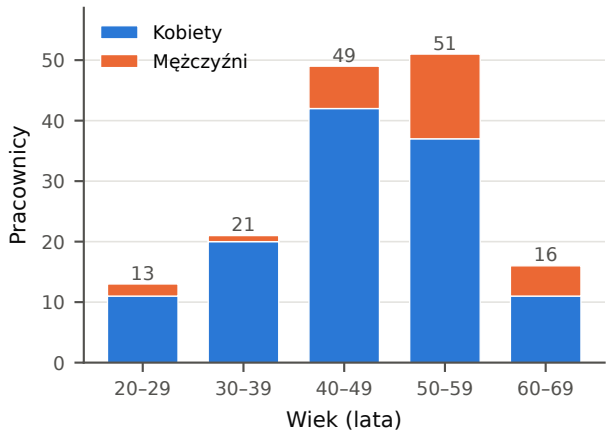
Materiał uzupełniający

Powtarzane przypominanie w programie mikrouczenia w banku: przyrost poprawności, zapominanie i utrwalone błędy w trzyletnich logach odpowiedzi

S1 Uczestnicy i aktywność

Spośród 187 pracowników objętych analizą dane o wieku i płci były dostępne dla 151 (80,7%; tab. 2 w artykule głównym). Wśród osób o znanej płci kobiety stanowiły 80,1% ($n = 121$), a mężczyźni 19,9% ($n = 30$). Mediana wieku wynosiła 47 lat (IQR 41–56; zakres 22–67), a najliczniejszą grupę stanowiły osoby w wieku 50–59 lat (34,0% osób o znanym wieku; rys. S1). Aktywność w kolejnych miesiącach przedstawiono na rys. S2.



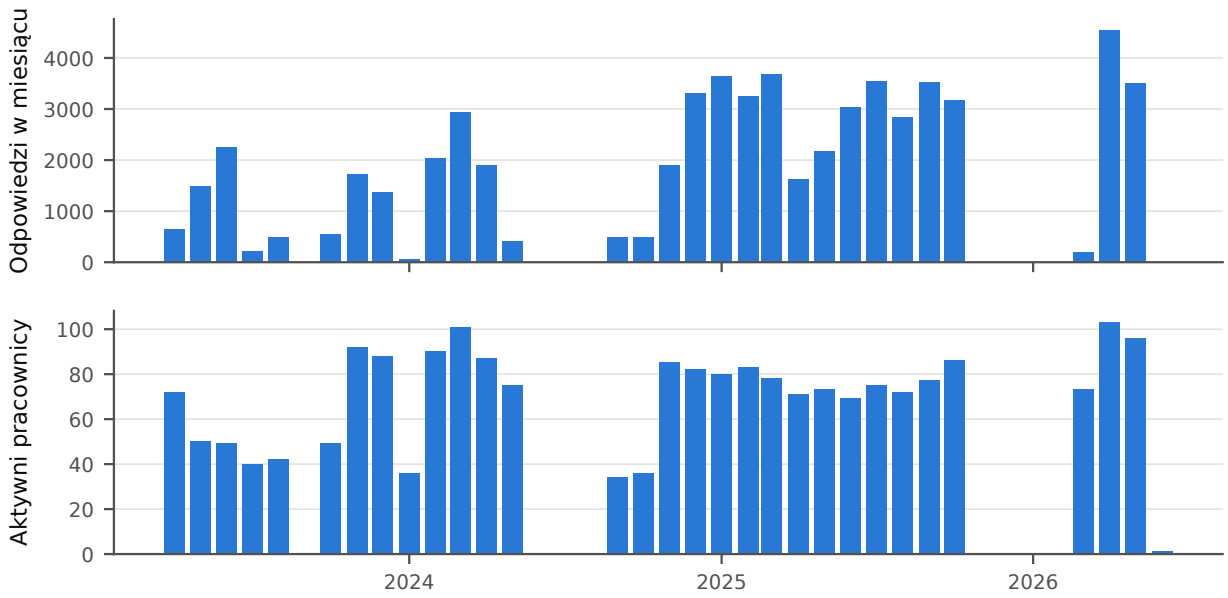
Rysunek S1: Pracownicy objęci analizą według wieku (przedziały 10-letnie) i płci. Liczby nad słupkami: łączna liczba pracowników w przedziale. Pominięto osoby bez danych o wieku ($n = 37$).

S2 Krzywa uczenia i retencja: wartości liczbowe

Tabele S1 i S2 zawierają wartości przedstawione na rycinach krzywej uczenia i zależności od odstępu w artykule.

S3 Analizy wrażliwości

Specyfikacje opisano w podrozdziale „Modele statystyczne” artykułu; wyniki zestawiono w tab. S3.



Rysunek S2: Miesięczna liczba odpowiedzi (u góry) i aktywnych pracowników (u dołu) w okresie obserwacji. Okresy bez odpowiedzi odpowiadają zawieszeniom programu na czas przeglądu pytań.

Tabela S1: Odsetek poprawnych odpowiedzi według numeru próby w sekwencjach pracownik–pytanie.

Próba	n	Pracownicy	%	95% PU	n (kohorta)	% (kohorta)	95% PU (kohorta)
1	15 783	187	82,5	[81,0; 83,9]	5187	81,8	[79,7; 83,8]
2	12 413	160	85,7	[84,1; 87,2]	5187	85,8	[83,9; 87,7]
3	9563	149	87,3	[85,8; 88,8]	5187	87,2	[85,3; 88,9]
4	7124	141	88,4	[86,7; 89,9]	5187	88,3	[86,6; 90,0]
5	5187	129	89,1	[87,4; 90,7]	5187	89,1	[87,3; 90,6]
6	3693	106	89,5	[87,6; 91,2]			
7	2638	90	89,9	[88,0; 91,6]			
8	1844	81	89,8	[87,9; 91,5]			
9	1186	70	91,1	[89,0; 93,0]			
10+	1531	57	91,8	[88,5; 94,4]			

Kohorta: sekwencje liczące ≥5 prób, co utrzymuje stały zbiór sekwencji w próbach 1–5 i eliminuje obciążenie przeżywalności. 95% PU z bootstrapu klastrowego, w którym losowano pracowników (2000 replikacji).

Tabela S2: Odsetek poprawnych odpowiedzi według odstępu od poprzedniej próby tego samego pytania, dla odpowiedzi poprzednio poprawnych (po lewej) i błędnych (po prawej).

Dni od poprzedniej	n	Poprawne, % [95% PU]	n	Poprawne, % [95% PU]
<14	6288	95,2 [94,3; 95,9]	949	61,0 [56,9; 65,3]
14–29	10 816	94,2 [93,2; 95,0]	1631	60,5 [56,9; 64,6]
30–59	8326	92,1 [91,0; 93,1]	1327	57,0 [53,9; 60,3]
60–119	6212	91,1 [89,9; 92,2]	964	54,5 [50,7; 58,8]
120–239	4220	90,6 [89,3; 91,9]	724	59,3 [55,4; 63,7]
≥240	3176	88,5 [87,2; 89,7]	546	58,4 [54,1; 62,8]

95% PU z bootstrapu klastrowego, w którym losowano pracowników (2000 replikacji).

Tabela S3: Analizy wrażliwości: iloraz szans poprawnej odpowiedzi na podwojenie numeru próby (model M1).

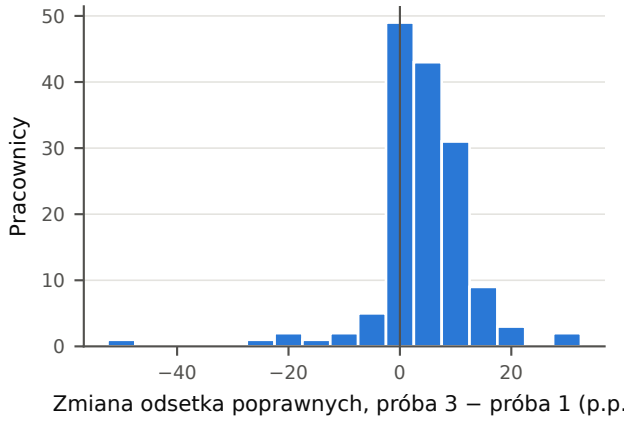
Analiza	Odpowiedzi	OR [95% PU]
Efekty stałe pracownika i pytania (model główny)	60 680	1,38 [1,32; 1,45]
Kohorta zbalansowana (sekwencje z ≥5 próbami, próby 1–5)	24 920	1,36 [1,27; 1,46]
Próby obcięte do 10	59 877	1,38 [1,32; 1,44]
Wyłącznie sekwencje o długości 3–4	14 218	1,30 [1,21; 1,40]
Wyłącznie sekwencje o długości 5–7	18 154	1,35 [1,26; 1,45]
Wyłącznie sekwencje o długości ≥8	16 884	1,40 [1,31; 1,50]
Pracownicy z ≥50 odpowiedziami	60 256	1,38 [1,32; 1,45]
Z korektą o staż pracownika	60 680	1,50 [1,42; 1,59]
GEE, korelacja wymienna w obrębie pracownika (efekt uśredniony populacyjnie)	60 962	1,29 [1,24; 1,35]
Skrzyżowane losowe wyrazy wolne pracownika i pytania (aproksymacja Laplace'a)	60 962	1,37 [1,34; 1,41]

Odchylenia standardowe losowych wyrazów wolnych (skala logitowa): pracownik SD = 0,69, pytanie SD = 1,10; ICC w skali latentnej: pracownik = 0,09, pytanie = 0,24; R^2 Nakagawy: brzegowy = 0,021, warunkowy = 0,35. Warstwy według długości sekwencji służą kontroli obciążenia typu *pattern-mixture* (ubywania obserwacji) w krzywej uczenia.

S4 Zmiana poprawności na poziomie pracowników

Metoda. Zmianę na poziomie pracownika zdefiniowano jako różnicę odsetka poprawnych odpowiedzi między próbą 3 a próbą 1, obliczoną na podstawie własnych sekwencji pracownika liczących co najmniej trzy próby. Zmianę testowano testem znaków i testem rangowanych znaków Wilcoxona, z korelacją rangowo-dwuseryjną jako miarą wielkości efektu.

Wyniki. Spośród 149 pracowników (79,7% wszystkich), którzy mieli co najmniej jedną sekwencję liczącą trzy lub więcej prób, 102 poprawiło wynik, 20 go pogorszyło, a u 27 nie zmienił się on między pierwszą a trzecią próbą (test znaków: $p < 0{,}001$; test Wilcoxona: $p < 0{,}001$; korelacja rangowo-dwuseryjna $r = 0{,}72$). Średnia zmiana wyniosła 3,8 punktu procentowego (95% PU [2,4; 5,2]; rys. S3, tab. S4).



Rysunek S3: Rozkład zmiany odsetka poprawnych odpowiedzi na poziomie pracownika między próbą 3 a próbą 1 w jego własnych sekwencjach liczących co najmniej trzy próby ($n = 149$ pracowników; przedziały o szerokości 5 punktów procentowych wyśrodkowane na zerze).

Tabela S4: Zmiana odsetka poprawnych odpowiedzi między pierwszą a trzecią próbą tych samych pytań.

Miara	Wartość
Pracownicy z ≥1 sekwencją o ≥3 próbach	149
Poprawa / pogorszenie / bez zmian	102 / 20 / 27
Średnia zmiana, p.p. [95% PU]	3,8 [2,4; 5,2]
Mediana zmiany, p.p.	3,7
Test znaków: odsetek z poprawą [95% PU]; p	0,84 [0,76; 0,90]; <0,001
Test Wilcoxona W; p; korelacja rangowo-dwuseryjna r	1052; <0,001; 0,72
Sekwencje (pracownik–pytanie) z ≥3 próbami	9563
Poprawne w próbie 1 / próbie 3 (%)	82,6 / 87,3
Błędna→poprawna / poprawna→błędna	1075 / 625
Test McNemara χ^2; p (bez uwzględnienia klastrów)	118,6; <0,001

Zmiana na poziomie pracownika: różnica odsetka poprawnych odpowiedzi między próbą 3 a próbą 1 we własnych sekwencjach pracownika liczących ≥3 próby; remisy wykluczono z testu znaków i testu Wilcoxona; p.p.: punkty procentowe.

S5 Analiza pytań

Metoda. Pytania opisano wskaźnikami klasycznej teorii testu. Trudność (odsetek poprawnych odpowiedzi) i dyskryminację (korelacja pytanie–reszta, tj. z poprawnością pracownika w pozostałych pytaniach) obliczono na pierwszych próbach. Funkcjonowanie dystraktorów oceniono na wszystkich odpowiedziach na pytanie; dystraktory wybierane w mniej niż 5% odpowiedzi uznano za niefunkcjonalne [2, 3]. Trendy poprawności w kolejnych próbach dla poszczególnych pytań testowano regresją logistyczną z błędami standardowymi klastrowanymi względem pracowników, kontrolując odsetek fałszywych odkryć (FDR) na poziomie 0,05 [1].

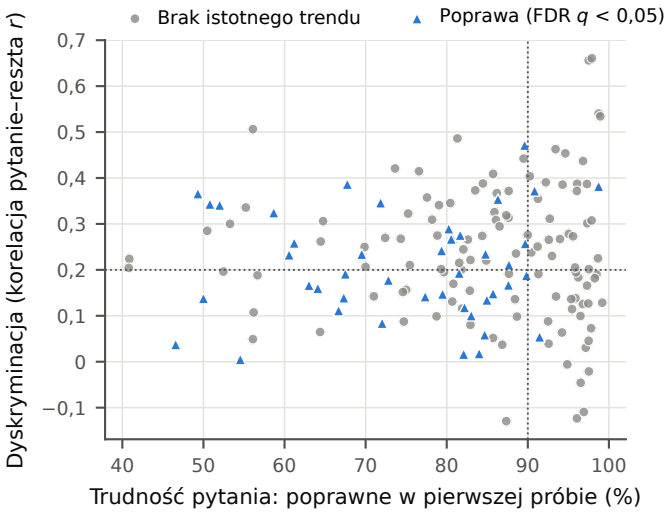
Wyniki. Mediana trudności pytań wynosiła 85,3% poprawnych odpowiedzi w pierwszej próbie: na 4 pytania poprawnie odpowiedziało mniej niż 50% pracowników, na 102 od 50% do 90%, a na 58 ponad 90% (tab. S5). Mediana korelacji pytanie–reszta wynosiła 0,22; 70 z 161 pytań miało korelację poniżej 0,20, natomiast w 49 osiągnęła ona co najmniej 0,30 (rys. S4). Błędy koncentrowały się na jednym dystraktorze (mediana 71,8% błędów w pytaniu), a 193 z 349 zaobserwowanych dystraktorów (55,3%) było niefunkcjonalnych. Poprawność istotnie rosła wraz z powtórkami w 44 z 164 testowalnych pytań, a malała w 1 (po korekcie FDR).

Literatura

[1] Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B (Methodological)*, 57(1):289–300, 1995. doi:10.1111/j.2517-6161.1995.tb02031.x.

[2] Mark J. Gierl, Okan Bulut, Qi Guo, and Xinxin Zhang. Developing, analyzing, and using distractors for multiple-choice tests in education: a comprehensive review. *Review of Educational Research*, 87(6):1082–1116, 2017. doi:10.3102/0034654317726529.

[3] Marie Tarrant, James Ware, and Ahmed M. Mohammed. An assessment of functioning and non-functioning distractors in multiple-choice questions: a descriptive analysis. *BMC Medical Education*, 9:40, 2009. doi:10.1186/1472-6920-9-40.



Rysunek S4: Trudność pytania (odsetek poprawnych w pierwszej próbie) a dyskryminacja (korelacja pytanie–reszta). Trójkąty: pytania, w których poprawność istotnie rosła wraz z powtórkami (Benjamini–Hochberg, $q < 0{,}05$). Linie kropkowane: $r = 0{,}20$ i 90% poprawnych.

Tabela S5: Analiza pytań (klasyczna teoria testu).

Miara	Wartość
Analizowane pytania	164
Trudność (% poprawnych w pierwszej próbie), mediana [IQR]	85,3 [75,2; 94,2]
Pytania z <50% / 50–90% / >90% poprawnych	4 / 102 / 58
Dyskryminacja (korelacja pytanie–reszta r), mediana [IQR], pytania z $n \geq 30$	0,22 [0,14; 0,32] ($k = 161$)
Pytania z $r < 0{,}20$ / 0,20–0,29 / $\geq 0{,}30$	70 / 42 / 49
Udział błędów przypadających na najczęstszy dystraktor (%), mediana [IQR]	71,8 [58,4; 84,3]
Zaobserwowane dystraktory wybierane w <5% odpowiedzi (niefunkcjonalne)	193 z 349 (55,3%)
Pytania z poprawą / pogorszeniem przy powtórkach (FDR $q < 0{,}05$)	44 / 1 (z 164 testowalnych)

Trudność i dyskryminację obliczono na pierwszych próbach, wskaźniki dystraktorów na wszystkich odpowiedziach; korelacja pytanie–reszta wykorzystuje poprawność pracownika w pozostałych pytaniach (pracownicy z $\geq$10 pierwszymi próbami). Trend: regresja logistyczna poprawności względem $\log_2$(numeru próby) dla każdego pytania z błędami standardowymi klastrowanymi względem pracowników, korekta Benjaminiego–Hochberga. Dystraktory, których nigdy nie wybrano, nie są widoczne w logu i nie zostały uwzględnione.