Powtarzane pytania, poprawność odpowiedzi i trwałość błędów: trzyletnia analiza mikrouczenia w organizacji

Bartosz Lewandowski (ORCID:0009-0004-1158-0693)[1,*], Monika Szerszeń (ORCID: 0009-0009-6625-3979)[2], Magdalena Dowgalec (ORCID:0009-0005-4469-2832)[3], Ewaryst Tkacz (ORCID:0000-0003-2580-7954)[4] i Maciej J. Wróbel (ORCID:0000-0003-1865-2122)[5]

[1,4]Department of Clinical Engineering, Academy of Silesia in Katowice
[3]Powiślański Bank Spółdzielczy w Kwidzynie
[4]Atende SA
[5]Department of Otolaryngology and Oncological Laryngology Collegium Medicum NCU
[*]Autor korespondencyjny: dr Bartosz Lewandowski, bartosz.lewandowski@akademiaslaska.pl

Streszczenie

Wprowadzenie. Przypominanie rozłożone w czasie poprawia zapamiętywanie w warunkach laboratoryjnych i edukacyjnych, jednak wyniki wieloletnich programów szkoleń w miejscu pracy opisano w niewielu badaniach. **Metody.** Przeanalizowano 60 962 odpowiedzi udzielonych przez 187 pracowników banku na 164 pytań wielokrotnego wyboru w programie mikrouczenia opartym na quizach (od kwietnia 2023 do czerwca 2026). Pytania wracały do pracownika w stałym, nieadaptacyjnym odstępie (mediana 36 dni), a po każdej odpowiedzi wyświetlano odpowiedź poprawną. Poprawność modelowano regresją logistyczną z efektami stałymi pracownika i pytania w trzech modelach: uczenia, retencji i nowych pytań. **Wyniki.** Odsetek poprawnych odpowiedzi wzrósł z 82,5% w pierwszej próbie do 91,8% w próbie 10. i kolejnych. Każde podwojenie numeru próby zwiększało szanse poprawnej odpowiedzi 1,38-krotnie (95% PU [1,32; 1,45]; zakres w analizach wrażliwości 1,29–1,50), a każde podwojenie odstępu od poprzedniej próby zmniejszało je (OR 0,88). Po powtórzonym błędzie pracownicy w 71,6% przypadków wybierali ten sam dystraktor, wobec 59,6% oczekiwanych przy uwzględnieniu popularności dystraktorów. Poprawność na nowo napotykanych pytaniach nie rosła wraz ze stażem (OR 0,88 na rok, 95% PU [0,76; 1,01]). **Wnioski.** Powtarzanemu przypominaniu towarzyszyła poprawa w powtarzanych pytaniach, zapominanie między powtórkami i utrwalanie konkretnych błędów mimo informacji zwrotnej. Dane nie rozstrzygają, czy poprawa dotyczy wiedzy, czy zapamiętania odpowiedzi. Adaptacyjny harmonogram powtórek i informacja zwrotna odnosząca się do wybranego dystraktora mogłyby zwiększyć skuteczność takich programów.

Słowa kluczowe: powtórki rozłożone w czasie; praktyka przypominania; mikrouczenie; szkolenia pracownicze; analityka uczenia się; informacja zwrotna; zapominanie

1 Wprowadzenie

Przypominanie sobie informacji z pamięci wzmacnia ich późniejsze utrwalenie silniej niż ponowne ich przeczytanie (efekt testowania), a nauka rozłożona w czasie jest zapamiętywana lepiej niż nauka skumulowana (efekt rozłożenia w czasie) [4, 5, 25]. W randomizowanych badaniach z udziałem lekarzy w trakcie kształcenia tzw. edukacja rozłożona w czasie (ang. *spaced education*), w której krótkie pytania wielokrotnego wyboru przesyła się cyklicznie przez tygodnie lub miesiące, poprawiała przyswajanie i utrwalanie wiedzy [11–13], natomiast przeglądy systematyczne wskazują na małe lub umiarkowane korzyści u pracowników ochrony zdrowia [18, 23].

W szkoleniach organizacyjnych stosuje się krótkie formy *mikrouczenia* (ang. *microlearning*) oparte na quizach, jednak dostępne dowody pochodzą głównie z badań na małych próbach lub z tzw. szarej literatury [29]. Ewaluacje obowiązkowych szkoleń organizacyjnych, np. z zakresu świadomości bezpieczeństwa, często wykazują efekty niewielkie albo zanikające z upływem czasu [10, 15, 24]. Dane z dzienników (logów) takich platform pozwalają natomiast obserwować uczenie się na poziomie pojedynczych odpowiedzi, podobnie jak w modelach ucznia rozwijanych dla inteligentnych systemów tutorskich i aplikacji do nauki języków [6, 14, 22, 26, 27].

W badaniach szkoleń organizacyjnych skuteczność ocenia się zwykle przez transfer, rozumiany jako zastosowanie nabytej wiedzy i umiejętności w pracy [2, 3]. Logi platform mikrouczenia nie pozwalają zmierzyć transferu w tym znaczeniu, umożliwiają natomiast śledzenie nabywania i utrwalania wiedzy sprawdzanej przez same pytania.

Badanie przeprowadzono w banku, w którym pracownicy odpowiadali na krótkie pytania wielokrotnego wyboru dotyczące wymogów regulacyjnych, produktów bankowych, umiejętności miękkich oraz, w przypadku kadry kierowniczej, zarządzania, wyświetlane przez aplikację na komputerze w trakcie dnia pracy. Pytania wracały do pracownika w stałym, nieadaptacyjnym odstępie, a po każdej odpowiedzi wyświetlano odpowiedź poprawną. Na podstawie trzyletnich logów odpowiedzi sformułowano trzy pytania badawcze: (PB1) czy odsetek poprawnych odpowiedzi rośnie wraz z kolejnymi przypomnieniami tego samego pytania przez tego samego pracownika; (PB2) jak poprawność zależy od wyniku poprzedniej próby i od czasu, który od niej upłynął; (PB3) czy powtarzane błędy są trwałe, co wskazywałoby raczej na utrwalone błędne przekonania niż na zgadywanie, mimo informacji zwrotnej po każdej odpowiedzi. Uzupełniająco sprawdzono, czy poprawność odpowiedzi na nowo napotykane pytania zmieniała się wraz ze stażem w programie.

2 Materiał i metody

2.1 Środowisko i program szkoleniowy

Program prowadzono w banku. Jego treść stanowiły pytania ogólne pogrupowane w cztery kategorie: wymogi regulacyjne, produkty bankowe, umiejętności miękkie oraz moduł dla kadry kierowniczej. Każde pytanie było pytaniem wielokrotnego wyboru z trzema do pięciu opcjami odpowiedzi, z których dokładnie jedna była poprawna, i zawierało wyjaśnienie poprawnej odpowiedzi. Aplikacja szkoleniowa uruchamiała się automatycznie na ekranach komputerów pracowników i wyświetlała od jednego do trzech pytań dziennie w godzinach 10:00–14:00; po każdej odpowiedzi pokazywano poprawną odpowiedź wraz z wyjaśnieniem. To samo pytanie mogło zostać ponownie zadane temu samemu pracownikowi nie wcześniej niż siedem dni po poprzedniej odpowiedzi, a harmonogram powtórek nie zależał od tego, czy odpowiedź była poprawna. Na czas przeglądu i aktualizacji pytań program był zawieszany. O udziale w programie decydował Departament Digitalizacji i Procesów banku, który był również autorem pytań. Pytania prezentowano w modułach tematycznych (mediana 3 zaobserwowanych opcji odpowiedzi na pytanie). W analizowanych danych pracownicy odpowiadali na medianę 3 pytań w dniu aktywności, a to samo pytanie było ponownie zadawane temu samemu pracownikowi po medianie 36 dni (IQR 18–90).

2.2 Dane

Dane przekazano w formie listy odpowiedzi zawierającej moduł, pytanie, wybraną opcję, kod odpowiadającego, znacznik czasu oraz poprawność odpowiedzi (wartość logiczna). Wykluczono 2 pytania, w których zarejestrowano tylko jedną opcję odpowiedzi (348 odpowiedzi), ponieważ nie niosą one informacji o błędach. Zbiór analityczny obejmował 60 962 odpowiedzi (tab. 1). Dane osób odpowia-

dających przekazano w formie metadanych zawierających płeć pracownika oraz przedział wiekowy (co 10 lat) oraz medianę wieku.

[Podstawa prawna przetwarzania danych spseudonimizowanych (wiek, płeć)]

2.3 Definicje

Sekwencja to uporządkowana chronologicznie seria prób jednego pracownika dotyczących jednego pytania; *numer próby* to pozycja odpowiedzi w jej sekwencji (przy jednakowym czasie o kolejności decydował identyfikator rekordu). *Poprawność* to odsetek poprawnych odpowiedzi. *Odstęp* to czas w dniach od poprzedniej próby w tej samej sekwencji. *Staż* to czas od pierwszej odpowiedzi pracownika w programie.

2.4 Analiza opisowa

Odsetki poprawnych odpowiedzi podano z 95-procentowymi przedziałami ufności (PU) z bootstrapu klastrowego, w którym losowano pracowników ze zwracaniem (2000 replikacji); procedura ta uwzględnia zależność odpowiedzi udzielanych przez tę samą osobę. Ponieważ osoby kontynuujące do kolejnych prób mogą różnić się od tych, które przestają, zagregowane krzywe uczenia mogą być zniekształcone przez ubywanie obserwacji [9, 19]; krzywą obliczono więc dodatkowo dla zbalansowanej kohorty sekwencji liczących co najmniej 5 prób. Zależność odsetka błędów od numeru próby opisano funkcją potęgową [21]. Ponieważ harmonogram powtórek nie był adaptacyjny, sprawdzono, czy ponowne zadanie pytania zależało od wyniku poprzedniej próby.

2.5 Modele statystyczne

Niech Y_{ijt} oznacza poprawność (1 albo 0) odpowiedzi pracownika i na pytanie j w próbie t. Zastosowano trzy modele regresji logistycznej o wspólnej postaci

$$\operatorname{logit} P(Y_{ijt} = 1) = \alpha_i + \gamma_j + \mathbf{x}_{ijt}^{\top}\boldsymbol{\beta},$$

gdzie α_i i γ_j są efektami stałymi pracownika i pytania. Efekty stałe pochłaniają stałe różnice poziomu wiedzy między osobami i trudności między pytaniami, dlatego współczynniki $\boldsymbol{\beta}$ opisują zmiany w obrębie tej samej osoby i tego samego pytania. Modele różniły się zbiorem odpowiedzi i wektorem predyktorów $\mathbf{x}_{ijt}$:

M1, model uczenia (PB1). Wszystkie odpowiedzi; jedynym predyktorem jest numer próby, $\beta_1 \log_2 t$. Wartość e^{β_1} jest ilorazem szans (OR) poprawnej odpowiedzi przy podwojeniu numeru próby (np. z 1 do 2 albo z 4 do 8).

M2, model retencji (PB2). Wyłącznie próby powtórne ($t \geq 2$); $\beta_1 \log_2 t + \beta_2 Y_{ij,t-1} + \beta_3 \log_2 \Delta_{ijt} + \beta_4 S_{it}$, gdzie $Y_{ij,t-1}$ to wynik poprzedniej próby, Δ_{ijt} odstęp od niej w dniach (ograniczony od dołu do 1 dnia), a S_{it} staż w latach. Konstrukcją model odpowiada modelom *performance factors analysis* i *half-life regression* stosowanym do logów uczących się [22, 26].

M3, model nowych pytań. Wyłącznie pierwsze próby ($t = 1$); jedynym predyktorem jest staż, $\beta_4 S_{it}$. Przy efektach stałych pracownika współczynnik porównuje pierwsze kontakty tej samej osoby z kolejnymi pytaniami, napotkanymi przy różnym stażu.

Pracowników i pytania, w których wszystkie odpowiedzi były poprawne albo wszystkie błędne, usuwano iteracyjnie przed estymacją, ponieważ ich efekty stałe nie są identyfikowalne. Modele szacowano metodą największej wiarygodności, a błędy standardowe klastrowano względem pracowników.

Odporność oszacowania e^{β_1} z modelu M1 sprawdzono w analizach wrażliwości: w zbalansowanej kohorcie, po obcięciu sekwencji do 10 prób, w warstwach długości sekwencji (kontrola obciążenia typu *pattern-mixture*), po wykluczeniu pracowników z mniej niż 50 odpowiedziami oraz po dodaniu stażu jako predyktora. Efekt uśredniony populacyjnie oszacowano ponadto metodą uogólnionych równań estymujących (GEE) z wymienną macierzą korelacji roboczej [16], a w modelu mieszanym efekty stałe zastąpiono skrzyżowanymi losowymi wyrazami wolnymi pracowników i pytań [1]. Z modelu mieszanego wyznaczono współczynniki korelacji wewnątrzklasowej (ICC) w skali latentnej oraz brzegowy i warunkowy współczynnik R^2 [20].

2.6 Przejścia i powtarzane błędy

Przejścia między kolejnymi próbami tego samego pytania zestawiono w tabeli kontyngencji. Dla dwóch następujących po sobie błędów porównano odsetek ponownych wyborów tego samego dystraktora z odsetkiem oczekiwanym przy losowym wyborze spośród zaobserwowanych dystraktorów oraz przy wyborze proporcjonalnym do popularności każdego dystraktora w danym pytaniu.

Analizy uzupełniające, czyli zmianę poprawności na poziomie pracowników oraz analizę pytań metodami klasycznej teorii testu, opisano w materiale uzupełniającym. Obliczenia wykonano w języku Python 3.14.4 z użyciem bibliotek pandas 2.3.3, NumPy 2.3.5, SciPy 1.16.3, statsmodels 0.14.6 i Matplotlib 3.10.7.

3 Wyniki

3.1 Próba i harmonogram powtórek

Zbiór danych obejmował 60 962 odpowiedzi 187 pracowników na 164 pytań w 9 modułach, zebranych od kwietnia 2023 do czerwca 2026 (tab. 1). Mediana liczby odpowiedzi na pracownika wynosiła 218 (IQR 67–592), udzielonych na 90 różnych pytań w ciągu 84 dni aktywności, a mediana czasu uczestnictwa w programie wynosiła 18 miesięcy. Okresy bez odpowiedzi odpowiadają zawieszeniom programu na czas przeglądu pytań (rys. S2). Wśród 151 pracowników o znanych danych demograficznych kobiety stanowiły 80,1%, a mediana wieku wynosiła 47 lat (tab. S1). Ogólny odsetek poprawnych odpowiedzi wynosił 86,5%, a w pierwszych próbach 82,5%.

Harmonogram powtórek nie zależał od wyniku poprzedniej próby: prawdopodobieństwo kolejnej próby wynosiło 74,0% po odpowiedzi poprawnej i 74,7% po błędnej, natomiast mediana odstępu do kolejnej próby wynosiła odpowiednio 36 i 38 dni. Kontynuacja sekwencji nie była więc selekcjonowana według wyników.

3.2 Uczenie się w kolejnych próbach (PB1)

Odsetek poprawnych odpowiedzi rósł wraz z numerem próby: z 82,5% [81,0; 83,9] w pierwszej próbie do 91,8% [88,5; 94,4] w próbie 10. i kolejnych (rys. 1, tab. S2). Wzrost był podobny w zbalansowanej kohorcie 5187 sekwencji liczących co najmniej 5 prób (81,8% [79,7; 83,8] w próbie 1 wobec 89,1% [87,3; 90,6] w próbie 5), nie wynika więc z selektywnej kontynuacji przez pracowników osiągających lepsze wyniki. Odsetek błędów był funkcją potęgową numeru próby (wykładnik 0,29, $R^2 = 0{,}98$), zgodnie z potęgowym prawem praktyki [21].

W modelu uczenia M1 każde podwojenie numeru próby wiązało się z 1,38-krotnie wyższymi szansami poprawnej odpowiedzi (95% PU [1,32; 1,45]; tab. 2). Efekt ten wyjaśniał jednak niewielką część zmienności poprawności (brzegowy $R^2 = 0{,}021$ wobec warunkowego $R^2 = 0{,}35$), a pytania odpowiadały za większą jej część niż pracownicy (ICC 0,24 wobec 0,09). Na poziomie pracowników

Tabela 1: Charakterystyka zbioru danych.

Cecha	Wartość
Odpowiedzi	60 962
Pracownicy	187
Pytania	164
Okres obserwacji	2023-04-24 – 2026-06-08
Sekwencje pracownik–pytanie	15 783
Zaobserwowane opcje odpowiedzi na pytanie, mediana (zakres)	3 (2–5)
Odpowiedzi na pracownika, mediana [IQR]	218 [67; 592]
Pytania na pracownika, mediana [IQR]	90 [26; 139]
Dni aktywności na pracownika, mediana [IQR]	84 [28; 220]
Odpowiedzi na dzień aktywności, mediana [IQR]	3 [2; 4]
Miesiące między pierwszą a ostatnią odpowiedzią, mediana [IQR]	18 [5; 30]
Próby w sekwencji, mediana [IQR] (maks.)	3 [2; 5] (19)
Sekwencje z $\geq$2 / $\geq$3 próbami (%)	78,6 / 60,6
Dni między próbami, mediana [IQR]	36 [18; 90]
Odpowiedzi poprawne, ogółem (%)	86,5
Odpowiedzi poprawne, pierwsze próby (%)	82,5

IQR: rozstęp międzykwartylowy. Sekwencja to seria prób jednego pracownika dotyczących jednego pytania. Wykluczone moduły testowe: mnk-tst (212 odpowiedzi). Wykluczone pytania z jedną zaobserwowaną opcją odpowiedzi: 2 (348 odpowiedzi).

wynik w trzeciej próbie był lepszy niż w pierwszej u 102 z 149 osób, a gorszy u 20 (średnia zmiana 3,8 p.p., 95% PU [2,4; 5,2]; tab. S5).

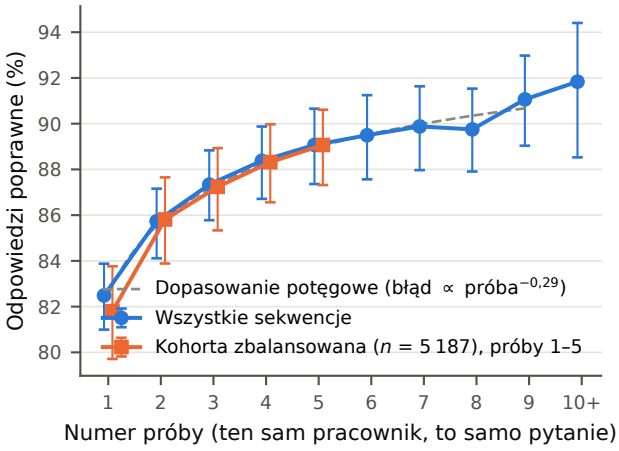
Tabela 2: Modele regresji logistycznej poprawności odpowiedzi: ilorazy szans [95% PU].

Predyktor	M1 (uczenie)	M2 (retencja)	M3 (nowe pytania)
Numer próby (na podwojenie)	1,38 [1,32; 1,45]	1,33 [1,24; 1,42]	
Poprzednia próba poprawna		3,85 [3,49; 4,26]	
Dni od poprzedniej próby (na podwojenie)		0,88 [0,86; 0,90]	
Staż pracownika (na rok)		0,87 [0,77; 1,00]	0,88 [0,76; 1,01]
Dane	Wszystkie próby	Próby $\geq$2	Pierwsze próby
Odpowiedzi	60 680	44 499	15 333
Pracownicy / pytania	163 / 164	146 / 163	162 / 161

Definicje modeli M1–M3 podano w podrozdziale „Modele statystyczne”. Wszystkie modele zawierają efekty stałe pracownika i pytania; błędy standardowe klastrowane względem pracowników. Pracowników i pytania bez zmienności poprawności usunięto przed estymacją (M1: 282 odpowiedzi). OR dla numeru próby i odstępu dotyczą podwojenia wartości, dla stażu jednego roku.

3.3 Wynik poprzedniej próby, odstęp i zapominanie (PB2)

W modelu retencji M2, po uwzględnieniu numeru próby, poprawna poprzednia odpowiedź wiązała się z wyższymi szansami poprawnej odpowiedzi (OR 3,85, 95% PU [3,49; 4,26]), natomiast dłuższy odstęp od poprzedniej próby wiązał się z niższymi szansami (OR 0,88 na podwojenie odstępu, 95% PU [0,86; 0,90]; tab. 2). Wśród odpowiedzi poprzednio poprawnych odsetek poprawnych zmniejszał się z 95,2%, gdy pytanie powtórzono w ciągu 14 dni, do 88,5% po 240 dniach lub dłużej; odpowiedzi poprzednio błędne były korygowane odpowiednio w 61,0% i 58,4% przypadków (rys. 2, tab. S3).



Rysunek 1: Odsetek poprawnych odpowiedzi według numeru próby w sekwencjach pracownik–pytanie. Koła: wszystkie sekwencje dostępne w danej próbie (ich liczba maleje wraz z numerem próby). Kwadraty: zbalansowana kohorta, tj. te same 5187 sekwencje, które osiągnęły co najmniej 5 prób, obserwowane wyłącznie w próbach 1–5, dzięki czemu każdy punkt opiera się na identycznych sekwencjach. Słupki błędów: 95% PU z bootstrapu klastrowego po pracownikach (2000 replikacji). Linia przerywana: dopasowanie funkcji potęgowej do odsetka błędów. Próby 10. i dalsze połączono.

Wzorzec ten jest zgodny z zapominaniem między powtórkami [4, 5].

3.4 Przejścia i utrwalone błędy (PB3)

Spośród odpowiedzi poprzednio poprawnych 92,6% [91,7; 93,3] było poprawnych również w kolejnej próbie, a 7,4% zapomniano. Spośród odpowiedzi poprzednio błędnych 58,5% [55,7; 61,3] skorygowano, a 41,5% pozostało błędnych, mimo że po każdej odpowiedzi wyświetlano poprawną odpowiedź (tab. 3). Gdy błąd się powtarzał (2546 przypadków), pracownicy wybierali ten sam dystraktor w 71,6% [69,4; 73,8] przypadków, wobec 47,1% oczekiwanych przy wyborze losowym i 59,6% oczekiwanych przy uwzględnieniu popularności poszczególnych dystraktorów. Wskazuje to na utrwalone błędne przekonania, a nie na zgadywanie.

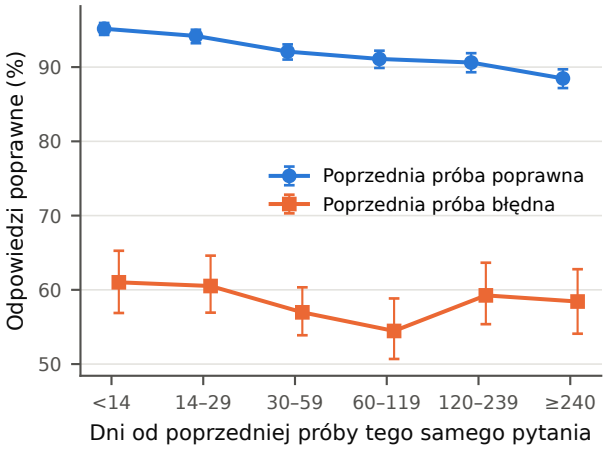
Tabela 3: Przejścia między kolejnymi próbami tego samego pytania.

Poprzednia próba	n	Kolejna poprawna (%)	95% PU	Kolejna błędna (%)
Poprawna	39 038	92,6	[91,7; 93,3]	7,4
Błędna	6141	58,5	[55,7; 61,3]	41,5

Po dwóch kolejnych błędach ten sam dystraktor wybrano w 71,6% [69,4; 73,8] przypadków ($n = 2546$); wartość oczekiwana przy losowym wyborze spośród zaobserwowanych dystraktorów wynosiła 47,1%, a po uwzględnieniu ogólnej popularności każdego dystraktora w danym pytaniu wynosiła ona 59,6%. 95% PU z bootstrapu klastrowego, w którym losowano pracowników (2000 replikacji).

3.5 Odporność wyników i nowe pytania

Oszacowanie efektu numeru próby pozostawało zbliżone we wszystkich specyfikacjach (OR od 1,29–1,50; rys. 3, tab. S4) i wynosiło 1,36 w zbalansowanej kohorcie, 1,30, 1,35 i 1,40 w sekwencjach liczących 3–4, 5–7 i co najmniej 8 prób, 1,29 w uśrednionym populacyjnie modelu GEE oraz 1,37



Rysunek 2: Odsetek poprawnych odpowiedzi według odstępu od poprzedniej próby tego samego pytania, osobno dla odpowiedzi poprzednio poprawnych (koła) i poprzednio błędnych (kwadraty). Słupki błędów: 95% PU z bootstrapu klastrowego po pracownikach.

w modelu mieszanym. Oszacowanie było wyższe po dodaniu stażu jako predyktora (1,50), ponieważ staż jest skorelowany z numerem próby.

W modelu nowych pytań M3 odsetek poprawnych odpowiedzi przy pierwszym kontakcie z pytaniem nie rósł wraz ze stażem (OR 0,88 na rok, 95% PU [0,76; 1,01]; tab. 2). Przedział ufności obejmuje zarówno brak efektu, jak i niewielki spadek, dlatego wynik oznacza brak dowodu na uogólnienie poprawy na nowe pytania, a nie dowód jego braku.

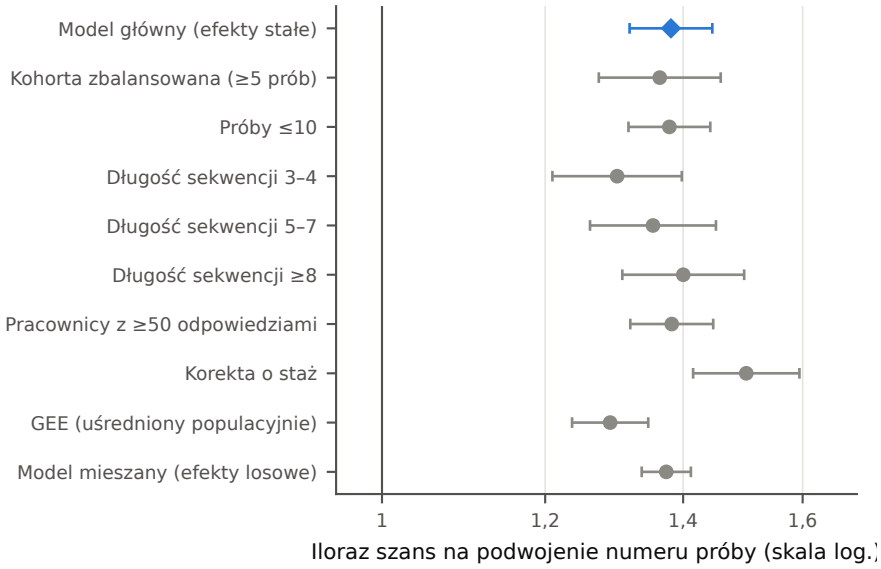
4 Dyskusja

4.1 Główne wyniki

W ciągu trzech lat rutynowego stosowania programu mikrouczenia odsetek poprawnych odpowiedzi na wielokrotnie prezentowane pytania rósł wraz z liczbą przypomnień zgodnie z funkcją potęgową, a efekt był odporny na ubywanie obserwacji, specyfikację modelu i klastrowanie danych. Poprawność malała wraz z odstępem od poprzedniego przypomnienia. Wcześniejsze błędy korygowano w kolejnej próbie tylko częściowo, a powtarzane błędy w większości odtwarzały ten sam dystraktor, mimo że po każdej odpowiedzi pokazywano odpowiedź poprawną. Efekt numeru próby, choć stabilny, wyjaśniał niewielką część zmienności poprawności; większa jej część wynikała z różnic trudności między pytaniami.

4.2 Uczenie się czy zapamiętanie klucza odpowiedzi

Ponieważ po każdej odpowiedzi wyświetlano odpowiedź poprawną, wzrost poprawności w powtarzanych pytaniach można wyjaśnić na dwa sposoby: przyswojeniem treści, której pytanie dotyczy, albo zapamiętaniem pary pytanie–odpowiedź. Oba mechanizmy prowadzą do tego samego wzorca w logu, a w badaniach, w których wielokrotnie wykorzystywano te same pytania, również nie dało się ich rozdzielić [7]. Za pierwszym wyjaśnieniem nie przemawia wynik modelu M3, w którym poprawność na nowo napotykanych pytaniach nie rosła wraz ze stażem; wynik ten jest jednak słabym testem, ponieważ pytania dotyczyły różnych tematów, a staż jest w obrębie osoby tożsamy z upływem czasu



Rysunek 3: Iloraz szans (95% PU) poprawnej odpowiedzi na podwojenie numeru próby w różnych specyfikacjach modelu M1. Romb: model główny; linia pionowa: brak efektu.

kalendarzowego, w którym pytania były przeglądane i zmieniane. Dla organizacji utrwalenie odpowiedzi na konkretne pytania regulacyjne może być celem samym w sobie; wnioskowanie o wiedzy wykraczającej poza pytania wymagałoby jednak równoległych pytań testowych, które nie byłyby powtarzane.

4.3 Porównanie z wcześniejszymi badaniami

Przebieg przyrostu odpowiada krzywym uczenia opisanym dla wielu zbiorów danych edukacyjnych [14] i jest zgodny z efektami testowania i rozłożenia w czasie [4, 25]. Randomizowane badania edukacji rozłożonej w czasie wykazały lepsze utrwalenie wiedzy [11, 13]; przedstawione dane obserwacyjne rozszerzają te ustalenia na niemedyczne środowisko pracy z długimi odstępami między powtórkami. Ujemny związek między odstępem a poprawnością jest zgodny z modelami krzywej zapominania dopasowywanymi do logów uczących się [26, 27]. W literaturze szkoleń organizacyjnych skuteczność ocenia się przez transfer do zachowań w pracy [2, 3]; dane z logu nie pozwalają go ocenić, opisują natomiast etap nabywania i utrwalania wiedzy, który transfer poprzedza.

4.4 Implikacje praktyczne

Najbardziej bezpośrednią implikacją jest trwałość konkretnych błędów. Wybory tych samych dystraktorów utrzymywały się mimo wyjaśnienia poprawnej odpowiedzi po każdej próbie, co sugeruje, że ogólne wyjaśnienie nie wystarcza do skorygowania błędnych przekonań. Skuteczniejsza może być informacja zwrotna odnosząca się do wybranego dystraktora, wyjaśniająca, dlaczego ta odpowiedź jest błędna. Program prezentował ponadto pytania w tym samym odstępie niezależnie od wyniku poprzedniej próby, podczas gdy harmonogramy adaptacyjne, które skracają odstęp po błędach i wydłużają go po poprawnych odpowiedziach, efektywniej wykorzystują historię uczącego się [17, 26, 27]. Analiza pytań w materiale uzupełniającym wskazuje kandydatów do zmiany: pytania o niskiej dyskryminacji, pytania rozwiązywane przez niemal wszystkich już w pierwszej próbie oraz dystraktory niefunkcjonalne [8, 28].

4.5 Ograniczenia

Badanie ma charakter obserwacyjny i nie obejmuje grupy kontrolnej, nie można więc przypisać przyrostu wiedzy programowi w sensie przyczynowym. Udział i aktywność różniły się między pracownikami, a wyniki dla sekwencji z wieloma próbami opisują bardziej aktywnych uczestników, choć analizy zbalansowanej kohorty i długości sekwencji nie wskazały na obciążenie wynikające z ubywania obserwacji. Odsetek poprawnych odpowiedzi w pierwszych próbach (82,5%) ogranicza zakres możliwej poprawy (efekt sufitowy). Odstęp między próbami nie był losowo przydzielany: dłuższe odstępy powstawały m.in. w okresach zawieszenia programu i nieobecności pracowników. Dystraktory, których nigdy nie wybrano, nie są widoczne w logu. Nie dysponowano informacjami o stanowiskach pracowników ani ich wcześniejszej wiedzy, a dane o wieku i płci były niedostępne dla 36 z 187 pracowników; cech demograficznych nie uwzględniano w modelach. Model mieszany zawierał wyłącznie losowe wyrazy wolne, nie modelowano więc indywidualnego tempa uczenia się. Dane pochodzą z jednej organizacji.

5 Wnioski

Powtarzanemu przypominaniu w ramach rutynowych szkoleń pracowniczych towarzyszyła poprawa w powtarzanych pytaniach, zapominanie między powtórkami oraz utrwalanie konkretnych błędnych odpowiedzi mimo informacji zwrotnej. Dane nie pozwalają rozstrzygnąć, czy poprawa dotyczy wiedzy, czy zapamiętania odpowiedzi na konkretne pytania. Logi takich programów mogą służyć do monitorowania utrwalania wiedzy, oceny pytań i projektowania adaptacyjnych harmonogramów powtórek oraz informacji zwrotnej ukierunkowanej na błędy.

Oświadczenia

Etyka. W badaniu wykorzystano dane przekazane przez bank, w których pracownicy byli reprezentowani przez kody. Dane dotyczące wieku i płci raportowano wyłącznie w postaci zagregowanej. [Informacja o zgodzie właściwej komisji etycznej lub zwolnieniu z obowiązku jej uzyskania, jeśli jest wymagana.]
Dostępność danych. Dane wykorzystane w badaniu stanowią własność klienta i nie są udostępniane publicznie.
Finansowanie. Badanie nie otrzymało finansowania.
Konflikt interesów. Autorzy deklarują brak konfliktu interesów.
Wykorzystanie narzędzi AI. Narzędzia generatywnej sztucznej inteligencji wykorzystano do przygotowania opisu wyników analizy oraz tłumaczenia tekstu na język angielski.

Literatura

[1] R. Harald Baayen, Douglas J. Davidson, and Douglas M. Bates. Mixed-effects modeling with crossed random effects for subjects and items. *Journal of Memory and Language*, 59(4):390–412, 2008. doi:10.1016/j.jml.2007.12.005.

[2] Timothy T. Baldwin and J. Kevin Ford. Transfer of training: a review and directions for future research. *Personnel Psychology*, 41(1):63–105, 1988. doi:10.1111/j.1744-6570.1988.tb00632.x.

[3] Brian D. Blume, J. Kevin Ford, Timothy T. Baldwin, and Jason L. Huang. Transfer of training: a meta-analytic review. *Journal of Management*, 36(4):1065–1105, 2010. doi:10.1177/0149206309352880.

[4] Nicholas J. Cepeda, Harold Pashler, Edward Vul, John T. Wixted, and Doug Rohrer. Distributed practice in verbal recall tasks: a review and quantitative synthesis. *Psychological Bulletin*, 132(3):354–380, 2006. doi:10.1037/0033-2909.132.3.354.

[5] Nicholas J. Cepeda, Edward Vul, Doug Rohrer, John T. Wixted, and Harold Pashler. Spacing effects in learning: a temporal ridgeline of optimal retention. *Psychological Science*, 19(11): 1095–1102, 2008. doi:10.1111/j.1467-9280.2008.02209.x.

[6] Albert T. Corbett and John R. Anderson. Knowledge tracing: modeling the acquisition of procedural knowledge. *User Modeling and User-Adapted Interaction*, 4:253–278, 1994. doi:10.1007/BF01099821.

[7] Stella C. M. Donker, Marc A. T. M. Vorstenbosch, Marie-José T. Gerhardus, and Dick H. J. Thijssen. Retrieval practice and spaced learning: preventing loss of knowledge in Dutch medical sciences students in an ecologically valid setting. *BMC Medical Education*, 22:65, 2022. doi:10.1186/s12909-021-03075-y.

[8] Mark J. Gierl, Okan Bulut, Qi Guo, and Xinxin Zhang. Developing, analyzing, and using distractors for multiple-choice tests in education: a comprehensive review. *Review of Educational Research*, 87(6):1082–1116, 2017. doi:10.3102/0034654317726529.

[9] Cyril Goutte, Guillaume Durand, and Serge Léger. On the learning curve attrition bias in additive factor modeling. In *Artificial Intelligence in Education (AIED 2018)*, LNCS, 2018. doi:10.1007/978-3-319-93846-2_21.

[10] Grant Ho, Ariana Mirian, Elisa Luo, Khang Tong, Euyhyun Lee, Lin Liu, Christopher A. Longhurst, Christian Dameff, Stefan Savage, and Geoffrey M. Voelker. Understanding the efficacy of phishing training in practice. In *2025 IEEE Symposium on Security and Privacy (SP)*, pages 37–54, 2025. doi:10.1109/sp61157.2025.00076.

[11] B. Price Kerfoot. Learning benefits of on-line spaced education persist for 2 years. *Journal of Urology*, 181(6):2671–2673, 2009. doi:10.1016/j.juro.2009.02.024.

[12] B. Price Kerfoot, Harley E. Baker, Michael O. Koch, David Connelly, David B. Joseph, and Michael L. Ritchey. Randomized, controlled trial of spaced education to urology residents in the United States and Canada. *Journal of Urology*, 177(4):1481–1487, 2007. doi:10.1016/j.juro.2006.11.074.

[13] B. Price Kerfoot, William C. DeWolf, Barbara A. Masser, Paul A. Church, and Daniel D. Federman. Spaced education improves the retention of clinical knowledge by medical students: a randomised controlled trial. *Medical Education*, 41(1):23–31, 2007. doi:10.1111/j.1365-2929.2006.02644.x.

[14] Kenneth R. Koedinger, Paulo F. Carvalho, Ran Liu, and Elizabeth A. McLaughlin. An astonishing regularity in student learning rate. *Proceedings of the National Academy of Sciences*, 120 (13):e2221311120, 2023. doi:10.1073/pnas.2221311120.

[15] Daniele Lain, Kari Kostiainen, and Srdjan Čapkun. Phishing in organizations: findings from a large-scale and long-term study. In *2022 IEEE Symposium on Security and Privacy (SP)*, pages 842–859, 2022. doi:10.1109/sp46214.2022.9833766.

[16] Kung-Yee Liang and Scott L. Zeger. Longitudinal data analysis using generalized linear models. *Biometrika*, 73(1):13–22, 1986. doi:10.1093/biomet/73.1.13.

[17] Robert V. Lindsey, Jeffery D. Shroyer, Harold Pashler, and Michael C. Mozer. Improving students' long-term knowledge retention through personalized review. *Psychological Science*, 25 (3):639–647, 2014. doi:10.1177/0956797613504302.

[18] Laura Martinengo, Marcus Sheng Pin Ng, Tabitha Dora Ruo Ng, Yu-Ian Ang, Ahmad Ishqi Jabir, Bhone Myint Kyaw, and Lorainne Tudor Car. Spaced digital education for health professionals: systematic review and meta-analysis. *Journal of Medical Internet Research*, 26:e57760, 2024. doi:10.2196/57760.

[19] R. Charles Murray, Steven Ritter, Tristan Nixon, Ryan Schwiebert, Robert G. M. Hausmann, Brendon Towle, Stephen E. Fancsali, and Annalies Vuong. Revealing the learning in learning curves. In *Artificial Intelligence in Education (AIED 2013)*, volume 7926 of *LNCS*, pages 473–482, 2013. doi:10.1007/978-3-642-39112-5_48.

[20] Shinichi Nakagawa and Holger Schielzeth. A general and simple method for obtaining R^2 from generalized linear mixed-effects models. *Methods in Ecology and Evolution*, 4(2):133–142, 2013. doi:10.1111/j.2041-210x.2012.00261.x.

[21] Allen Newell and Paul S. Rosenbloom. Mechanisms of skill acquisition and the law of practice. In John R. Anderson, editor, *Cognitive Skills and Their Acquisition*, pages 1–55. Lawrence Erlbaum, Hillsdale, NJ, 1981.

[22] Philip I. Pavlik, Hao Cen, and Kenneth R. Koedinger. Performance factors analysis - a new alternative to knowledge tracing. In *Artificial Intelligence in Education (AIED 2009)*, volume 200 of *Frontiers in Artificial Intelligence and Applications*, pages 531–538. IOS Press, 2009. doi:10.3233/978-1-60750-028-5-531.

[23] Jane L. Phillips, Nicole Heneka, Priyanka Bhattarai, Clare Fraser, and Tim Shaw. Effectiveness of the spaced education pedagogy for clinicians' continuing professional development: a systematic review. *Medical Education*, 53(9):886–902, 2019. doi:10.1111/medu.13895.

[24] Benjamin Reinheimer, Lina Aldag, Peter Mayer, Mattia Mossano, Reyhan Duezguen, Bettina Lofthouse, Tatiana von Landesberger, and Melanie Volkamer. An investigation of phishing awareness and education over time: when and how to best remind users. In *Sixteenth Symposium on Usable Privacy and Security (SOUPS 2020)*. USENIX Association, 2020.

[25] Henry L. Roediger and Jeffrey D. Karpicke. Test-enhanced learning: taking memory tests improves long-term retention. *Psychological Science*, 17(3):249–255, 2006. doi:10.1111/j.1467-9280.2006.01693.x.

[26] Burr Settles and Brendan Meeder. A trainable spaced repetition model for language learning. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics*, pages 1848–1858, 2016. URL `https://aclanthology.org/P16-1174`.

[27] Behzad Tabibian, Utkarsh Upadhyay, Abir De, Ali Zarezade, Bernhard Schölkopf, and Manuel Gomez-Rodriguez. Enhancing human learning via spaced repetition optimization. *Proceedings of the National Academy of Sciences*, 116(10):3988–3993, 2019. doi:10.1073/pnas.1815156116.

[28] Marie Tarrant, James Ware, and Ahmed M. Mohammed. An assessment of functioning and non-functioning distractors in multiple-choice questions: a descriptive analysis. *BMC Medical Education*, 9:40, 2009. doi:10.1186/1472-6920-9-40.

[29] Allison D. Taylor and Woei Hung. The effects of microlearning: a scoping review. *Educational Technology Research and Development*, 70:363–395, 2022. doi:10.1007/s11423-022-10084-1.